QCon
全球软件开发大会

InfoQ 技术大会

Agent的记忆不在对话里

把企业数仓沉淀为可治理的共享语义记忆

余锦泽 博士

大规模个性化定制系统与技术全国重点实验室

工业智能首席科学家



讲者简介



余锦泽 博士

大规模个性化定制系统与技术全国重点实验室 工业智能首席科学家

现任 大规模个性化定制系统与技术全国重点实验室数据智能分研究室负责人；早稻田大学客座研究员

方向 工业本体与本体增强检索、多智能体协同；计算机视觉、三维感知与具身智能

经历 东京大学博士；曾任亚马逊云科技日本生成式AI创新中心高级应用科学家 Connected Robotics AI与软件副总裁；曾在Mujin从事工业机器人视觉研发

成果 同行评审论文30余篇；全球专利121项（含在审，不计放弃、撤回与驳回），其中第一发明人美国授权专利22项；团队获日本机器人大奖

目录

01 AS-IS：现有做法与问题
02 TO-BE：本体辅助的Agent记忆
03 效果：改进前后对比
04 回到开头的问题：适用边界与建议

本次分享：从AS-IS到TO-BE

指标定义与表间关系不再只靠对话记忆或自动生成：写入本体前，先用数据核对

	AS-IS：现在的做法	TO-BE：本体辅助的Agent记忆
记忆从哪来	从对话与交互中提炼；或从表结构、已有语义模型、查询历史自动生成	对话与反馈进入动态记忆；指标定义与表间关系写入本体，附数据、代码与文档证据
谁决定写入	记忆框架由大模型判断新增、更新与冲突；语义层工具生成的关系，多靠人工核对	大模型只提出候选；程序用数据核对，给出“已验证”或“候选”；业务人员确认或否决
回答问题时	答案中看不出所用定义与关系是否经过核实	按问句组装本体子图；SQL执行前做本体约束校验；答案旁附计算规则卡和采用状态
出错以后	错误的关系留在记忆里，后续查询反复出错	人工否决即时传到下游，可以撤销；否决记录作为下一轮构建的反例
实测效果	只补实体与关系：8道题答对2道	**补上指标定义与校验：答对6道**（同一合成库、同一模型）

我们做的工作

- **方法**：证据分级 · 写入校验 · 本体约束校验
- **工具**：开源的Cosmo DataMind
- **验证**：合成库 · 公开基准BIRD · 真实平台

01

AS-IS：现有做法与问题

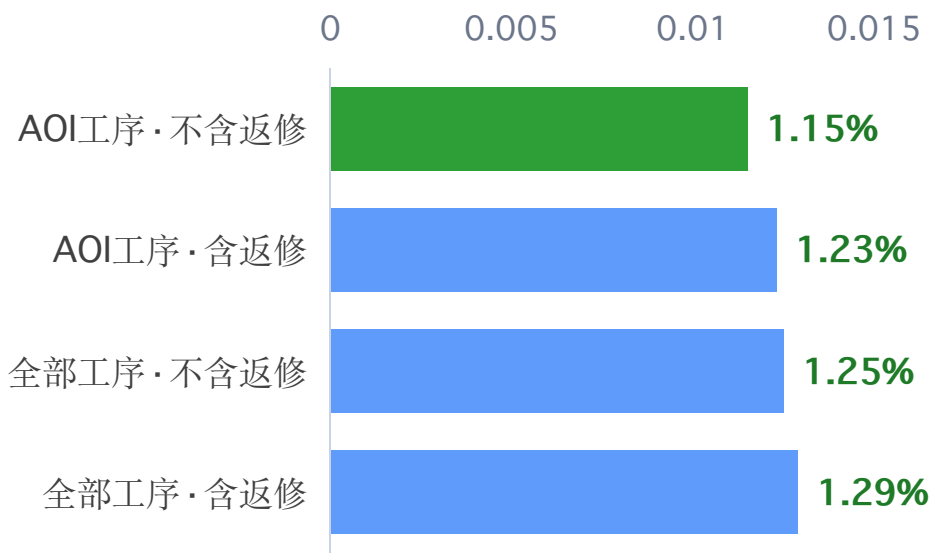
智能体靠什么记住企业的指标定义和表间关系？记错了会怎样？

一个问题，四个答案

AS-IS

四种算法都没有算错，结果却不同；该用哪一种由指标定义决定，而定义散落在表结构、代码和文档里

业务人员问： 上个月电路板的不合格率是多少？



绿色与质量日报一致。四种算法来自两个条件：只算AOI（自动光学检测）工序还是全部工序，是否计入返修（教学合成数据）

指标定义存放在哪里

表结构与注释

同一编号在不同表中列名不同；表间多无声明外键

某能源管理平台：近600张表，没有声明外键

查询代码与ETL

连接条件、过滤条件、去重规则写在代码中

某电子制造数仓：连接条件分散在十余个代码文件中

指标定义表与接口文档

分子分母、是否含返修、统计粒度写在文档中

某电子制造企业：指标定义写在十万字级的接口文档中

三种常见做法：流程与问题

AS-IS

指标定义与表间关系，现在主要靠人工建模、自动生成语义层，或从对话中提炼

人工建模

代表： dbt语义层（手写YAML）、Palantir本体管理器

流程

访谈业务 → 阅读表结构与代码 → 手写对象、关系与指标定义 → 评审后发布

问题

- 工作量大，表多又没有外键时难覆盖
- 定义与数据是否一致，靠人工抽查

自动生成语义层

代表： Fabric IQ、Snowflake Autopilot、Google Knowledge Catalog

流程

读取表结构、已有语义模型或查询历史 → 自动生成对象与关系 → 人工检查后发布

问题

- 关系取自已有模型或查询中的连接，是否符合数据多要人工确认
- 没有外键、查询历史少的库，线索有限

从交互提炼的Agent记忆

代表： Mem0、Zep、Letta、MemOS

流程

对话与反馈 → 大模型抽取事实 → 模型或规则判断新增、更新与失效 → 按相关度召回

问题

- 计算规则、数据证据和确认记录，通常不在对话里
- 一条错误的关系写入后，会在后续查询中反复使用

共同的缺口： 关系与定义写入时，很少逐条用数据核对；记忆里也不区分“已核实”和“未核实”，写错的内容会被反复使用

现有Agent记忆框架：记忆来自交互，写入多由模型判断

AS-IS

这些框架管理记忆的来源、版本与失效；企业指标还需要计算规则、数据证据与确认记录

Mem0

记忆来源

对话消息，结合会话摘要和近期消息

写入与更新

大模型在新增、更新、删除、不变中选择操作

冲突处理

与新信息矛盾的旧记忆由大模型判定删除

组织方式

自然语言事实；可选图记忆

Zep（Graphiti）

记忆来源

消息、文本与业务JSON；可自定义实体与关系类型

写入与更新

大模型抽取实体与关系，构建时序知识图谱

冲突处理

大模型比对新旧关系，为旧关系设置失效时间

组织方式

双时态：事实有效时间与系统记录时间

Letta（MemGPT）

记忆来源

对话与智能体自身的上下文

写入与更新

智能体通过记忆工具自行编辑

冲突处理

由智能体改写或替换记忆内容

组织方式

核心记忆块常驻上下文；其余记忆按需检索

MemOS

记忆来源

推理抽取、用户输入、外部检索与参数微调

写入与更新

记忆单元在生成、激活、合并、归档间迁移

冲突处理

明文记忆有冲突检测、去重与遗忘策略

组织方式

参数、激活、明文三类记忆；附来源、版本链与权限

构建工具对标：能自动生成，关系核对多靠人工

AS-IS

各产品都能生成或配置语义层；关系写入前是否与数据相符，公开文档中多要求人工检查

产品	关系怎样生成	写入前怎样核对数据	审核与版本
Palantir Foundry本体	在本体管理器中配置外键对主键、连接表；也可经MCP由智能体创建类型	自动匹配主键与属性类型；未说明取值核对	分支加提案评审，批准后合并
Microsoft Fabric IQ本体（预览）	从Power BI语义模型生成：表转为实体类型，沿用模型中的关系	要求人工检查键与数据绑定；未说明自动核对	低代码编辑；人工复查整份本体
Snowflake Semantic View Autopilot	从示例SQL、查询历史、表元数据与BI文件生成；关系取自查询中的连接	无效的示例SQL被丢弃；关系须由用户确认与数据相符	生成的建议经人审阅后应用
Databricks Genie	主外键自动导入；作者手工添加连接；按作者反馈建议新连接	未说明连接的取值核对	作者审阅建议
Google Knowledge Catalog（预览）	从查询日志的JOIN模式、大模型对表结构与数据重叠的分析中发现	未给出置信分数或阈值	未说明审批流程
dbt语义层（MetricFlow）	在YAML中声明实体，同名实体作为连接键；dbt Wizard（预览）可由智能体生成	校验项目能否解析、引用能否对上；含义不清时经人批准再抽样数据	人审生成的定义后写入；随项目代码做版本管理
本方案（Cosmo DataMind）	大模型从表结构、代码与文档提出候选	逐条检查包含率、唯一性、名称依据、引用方向，结果作为证据保存	评审台确认或否决并填写理由；可撤销、另存版本

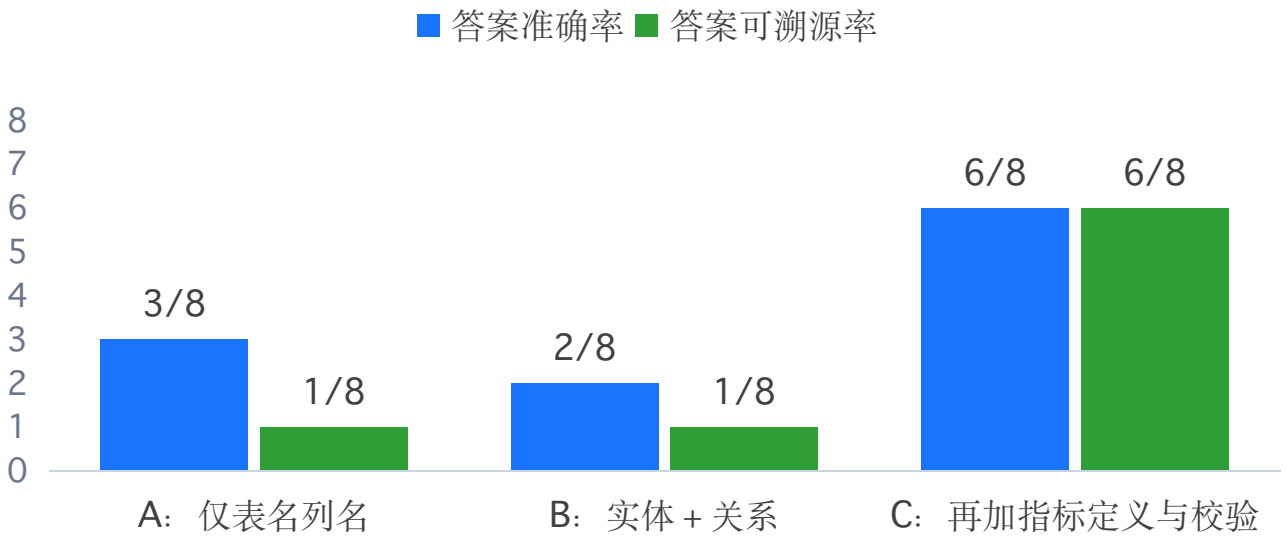
资料来源：各产品公开文档，2026年10月；“未说明”指公开文档中没有相应描述。Neo4j LLM Graph Builder主要处理非结构化文档，未列入

实测：只补实体与关系，准确率没有提高

AS-IS

B组比只给表名列名的A组少答对1道；再补上指标定义与校验的C组答对6道

三组对照实验（首轮）



108张表合成库、8道答案已在库上核对的题，同一模型与提示词，只替换上下文；小样本，只看方向

C组答错的2道题，原因是汇总表与明细表合计相差10.9%—17.4%；题面写明以明细为准、补上两跳连接并修正月均分母后，C组8道全对，A、B组不变

B组的错误

题目问设备总数。B组在名称相近的设备日汇总表上计数，只数到实际数量的五分之一。实体与关系把模型引向了相近的表，但没有提供指标定义。

记忆投毒是已知风险

AgentPoison（NeurIPS 2024）：向智能体的记忆或知识库投毒，诱导目标行为

MINJA（2025）：仅通过查询与观察输出，即可向智能体记忆注入恶意记录

企业场景中无需攻击者：一条错误的连接关系写入记忆，就会在后续查询中反复出错

02

TO-BE：本体辅助的Agent记忆

方法与开源工具：写入记忆的定义和关系有证据、可核对、可撤销

TO-BE总体架构：动态记忆与本体分工

TO-BE

对话与反馈仍由动态记忆承接；指标定义与表间关系写入本体，写入前用数据核对，回答时用本体约束SQL



四项要求

写入有校验
“已验证”只由数据校验给出

冲突有消解
数据、代码与文档相互印证

经验可积累
经验写成技能；否决的错误作反例

错误可撤销
单一写入入口；修改可撤销

写入流程：大模型提议、程序校验、业务人员确认

TO-BE

大模型负责提出候选，程序负责用数据检查，业务人员负责确认；五个环节，每一步都留下记录

	构建准备	① 候选生成	② 语义复核 与数据校验	③ 标准对齐 与约束检查	④ 范围与业务 问题核验	⑤ 人工审核 确认	发布与维护
大模型		提出对象、关系 属性与定义候选 并附来源	语义复核 只看名称与结构 结论：通过或存疑				
程序	构建前预检 生成分轮计划		数据校验 只看数据 已验证或候选	对齐上层本体 检查关系两端类型	找出孤立概念 检查需求问题 能否答到		构建验收 通过、复核 或不通过
业务人员	确定目标与范围 整理需求问题 登记证据			复核映射 确认约束	核对答案 整理未决问题	确认、否决 或修改 并填写理由	发布内容附来源 检查结果与 未决问题

全过程记录 来源与版本 · 检查条件与结果 · 语义复核意见 · 映射依据 · 核验结果 · 审核决定与理由 · 未决问题与复查要求

写入校验：程序如何判定一条表间关系

TO-BE

以投料记录连到元器件批次为例：四项条件都满足记为“已验证”，只满足一部分记为“候选”

投料记录（引用侧）

投料单	批次号	数量
I-01	B-001	200
I-02	B-002	120
I-03	B-001	80
I-04	B-003	60

`lot_no → lot_no`

包含率 = 共有去重值数 ÷ 引用列去重值数

本例：3 ÷ 3 = 100%

元器件批次（被引用侧）

批次号	零件	供应商
B-001	零件P1	供应商S1
B-002	零件P2	供应商S2
B-003	零件P1	供应商S3

① 取值包含

引用列去重取值在被引用列中的占比，即包含依赖（inclusion dependency）检验

② 唯一性

被引用列（或复合键）能唯一确定一条记录；严格判断，含空值即视为不唯一

③ 名称依据

去掉id、code、no等后缀后词根相同，或引用列名含被引用表名

④ 引用方向

唯一的一侧是被引用侧；两侧都唯一时，可能是一对一，也可能是巧合

默认阈值60%

20%—60%通常为候选

列名直指对方主键时20%以上可通过

低于20%不保留

在库内对完整取值集合计算

写入结果：一条带证据的记忆

TO-BE

按智能体记忆的常用分类（CoALA）组织条目；每条记忆都附带可复核的证据记录

语义记忆

对象、事件类型、关系、指标定义

情景记忆

历史问答、用户反馈与评审记录

程序性记忆

建模技能、已验证的SQL、需审批的动作

采用状态由证据决定，与记忆类型无关

关系 **投料记录 → 元器件批次**

质量追溯教学合成数据

来源	投料记录表的批次号列与批次表主键；候选由大模型提出，记录模型、提示词版本与时间
数据校验	取值包含率100%；被引用列唯一；词根相同；方向正确
语义复核	通过
标准映射	未映射，保留为本地关系并记录原因
人工审核	确认：可用于追溯查询
采用状态	已验证
使用范围	追溯查询；冻结批次等操作需另行审批
版本	v1.0

证据分级：采用状态由谁产生

TO-BE

状态由谁给出，决定了它有多可信；大模型不能把自己提出的候选标为“已验证”

角色	提出候选	置为已验证	置为人工断言	否决与撤销
大模型	✓	✗	✗	✗
程序（数据校验）	✓	✓	✗	复查未通过时降级
业务人员	✓	✗	✓	✓

- 接口中不存在由模型或人工把状态改为“已验证”的操作
- 人工确认一条已验证关系时，状态不变，确认记录另行保存
- 人工审核结果与程序校验结果分别记录，互不覆盖

已验证 verified

数据校验通过，且满足全部判定条件

人工断言 asserted

业务人员已确认，数据校验未通过或无法执行

候选 candidate

尚未确认；只读问答可用，答案须标明未确认

未决问题清单（gap list）

证据不足、业务分歧或范围未定的事项单独列出；不参与分级，随本体版本保存

冲突消解：数据校验与语义复核互补

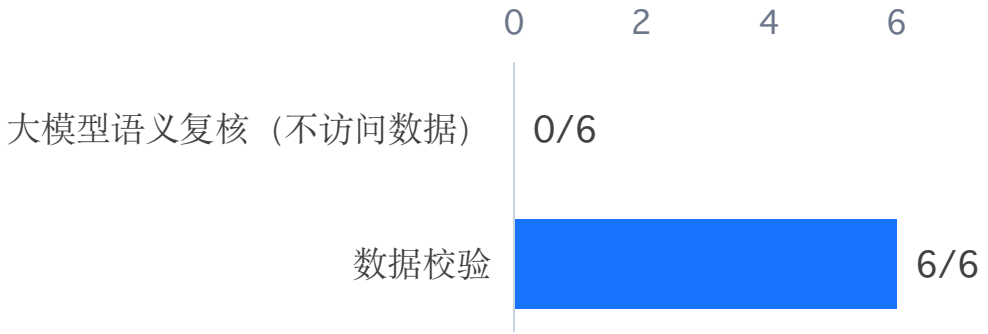
TO-BE

108张表合成库上，两类检查拦下的错误互不重叠，二者不能相互替代

	数据校验：通过	数据校验：不通过
语义复核：通过	**可能成立** 仍需人工核查引用范围、汇总规则、时间条件与例外规则	**名称合理，取值不符** 同名不同源、编号规则变更、快照不一致，由数据校验拦截
语义复核：不通过	**取值相符，业务无关** 代理键巧合、共享值域、派生列，由语义复核拦截	**两项都不通过** 不保留，记录判定结果

独立复核只降级、不升级；语义复核存疑时不推翻数据证据，转人工审核

名称陷阱探针（合成对抗库，6条）



数据校验的边界

8表对抗基准： 订单·状态码 → 状态字典（真）与订单·等级 → 库位·等级（假）四项条件均满足

108张表合成库： line_id既是产线表主键，也是采购订单行表主键，两条连接都通过数据校验；按字段注释写明的引用，错误的一条降为候选

回答问题：按问句组装本体子图

TO-BE

问数（用自然语言查数据）时，先找出相关的表，再沿已确认的关系补全连接，最后附上指标定义

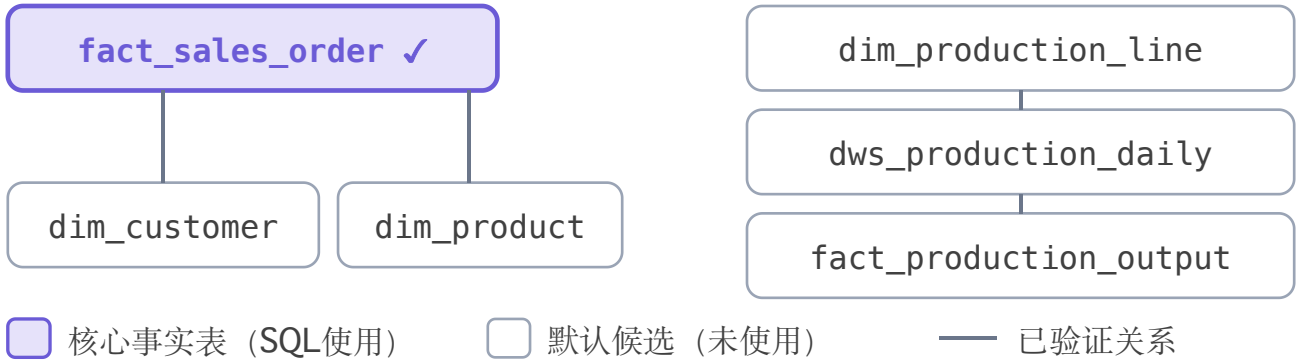
模式链接 → **指代延续** → **术语扩展** → **关系补全** → **附加指标定义** → **生成与核对** → **答案与出处**

- 模式链接：在选中本体内按问句打分召回
- 指代延续：取回上文提到的对象
- 术语扩展：用术语词典扩展召回
- 关系补全：只用已验证与人工断言关系
- 附加指标定义：计算规则、数据实际覆盖的时间
- 生成与核对：先探查取值；执行前校验、执行后核对
- 答案与出处：计算规则卡、出处表列、锚定子图

一次问答的锚定子图（示例本体）

问句：最近几个月毛利率的变化趋势

6个对象进入上下文　1张核心事实表　5个默认候选　1张表被SQL使用



一次问答（108张表合成库）

问句：最近一个月各产线产量趋势

14个锚定对象

9条关系（7条直连、2条两跳）

1张表被SQL使用

召回范围比实际使用宽一个数量级；遗漏一张必需的表，问题就无法回答

答案可核对：计算规则卡与本体约束校验

TO-BE

本体约束校验只拦截、不改写SQL；模型按拦截原因修改一次，改后的SQL重新校验

答案同屏展示的计算规则卡（示意，教学合成数据）

指标名称	电路板不合格率
计算规则	AOI工序、不含返修；不合格件数÷检验件数
出处	检验事件表；与质量日报核对一致
单位	%
状态	业务已确认；尚未核验的计算规则标注“数值仅供参考”
入口	数据血缘、锚定子图、图谱中高亮显示

澄清与拒答：表与问句对象对不上且重写无效时，列出候选表请用户指明；诊断对象不在本体中时如实拒答

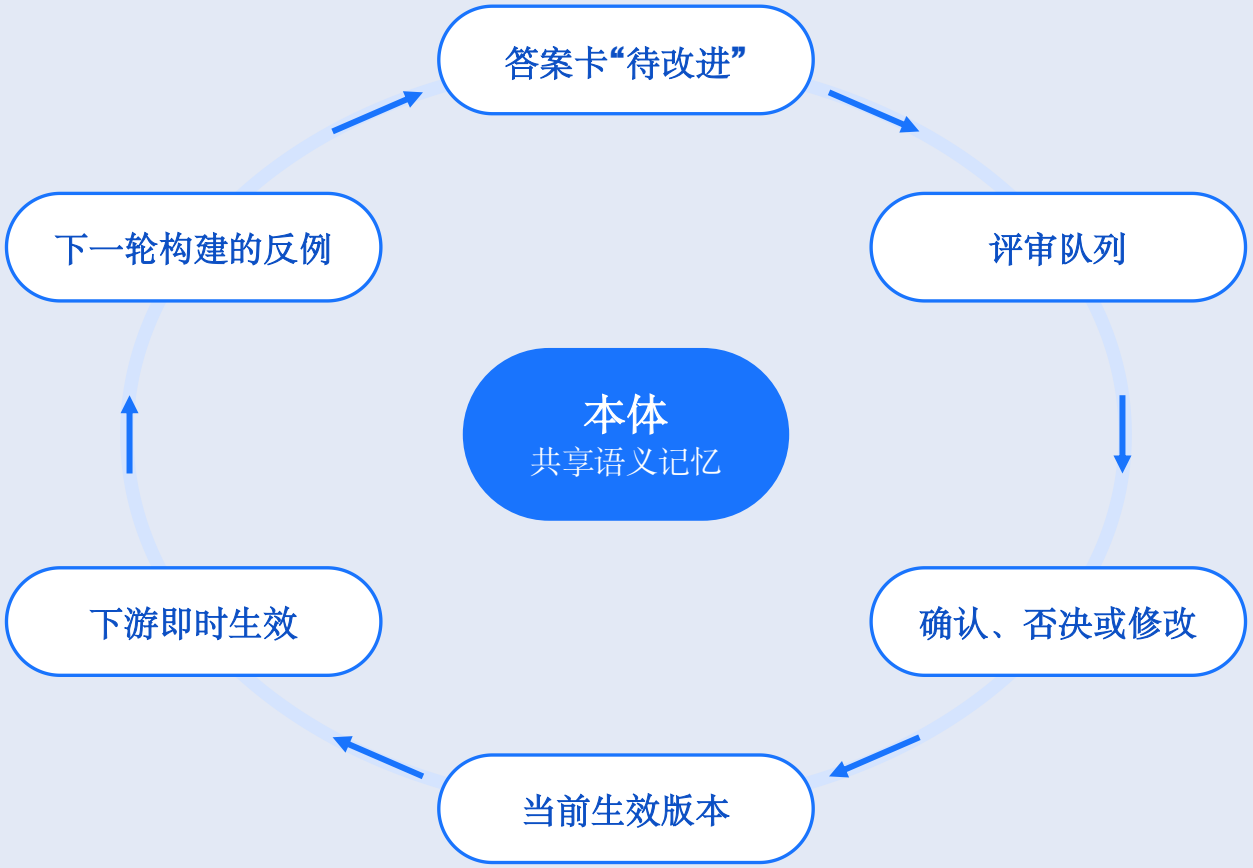
1. **只读单语句**
   多语句与写操作一律不执行
2. **表在允许清单内**
   只允许本次锚定与选中的表
3. **连接键落在已确认关系上**
   异名连接键须对应已确认关系；软删除、租户等有效行条件须写出
4. **扇形陷阱（fan trap）检查**
   一对多连接后对“一”侧列求和、求平均或计数会重复累加，即拦截
5. **问句与SQL意图核对**
   按规则分别判定问句与SQL的对象，不调用大模型；对不上时重写一次

意图核对发现的实例： 问“业务员维度表里有多少人”，SQL却在销售订单表上去重计数；前四项校验均放行，意图核对判为不一致

反馈回路：动态记忆经评审进入本体

TO-BE

答案卡上的反馈先进入评审队列；评审结论更新本体，即时改变下游，并在下一轮构建中作为反例



界面截图：本体评审台（节选）

关系	动词	状态	取值重合	语义评审	人审
采购日汇总表 → 供应商 DWS_PROCUREMENT_DAILY → dim_supplier	关联供应商	待取证	100%	通过	待审
生产日汇总表 → 车间 DWS_PRODUCTION_DAILY → dim_workshop	关联车间	待取证	100%	通过	待审
风险日汇总表 → 产品 DWS_RISK_DAILY → dim_product	关联产品	待取证	0%	通过	待审
安全日汇总表 → 车间 DWS_SAFETY_DAILY → dim_workshop	关联车间	待取证	100%	通过	待审

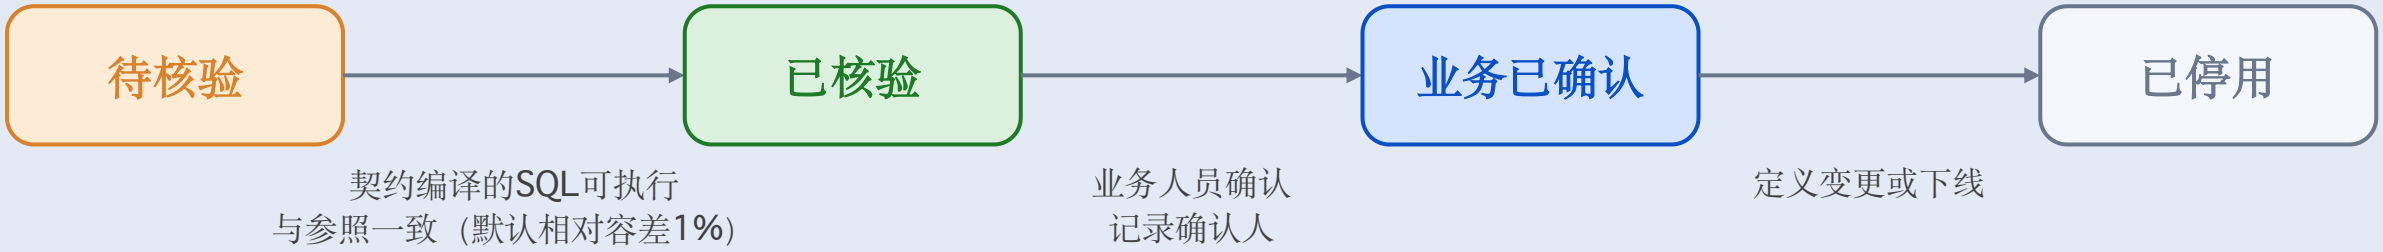
评审要求：必须填写评审人；否决与删除须填写理由；记录评审人、时间与理由

使用频次反馈：高频使用但仍为候选的，优先补充证据；长期零调用的，可能建模过度，需结合统计窗口判断

指标记忆：从待核验到业务确认

TO-BE

与关系一样，指标的“已核验”只由程序核验给出，“业务已确认”只能由业务人员给出



新的核验失败会撤销旧的机器判定状态；人工给出的业务确认与停用受保护；并发修改时返回冲突，不静默覆盖

指标契约：结构化的计算规则

绑定对象	度量列	聚合方式
过滤条件	时间列与粒度	可用维度

契约绑定单张表；可用维度为本表列与沿已确认关系一跳可达的列，跨表维度由问数经已确认关系连接；父侧维度标注重复计算风险

候选来源与对外服务

- 从历史SQL、指标定义表、已保存的SQL三个入口反解候选
- 含连接的历史SQL不推测计算规则，登记待人工拆解；含OR或子查询的条件不作为过滤条件
- 对外指标查询工具只返回业务已确认的指标
- 可按Apache Ossie（原Open Semantic Interchange）开发版格式导出，状态与证据放在扩展字段

开源工具Cosmo DataMind：方法的工程实现

TO-BE

前面的方法都实现在这个工具里：从接入数据、构建校验、评审治理，到问数使用和对外服务

接入与预检

- 文件上传
- 外部库只读抽样
- 预检不调用模型
- 生成分轮构建计划

构建与校验

- 大模型提出候选
- 四项条件数据校验
- 语义复核
- 上层本体映射
- 构建验收与交叉复核

评审与治理

- 确认或否决关系
- 修改关系动词
- 填写评审理由
- 撤销与另存版本
- 未决问题清单
- 指标生命周期

问数与使用

- 按问句组装子图
- 先探查，再生成SQL
- 本体约束校验
- 意图核对
- 答案附计算规则卡

对外服务

- 构建MCP
- 动作MCP
- 审批不对智能体开放
- 只返回已确认指标
- Apache Ossie导出

1252
项单元与行为测试

551
项HTTP集成检查通过

45
项场景回归检查

89%
确定性模块覆盖率

Apache License 2.0
github.com/cosmoplat-opensource/cosmo-datamind

03

效果：改进前后对比

相同的数据与题目，改用新方法前后的结果

效果：AS-IS与TO-BE对比

效果

每一行是同一场景下替换做法前后的结果；AS-IS列为常见做法或本工具改进前的版本

改善点	AS-IS	TO-BE	数据与规模
补充语义能否提高准确率	只补实体与关系：8道题答对2道	加上指标定义与校验：答对6道	108张表合成库
取值巧合造成的假关系	只看取值：精确率约36%	加入名称依据：精确率约68%	108张表合成库
真实数仓的表间关系	只有表结构：6条通过0条	加入代码与文档证据：通过5条	某电子制造数仓
问数准确率	只生成一次SQL：约24%	先探查、后核对：约42%（ReAct智能体约43%）	BIRD Mini-Dev，251题
已验证关系是否可靠	首轮240条中约三成可疑	全部594张表：487条；盲评抽查60条，59条为真	某能源管理平台
人工审核工作量	需人工查看367条	106条，减少约七成	同上
答错时是否提示	19道题中4道答错且无提示	0道；选错表时给出提示或请用户指明	同上，每题运行3次

小样本结果只看方向；问数由大模型生成SQL，多次运行结果会有出入

真实数仓：加入代码与文档证据后，6条关系通过5条

效果

只看表结构，6条关系都没通过；补充代码与文档、把多版本维度表去重后，5条通过

查询代码
质量追溯代码中的连接条件原文

指标接口文档
十万字级文档，整理为指标域摘要

看板指标定义表
反解出数百个候选，含连接的待拆解

一致性维度
维度表为多版本快照，按键保留最新一条

同一套
数据校验

仅表结构

0 / 6

加入代码、文档与一致性维度

5 / 6

制令号关系：维度表是多版本快照，被引用列有少量重复；按键保留最新一条后通过

区域编号关系：包含率100%、被引用列唯一，但列名不同，保留为候选；代码中的连接条件可作为人工确认的依据

代码中的连接条件用于提议与人工确认，不替代数据校验

数据分布与代码假设矛盾时以数据为准

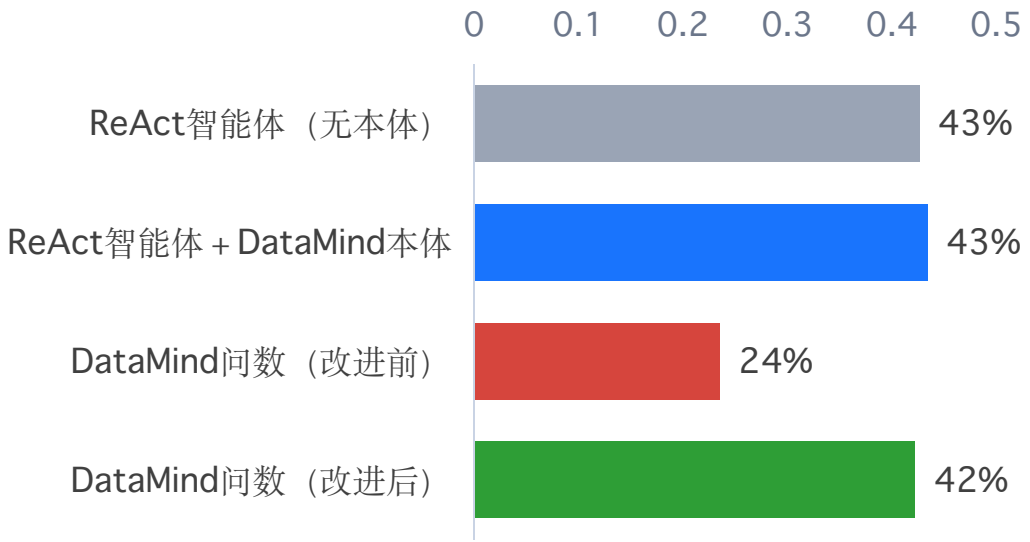
仅有单一弱证据时保留为候选

公开基准：同一份本体，问数流程决定准确率

效果

能探查数据的智能体用这份本体，准确率与不用本体时持平；只生成一次SQL的问数流程，准确率低得多

BIRD Mini-Dev留出测试集（251题）执行准确率



同一骨干模型DeepSeek-V4-Flash；ReAct智能体可多轮查看表结构与取值、试运行SQL

各条件在测试集上运行一次；诊断用验证集，精确作答提示词曾在查看8道测试失败题后修正一次

验证集上逐题诊断的原因

- 只生成一次SQL：不看取值、不试运行，结果为空也不修正
- 召回的表不全时编造表名，被本体约束校验拦下后拒答
- 意图核对过严：经持有外键的子表作答，被判为答非所问
- 规划线程丢失请求上下文，精确作答规则没有生效

修改

- 先探查：每轮最多3条只读查询，最多2轮，看到结果后再给出SQL
- 按结果核对：结果列、行数和前5行交给模型复查，需要时改写
- 上下文补全：列出全部表名、日期取值示例、问句中取值的出处

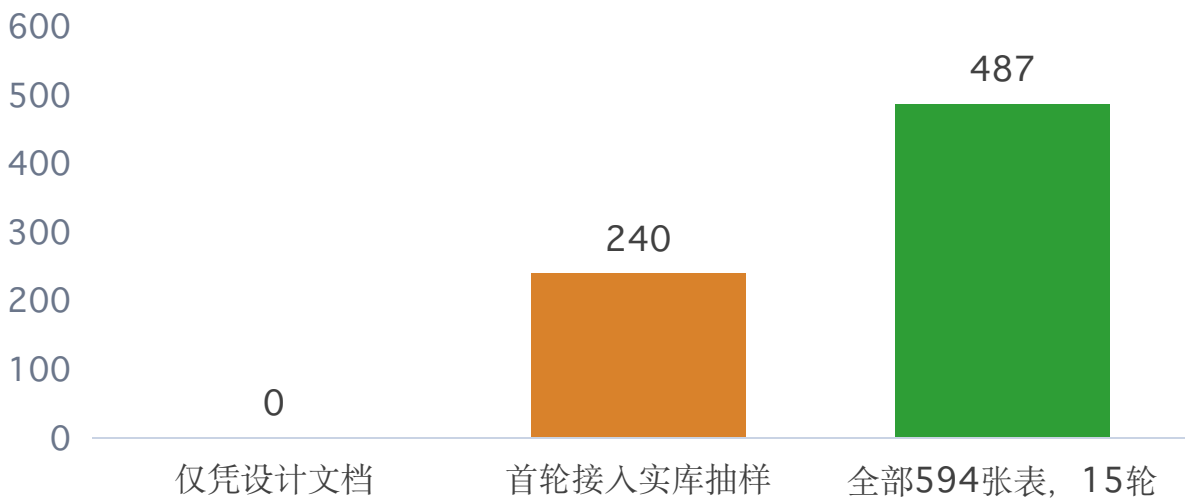
记忆提供给智能体，不等于被使用：带语义工具的ReAct智能体，只有约三分之一的题调用了这些工具

真实平台：从设计文档到全库分轮构建

效果

只凭设计文档得不到已验证关系；首轮已验证中约三成可疑，复核后抽查60条有59条为真

已验证关系（条）



首轮：240条中63条只因两表都带企业编号而判为“归属企业”，8条是自增id碰撞，合计约三成

全库：租户键只在关联表上提议；交叉复核把强冲突降为候选；两位评审盲评抽查60条，59条两人都判为真

需人工查看的条目

减少约七成

候选关系、复核疑点与待确认名称合计

候选关系按已有证据分为自动驳回、暂缓（待全量核对）与待审；驳回与暂缓保留证据和理由，可恢复

问数：19道题各运行3次

选错表时给出提示或请用户指明，没有静默答错；剩余错误主要来自模型给对象起的中文名不稳定，同类表之间选错

适用边界

数据来自只读抽样，大表只保留最新一部分记录；约80条暂缓的关系需要在全量数据上核对

04

回到开头的问题：适用边界与建议

这一次，智能体怎样给出唯一、可核对的答案？哪些情况适用？

回到开头的问题

这一次，计算规则来自本体中业务已确认的指标契约；答案可核对，反馈经评审再修改本体

业务人员问：
上个月电路板的不合格率是多少?

四种算法的处理

AOI工序 · 不含返修
登记为“不合格率”，由业务人员确认

AOI工序 · 含返修
全部工序 · 不含返修
全部工序 · 含返修
如需使用，登记为不同名称的指标

示意（教学合成数据）

1	模式链接	从问句锚定“不合格率”指标与检验事件对象	本体
2	指标契约	过滤条件为AOI工序、不含返修；时间为上个月	本体
3	采用状态	该计算规则已由业务人员确认；尚未核验时答案标注“数值仅供参考”	本体
4	本体约束校验	只读单语句、表在允许清单内、连接键落在已确认关系上	本体
5	答案与规则卡	1.15%，与质量日报一致；同屏展示计算规则、出处与状态	本体
6	反馈回路	用户标记“待改进”时进入评审队列，结论向下游传播	动态记忆

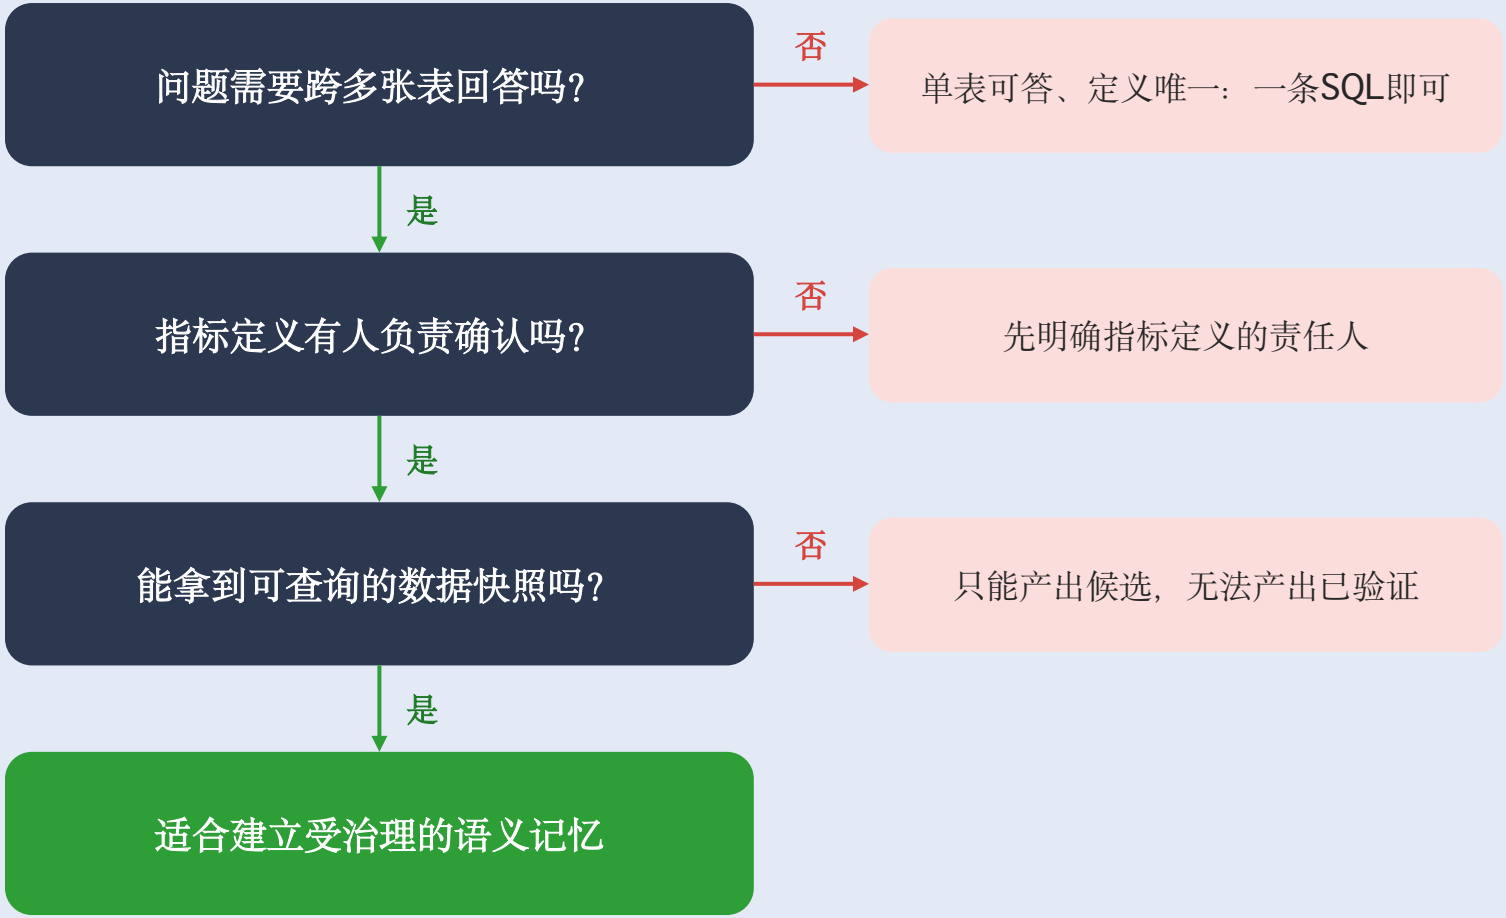
工程取舍

圆点位置表示当前实现偏向的一侧

1	覆盖率	——●——	准确性	证据不足的真关系保留为候选，不降低阈值换取完整；冷启动阶段覆盖有限
2	写入吞吐	——●——	一致性	单一写入路径与人工审核保证一致、可追责，代价是不适合高频自动写入
3	可撤销	——●——	可审计	基线不改写；撤销移除编辑日志末条，可另存版本；审计视图反映当前生效的变更集，还不是只追加（append-only）日志
4	通用阈值	——●——	按场景确定	默认60%取自4库合并数据上的阈值扫描，60%附近F1最高；孤儿记录等情形另有规则；跨行业需用目标数据复核
5	可复现	——●——	外部效度	公开基准与合成工业库可复现；合成库数据由业务过程仿真生成，不代表真实客户库；真实库评测受数据授权约束

适用条件

三个条件决定是否需要这套机制；智能体使用记忆分四种方式，目前实现前三种



智能体使用记忆的四种方式

只读问答

候选可用，答案标明未确认

提出建议

依据须为已验证或人工断言

经批准执行

人工批准，保留审批与执行记录

限定范围内自动执行

低风险且可撤销；事后审计

已实现前三种；经批准执行目前只记录审批与决策，不写回业务系统；第四种有意未实现

总结：从AS-IS到TO-BE

指标定义与表间关系经过校验和业务确认，开头的问题才有唯一、可核对的答案

AS-IS：现在的做法

- 记忆从对话中提炼，或从表结构自动生成
- 写入多由模型判断，关系核对多靠人工
- 错误的关系留在记忆里，反复出错
- 只补实体与关系，8道题答对2道

TO-BE：本体辅助的Agent记忆

- 动态记忆承接对话与反馈；本体保存定义与关系
- 大模型提议，程序用数据核对，业务人员确认
- 回答时按本体约束SQL，答案附计算规则与状态
- 否决可撤销，并即时传到下游

实施建议

1. 记忆附证据与状态；已验证只由数据校验产生
2. 阈值类改动同时做基准验证与目标库回归
3. 回答时用上记忆：先探查，再校验，后核对
4. 新增一类记忆时，写明由谁读取，并补一致性测试

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The Software



附

附录：细节与实践问题

写入校验、冲突消解、读取一致性等细节，供会后查阅

附：企业语义记忆的四项治理要求

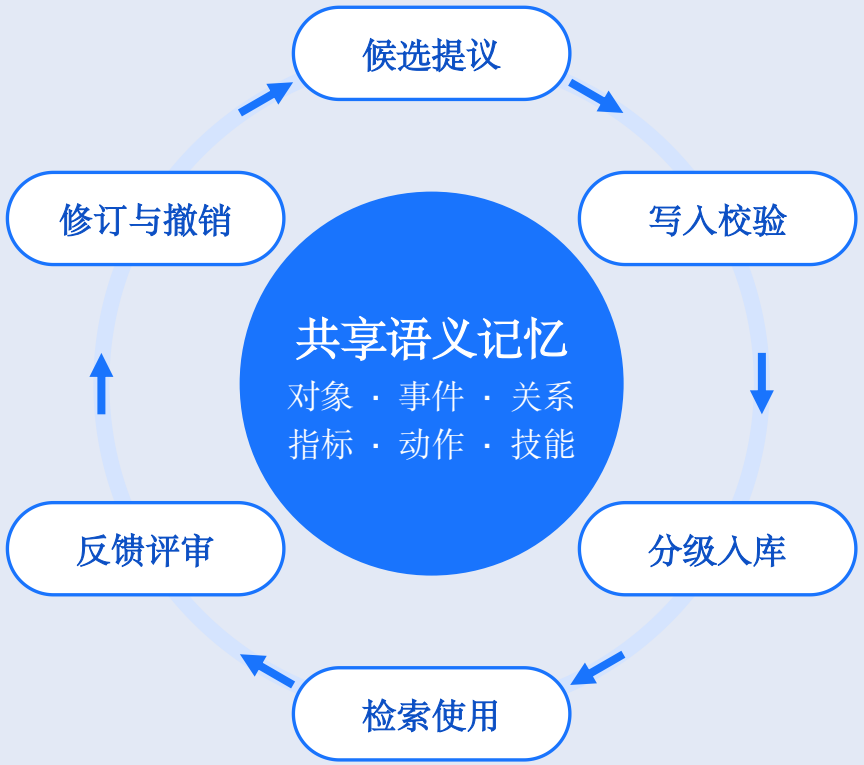
这类记忆以本体组织，即对象、关系、指标等的结构化定义；要稳定答对，它需要满足四项要求

写入有校验

大模型只提议；“已验证”只由数据校验产生

冲突有消解

数据、代码与文档相互印证；两类检查互补；扩大数据窗口复查



经验可积累

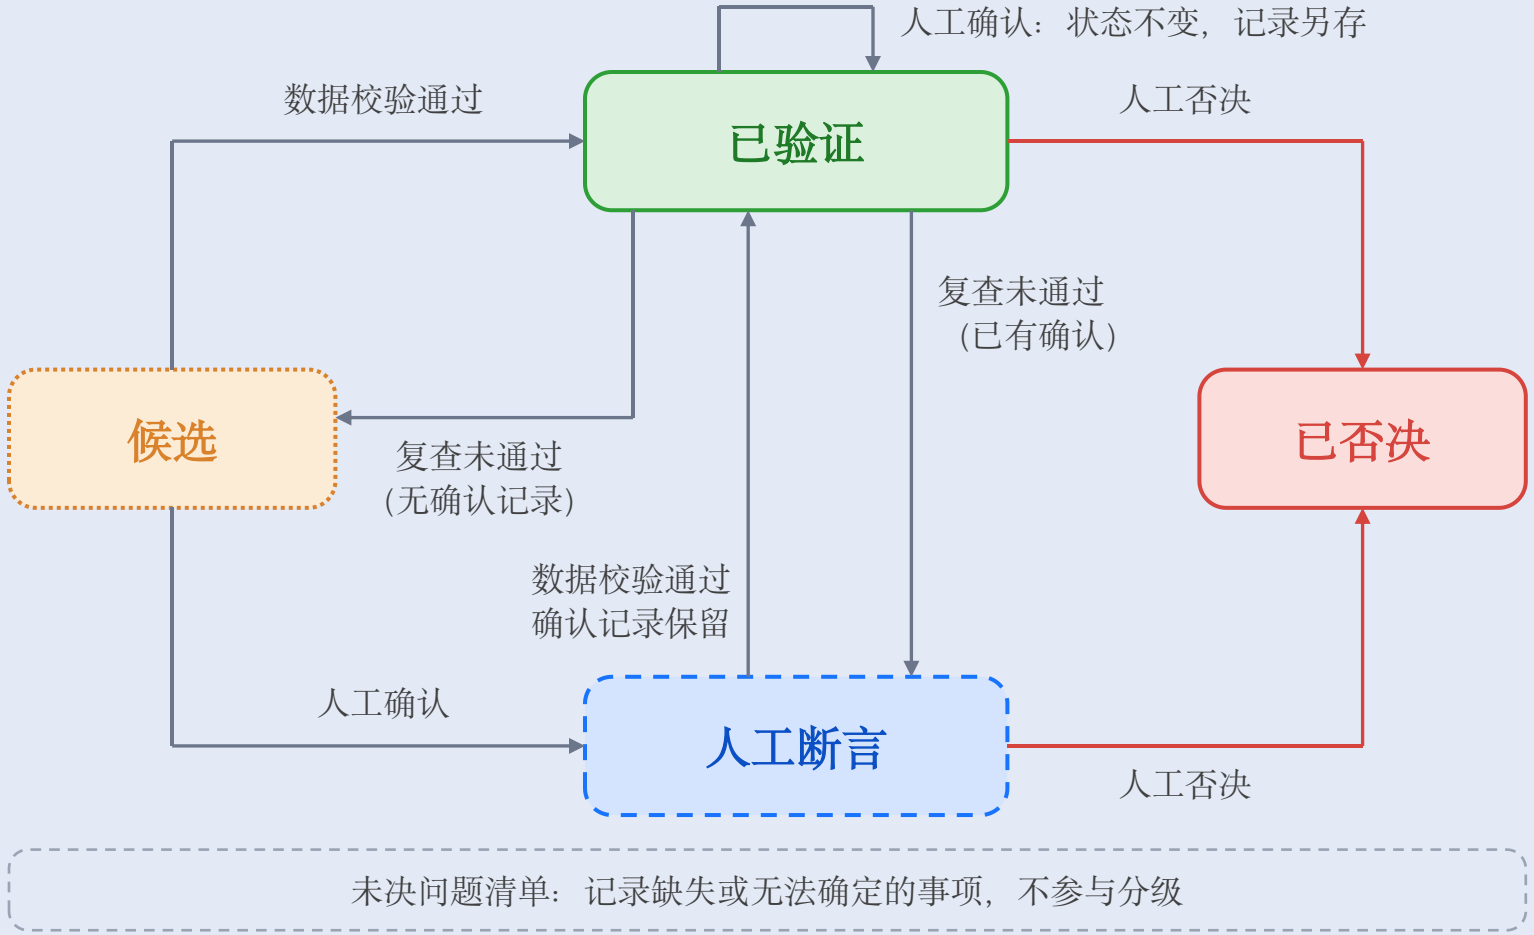
经验写成技能；否决过的错误作为反例；发现的问题变成检查项

错误可撤销

只有一个写入入口；每次修改有日志、可撤销；改动立即传到下游

附：证据变化时状态的升级与降级

程序判定的状态随最新一次数据校验升降；人工结论不被程序覆盖



迁移规则

1. 程序判定的状态服从最新一次数据校验
2. 人工结论不被程序覆盖：被否决的记录不会因后续校验通过而自动恢复，并作为反例进入候选生成
3. 推理结论的状态不高于任一前提，前提被否决时一并撤回
4. 每次变化保留前后状态、触发证据与时间

实现现状：合并时人工结论优先；交叉复核可把已验证降为候选；自动复查降级仅在指标上实现；推理结论撤回尚未实现

附：四成多的工单号在工单表中找不到

包含率不足未必是关系不存在，也可能是建模范围不全；这类事项记入未决问题清单

检验记录 · 工单号 → 工单 · 工单号 （教学合成数据）

检验记录中工单号的去重取值



编号全部以RW开头

1	数据校验	包含率约59%；找不到的约41%称为孤儿记录
2	记入未决问题清单	原因类型：范围未定；需查明孤儿编号的来源
3	核实来源	RW开头的是返修工单，补入返修工单表
4	复查	对工单与返修工单的并集，包含率100%

返修与开头的不合格率

找不到的编号都是返修工单。经工单表关联取数时，返修的检验记录会被连接过滤掉，结果相当于默认“不含返修”。开头四种算法的一处分歧就在这里；计不计返修由业务人员确定

未决问题清单应记录的内容

事项	原因类型
需补充的材料或决定	责任人
计划时间	处理结果

现有实现记录类型、说明与补救建议
责任人与计划时间尚未支持

附：两列独立编号的取值重合

两张表的自增编号（代理键）都从1开始，取值天然重合；只看取值，会把巧合当成关系

产品表.prod_id

1	2	3	4	5	6	7	8	9	10	...	15

生产订单表.order_id

1	2	3	4	5	6	7	8	9	10	...	N

仅看取值：包含率100%，被引用列唯一，误判为已验证

加入名称依据：prod_id与order_id词根不同，降为候选并送人工审核

取值证据只能说明数据没有否定这条关系，不能证明关系存在

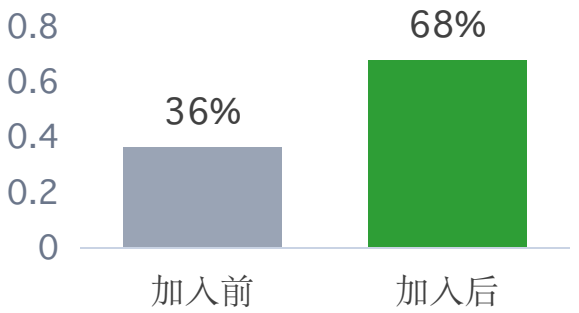
八成以上

一次构建中，带编号的关系属于这种巧合的比例

约15%

加入名称规则后被降为候选的比例；逐条核查都是巧合，其余未逐条核验

加入名称规则前后的精确率（108张表合成库）



假关系减少约3/4

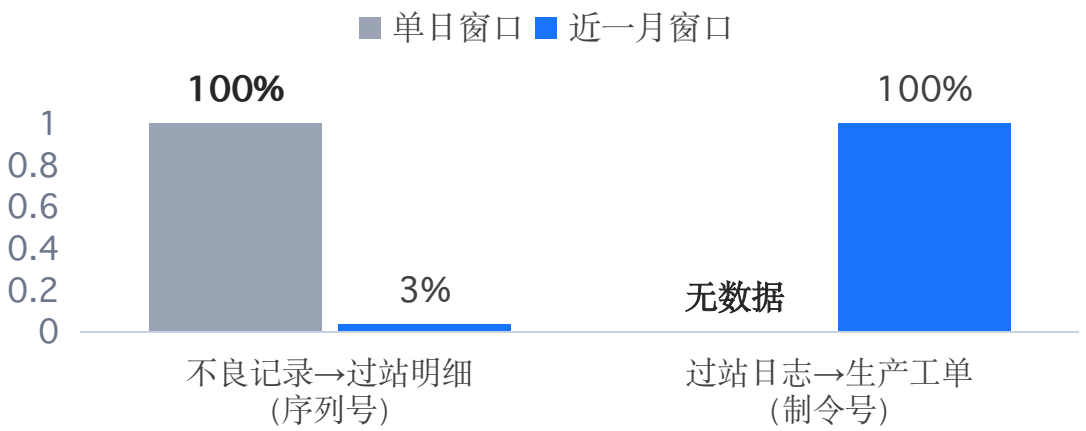
精确率提高到约1.9倍

召回率下降约5个百分点

附：只看部分数据会误判

数据窗口太短、取值被截断、类型没有对齐，都会让包含率失真

时间窗口（某电子制造数仓）：单日分区 → 近一月



↓ 降级　单日窗口内全部命中；扩大到近一月后仅约3%命中

↑ 升级　单日窗口没有数据；扩大到近一月后全部命中

取值截断（108张表合成库）

原实现只取前8000或20000个去重值，且未排序；改为在库内对完整取值集合聚合

约2%

已验证关系被降级

上百至数千行

每条被降级关系的孤儿记录

截断后的样本不能代表完整取值集合，包含率可能被高估；表越大，样本覆盖的比例越低

大表按时间窗、小表全量

外部库大表按主键取最新数据

在库内对完整取值集合聚合

比较前先对齐类型（字符串转为整数会得到假0%）

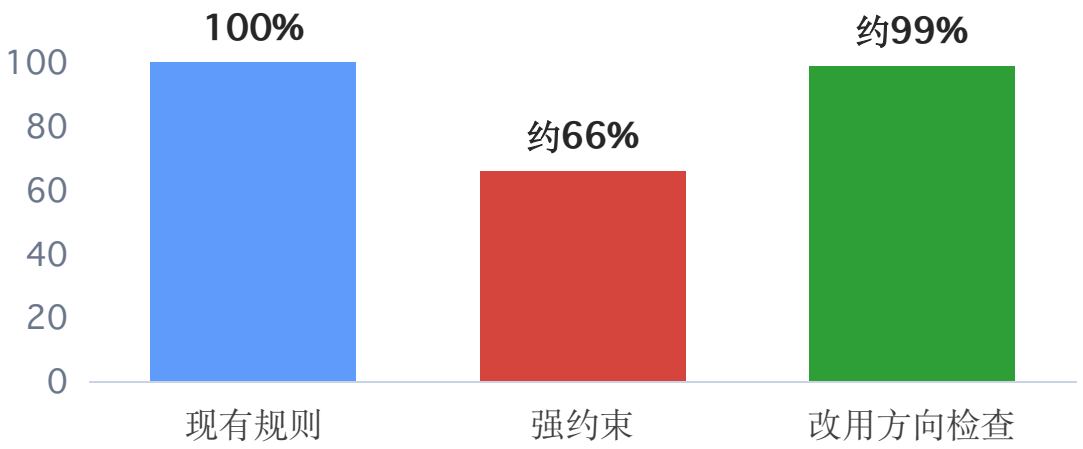
没有宽窗复查的结论标记“未复检”

附：判定阈值不能照搬

在别处有效的阈值，换到自己的库上可能误伤真关系；阈值改动要同时在基准和目标库上验证

移植上游引擎的强约束

引用列去重值≥3，且排除引用列唯一的候选；以现有规则为100%



强约束： 关系减少约三分之一，其中包括小维表中天然低基数或恰好唯一的真实外键

方向检查： 只剔除极少数共享维度键的巧合关系，真实关系没有丢失

基数自适应阈值

引用列去重值≥50时，阈值由60%降至50%

对抗基准

0.8 → 1.0

部分重叠真外键的召回率

108张表合成库

全部

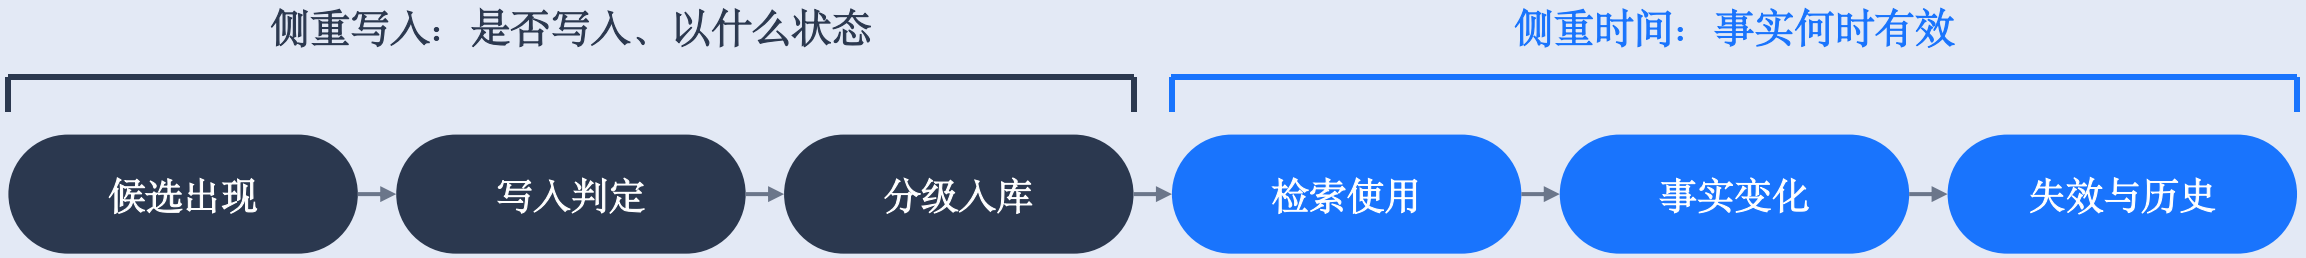
新增的已验证均为假阳性

原因：不同事实表的同名代理键（plan_id、order_id）取值偶然重合过半，与带孤儿记录的真外键信号无法区分

已实现，默认关闭

附：与时序知识图谱记忆的分工

本方案侧重按证据决定是否写入、以什么状态写入；时序知识图谱侧重事实的有效期与历史



企业语义记忆（本方案）

判定依据	数据校验、代码与文档证据、人工审核
数据变化后	按最新校验升降级（指标已实现，关系待完善）；人工结论不被程序覆盖
输出	已验证、人工断言、候选，以及未决问题清单

时序知识图谱记忆（如Zep）

判定依据	摄入新信息时由大模型比对新旧事实，识别矛盾
时间记录	事实有效时间与系统记录时间（双时态）
输出	失效的关系保留为历史，可按时间点回溯

两种机制侧重不同，可以组合使用

附：“已验证”只能由程序给出

这条规则写在接口实现里，不依赖规范文档或提示词约定

关系人审操作（server.py节选）

```
# 人审通过：candidate/gap/rejected → asserted
# verified 只记通过、不动状态
if kind == "confirm_relation":
    l.setdefault("review_prior_status",
l.get("status"))
    if l.get("status") != "verified":
        l["status"] = "asserted"
    l["human_review"] = "approved"
    _stamp_review(l, op)
```

关系编辑的允许清单中，没有任何操作能把状态写为verified；清单外的操作一律拒绝

指标状态接口

只接受业务确认、停用、退回待核验；提交“已核验”直接拒绝

构建服务（MCP）

唯一写操作是启动构建；不提供修改状态、删除图谱的工具

动作服务（MCP）

唯一写操作是发起动作；审批不向智能体开放

构建验收

每条已验证关系须附完整证据，否则验收不通过

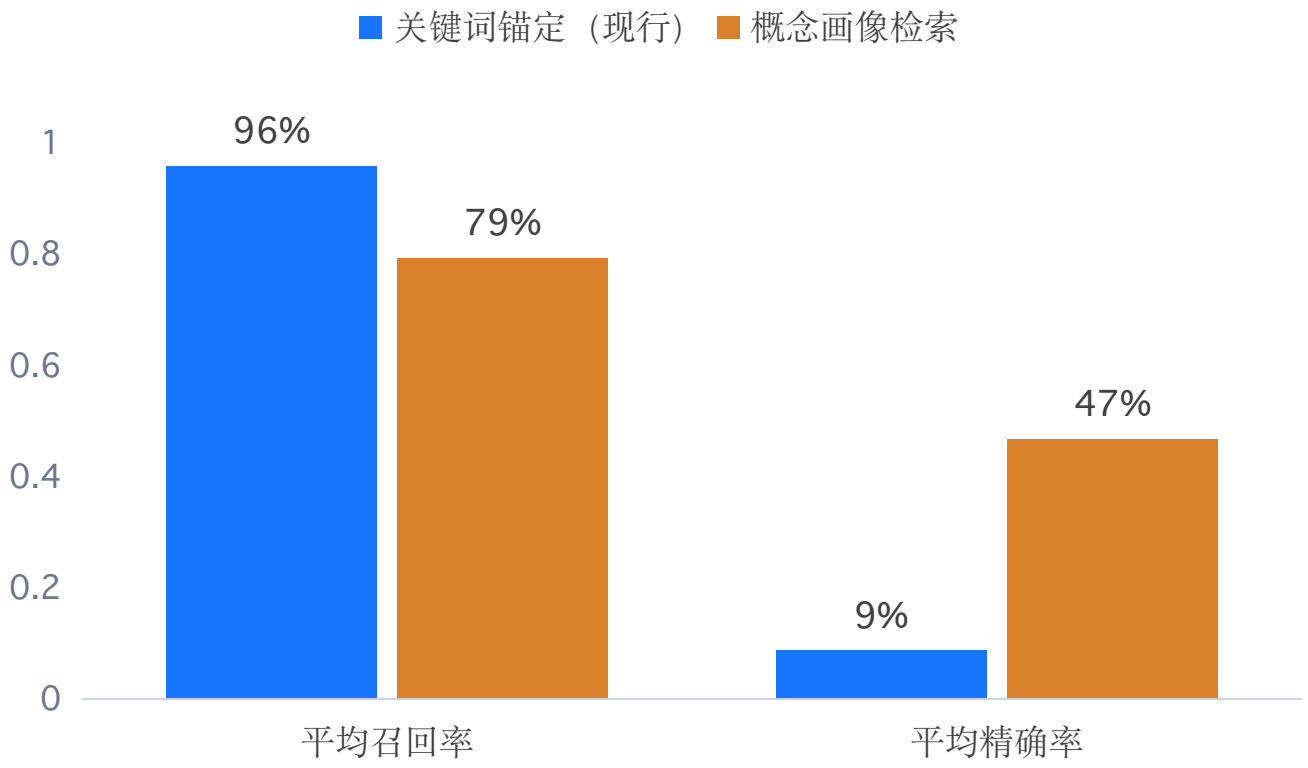
审计

人工试图直接指定“已验证”的编辑记为风险项

附：两种锚定方式对照，优先保证召回率

另一种检索方式（概念画像）带入的表只有约1/5，但会漏掉必需的表；默认方式保持不变

离线锚定对照：8道题，取前5个对象



约1/5

概念画像带入的表数，相对现行方式

下降约17个百分点

概念画像的平均召回率，相对现行方式

决定

- 默认保留关键词锚定：遗漏必需的表会导致问题无法回答
- 概念画像用于外部智能体的概念检索工具
- 不在同一份8题集上调整规则后再报告改进

附：中文实体匹配的四个细节

用本体里的名称和别名去匹配问句，不另外引入通用分词与指代消解组件

① 反向匹配

原实现按标点切词，“车间近期产能怎么样”整句成为一个词元，业务别名从未在召回中生效

改为用本体中的中文名、别名、指标名在问句中查找；单字不参与匹配

② 表名后缀剥离

“生产工单表”与问句中的“生产工单”精确匹配失败

剥离“表、事实表、维度表、汇总表”等后缀后再匹配

③ 指代延续

多轮追问中的“它”“该产线”无法定位对象

短问句或含指代词时，从上文取回对象并写入上下文

④ 缩写与数据时间窗

“ar”可能被理解为增强现实；模型按“最近3个月”生成条件，只命中约5%的数据

缩写锚定为“应收账款”；把数据的实际时间范围写入上下文

附：多个智能体共用一份记忆，只有一个写入入口

大模型只能把自然语言意图转换为带类型的受控操作，经预览和人工确认后写入

自然语言意图 → 带类型的操作 → 预览差异 → 人工确认 → 写入编辑日志 → 撤销或另存版本

用户

把“生产日报”“日产量”设为生产日度汇总的业务别名

```
{
  "op": "set_alias",
  "target": "obj:生产日度汇总",
  "params": {"aliases": "生产日报,日产量"},
  "reason": "用户指定的业务别名"}
```

编辑日志

- 操作人与理由
- 来源：对话、评审、图谱或接口
- 服务端时间戳

当前生效版本 = 基线 + 编辑日志回放

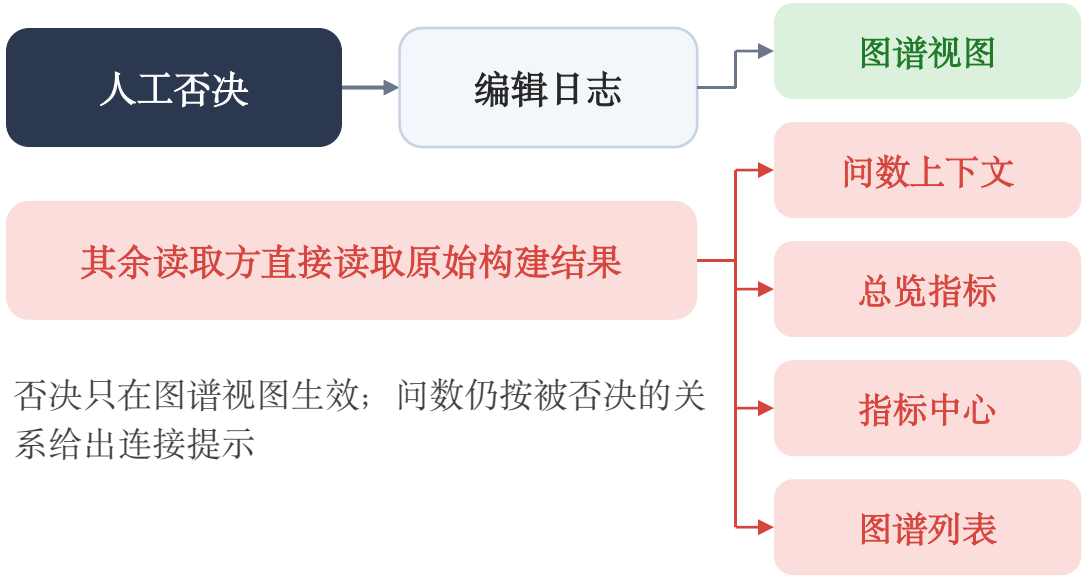
- 问数智能体
- 诊断智能体
- 构建智能体
- 外部智能体（MCP）

破坏性重建须显式确认，旧编辑日志改名保留；原始构建结果不被改写

附：读取入口不一致，否决未传到问数

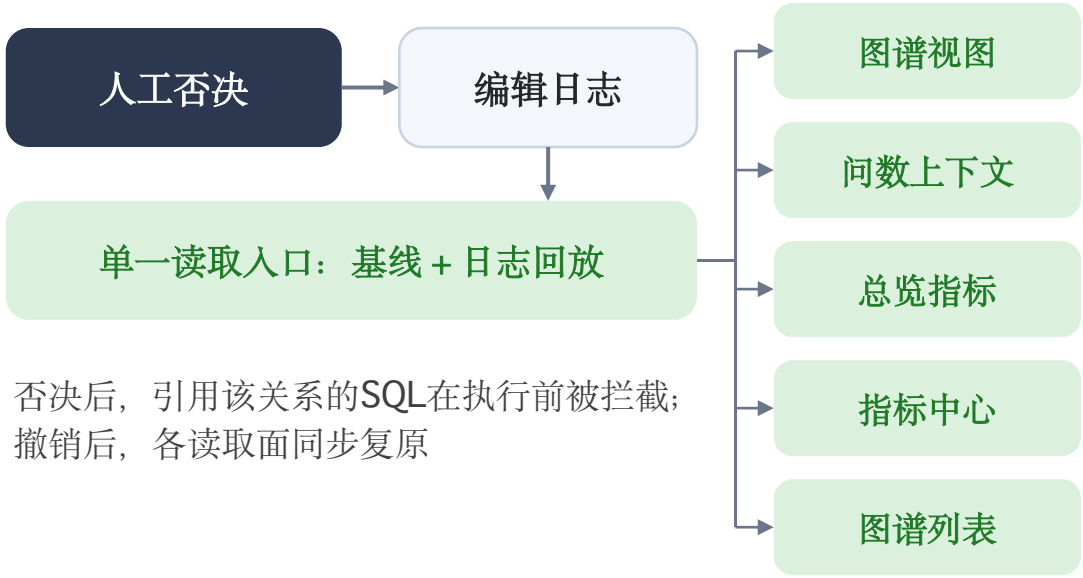
人工否决一条关系后，图谱已剔除，问数的连接提示仍引用该关系

修复前：读取方各自取数



否决只在图谱视图生效；问数仍按被否决的关系给出连接提示

修复后：单一读取入口



否决后，引用该关系的SQL在执行前被拦截；撤销后，各读取面同步复原

一致性测试

写入一次 → 断言每个读取面 → 撤销 → 再次断言每个读取面 → 联动检查全部通过

附：录入了却没有被使用的输入

每类输入都要写明由哪个功能读取；没人读取的，要么接上，要么在界面标注“仅登记”

输入项读取方审计：13项

CSV/TSV上传	文档与代码上传	图像上传
术语词典	构建技能	问数保存的技能
知识包	外部库连接	API数据源
动作外呼	评审意见	引擎配置
用户反馈		

有读取方　曾无人读取，已接入　有意保留的边界

术语词典	只做展示，不参与检索	→ 接入术语扩展召回
自定义构建技能	正文未进入构建提示词	→ 注入提示词并记录
问数保存的技能	只展示，不复用	→ 命中即复用已验证SQL

同类问题：文档只读取了开头

数十万字的设计文档，每份只读开头，合计再截断。改为整份读入、按标题分块，先按表名锚定，再用BM25补齐

约2%
修复前：模型读到的文档内容

约97%
修复后：找到对应说明段的表

附：建模经验保存为可插拔的技能

建模经验以技能形式保存并注入构建提示词；注入规范后候选规模缩小、已验证占比上升

人工编写的建模规范

限定关系动词；传感器、告警、质检、停机一律判为事件；定义写成“上位类 + 区别特征”，不循环

从已构建图谱确定性提取

动词表、类型分布、定义样例，不经大模型

人工否决样本

作为“已知误判模式”注入后续构建

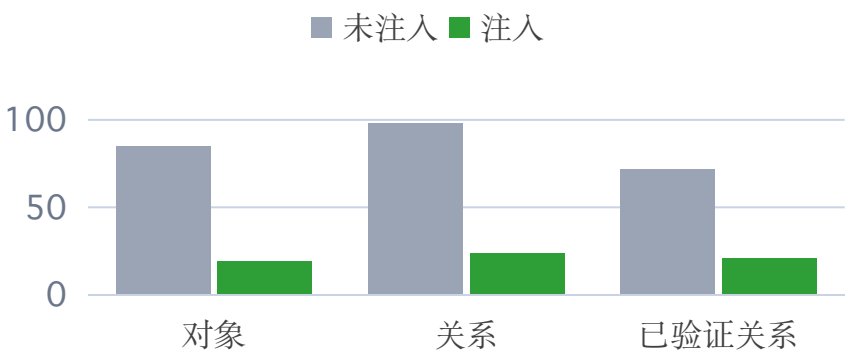
问数中验证过的SQL

相同问题直接复用；相近问题作为写法示例

技能库

可修改 · 可删除

注入建模规范前后（单次对照，108张表合成库）



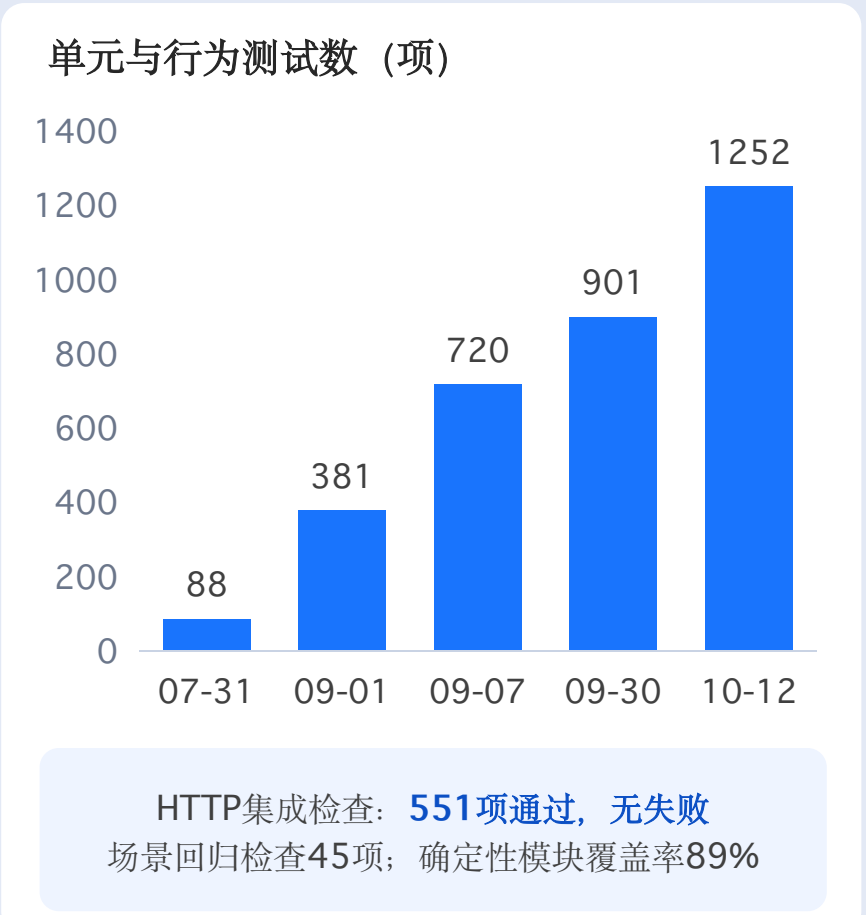
规模缩小到约1/4；已验证占比约七成→近九成

- 否决样本起初读取基线图谱，一条也取不到；改为读取当前生效版本后恢复
- 界面显示技能已修改，构建仍使用出厂正文；技能解析改为单一来源

附：已发现的问题都变成检查与测试

每个问题都对应检查项、接口约束、判定规则或评审清单；可自动检验的纳入回归测试

问题	固化为	形式
时间窗口过短	宽窗复查与未复检标注；外部库抽样规则	技能规范与实现
取值被截断	在库内对完整取值集合聚合	取证实现
人工断言冒充已验证	接口中没有写入已验证的操作	接口约束
输入没有读取方	读取方审计清单	评审清单
读取入口不一致	单一读取入口；写—读—撤销—读测试	一致性测试
问数一次生成、不看数据	先探查取值，执行后按结果核对	问数流程
汇总层与明细层不一致	分层对账，差异超过5%告警	数据质量项
空表的声明外键被判已验证	至少需要一行非空引用值	判定规则
同名键连到错误的父表	字段注释通道，冲突时降为候选	交叉复核技能



HTTP集成检查：**551项通过，无失败**
场景回归检查45项；确定性模块覆盖率89%

附：近600张表的只读预检

新数据源先做只读预检，再从被引用最多的枢纽表开始，分轮构建

近600
张表，6000余个字段

0
个声明外键

约1/5
的表使用软删除

数十
张表存在多态关联

近三成
的表共用同一编号

十余
轮构建计划

界面截图：预检结果节选（其中一个抽样子库）



预检只读、不调用模型，秒级完成；同时生成分轮计划：枢纽优先，限制每轮表数，疑似演示、临时、历史分表默认排除

单轮表数过多时，模型只绑定了约一半的表 → 限制每轮表数

继续构建时丢失跨轮关系；枢纽层后建，关系无处挂接 → 修复跨轮关系保留并改为枢纽先建后，跨库关系从1条增至百余条

附：语义记忆的评测维度

从写入、使用、数据三个方面分别评测；参考答案先在库上执行校准

写入侧：是否应写入

对抗基准： 植入代理键碰撞、方向相反、低基数巧合；干净子集上零泄漏、全召回

公开库： Chinook、Sakila、Northwind合并F1在九成以上；BIRD Mini-Dev的11个库精确率、召回率均在九成以上

复合自然键： Burr基准的Mondial库，召回率从约七成提高到九成以上

合成工业库： 108、200张表，对照声明外键与注释写明的引用，召回率均在97%以上

使用侧：是否正确使用

三组对照： 答案准确率与答案可溯源率

锚定： 召回率、精确率、带入表数

本体约束校验： 三组对照中误拦为0；漏拦统计待补充

问数准确率： BIRD Mini-Dev与合成工业库，按执行结果比对；双向划分、3次重复

数据侧：是否为数据问题

分层对账： 汇总层与明细层按相同条件合计，差异超过5%告警

源数据质量： 维表重复键、采样时段未对齐、类型转换导致的假0%

问句歧义： 同一问句可有两种理解，如按下单日期还是完工时间归年

正文与其他附录页中108张表合成库的结果来自该库重建前的版本；本页的合成工业库为重建后的版本

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师