QCon
全球软件开发大会

InfoQ 技术大会

AI + SRE ≠ AISRE

AI 如何真正进入生产运维闭环

周昕毅 | 携程大数据平台



QCon
全球软件开发大会

InfoQ 技术大会

目录

01 从一个现实的问题出发

02 在实际场景中寻求答案

03 携程实践一：告警自愈，AI参与生产故障处置

04 携程实践二：从专家经验到智能诊断，核心组件故障的AI识别

05 携程实践三：从资源监控到成本治理，AI驱动存储优化决策

06 总结：从AI辅助走向AI原生运维

01

从一个实际的问题出发

AI 到底能不能接管生产运维?

先用三次现场检验，判断 AI 是否真的进入生产

01 告警来了 能否给出优先级与影响面？ → 生产检验 判断必须引用实时指标、日志与拓扑

02 服务异常 能否安全执行并验证恢复？ → 生产检验 动作必须受控，失败能够熔断或回滚

03 成本上涨 能否找到浪费并推动落地？ → 生产检验 结论必须解释价值、风险与收益

能回答只是起点；能取证、执行、验证，才是生产能力。

CORE TENSION

会回答问题，不等于能承担 SRE 的工作

AI 的优势

- ✓ 读懂海量信号
- ✓ 快速生成假设
- ✓ 调用标准工具
- ✓ 持续吸收反馈

生产的要求

- ! 结论可解释
- ! 动作有权限边界
- ! 影响面可控制
- ! 结果可验证、可回滚

模型输出是概率性的 × 生产运维要求确定性

02

在实际场景中寻求答案

从 AI 辅助到 AI 闭环

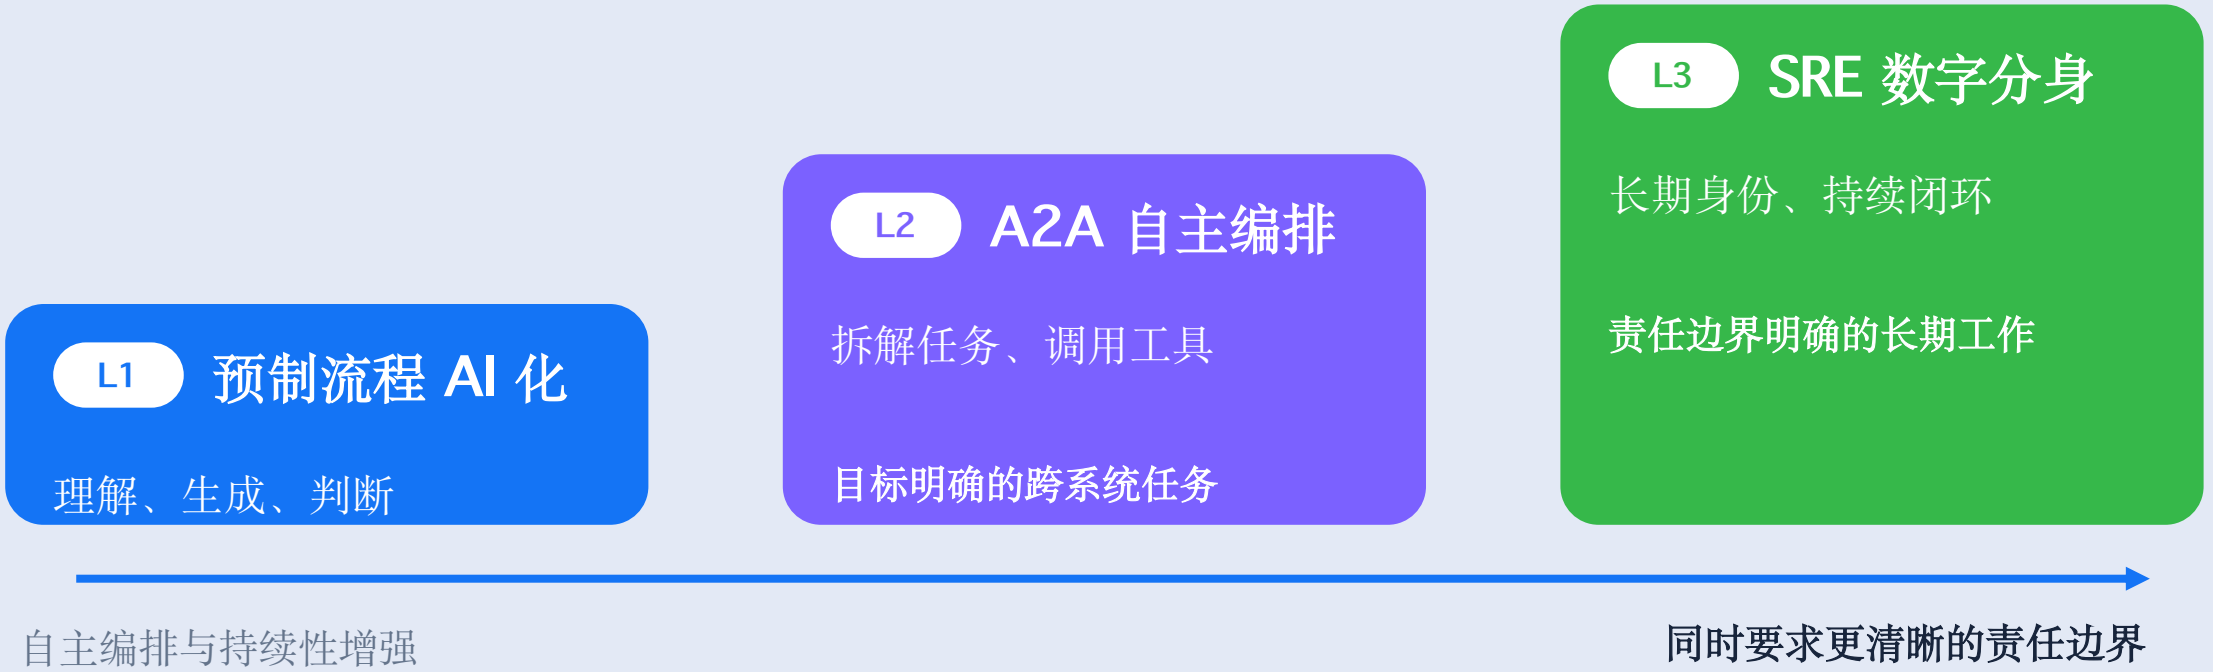
DEFINITION

真正的 AISRE：AI 进入完整运维闭环



Copilot 停在“分析与建议”；生产闭环必须走到“执行、验证和反馈”。

AI 智能运维的三层演进



L3 CONTROL PLANE

L3 不是“完全放权”，而是建立可控的数字分身

SRE 数字分身的生产底座

01 执行环境

OS 安全控制 · Skill 分级 · 身份隔离

02 任务过程

任务状态 · 检查点 · 结果复核

03 治理与质量

全链路审计 · 持续评测

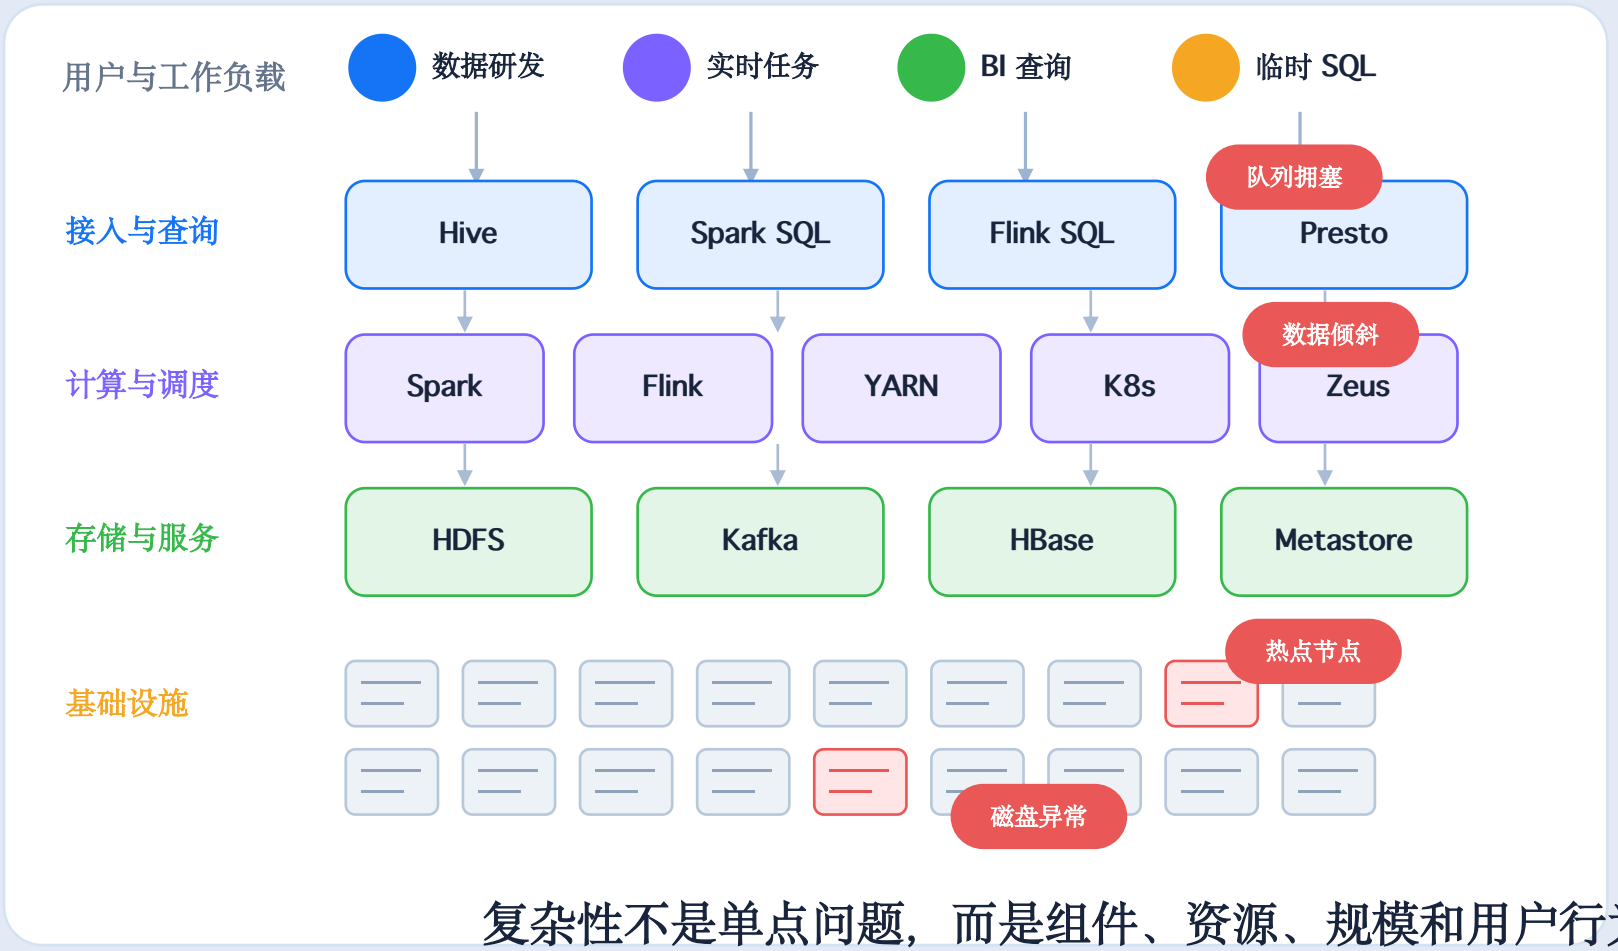
04 安全兜底

自动回滚 · 人工兜底

适合：长期、跨系统、责任边界明确

人工负责：跨业务影响与不可逆动作

为什么大数据平台 SRE 是 AISRE 的“压力测试”?



一个用户动作

↓

穿过多个组件

↓

竞争共享资源

↓

产生多源异常

↓

故障现象 ≠ 根因位置

错误动作还可能放大影响

复杂性不是单点问题，而是组件、资源、规模和用户行为的叠加。

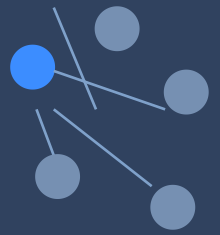
PRESSURE MAP

四种压力，决定 AI 必须具备四种生产能力

01

大数据组件复杂

多引擎、多版本、跨层依赖
同一症状对应不同根因



AI 能力：理解拓扑，组织证据

02

负载打满是常态

峰值、批任务、临时查询争抢
高负载并不等于故障

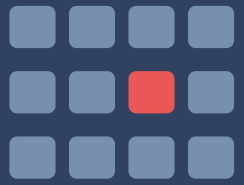


AI 能力：识别基线与业务优先级

03

机器数量多

节点故障频繁、噪声大
局部异常可能沿集群扩散

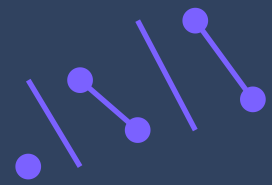


AI 能力：先聚合事件，再评估影响

04

用户行为不可控

临时 SQL、倾斜、流量突发
规则无法穷举故障模式



AI 能力：结合行为上下文并安全降级

告警噪声、跨组件根因、容量争抢和经验依赖往往同时出现。

三个场景，验证同一个闭环

稳定性 | 告警 → 自愈 | 发现· 分析· 执行 | 更快恢复 | 压缩故障处置时间

运维效率 | 经验 → 诊断 | 知识· 工具· 反馈 | 更快定位 | 复制专家判断能力

成本治理 | 监控 → 决策 | 识别· 协作· 验证 | 更优资源 | 推动治理建议落地

共同底座：多源上下文 → 可解释判断 → 受控工具 → 结果验证

03

实践一：从“告警”走向“自愈”

AI 如何参与生产故障处置？

INCIDENT

传统处置慢，不是因为没有告警



真正耗时的是：把信号变成一个可以安全执行的动作。

第一步：把“信号”收敛成“事件”



收敛的目标不是“少报”，而是给后续决策一个稳定、可解释的输入。

ROOT CAUSE

第二步：从“可能是”走向“证据链”

- 指标：什么时候开始异常
- 日志：发生了什么错误
- 变更：此前改变了什么
- 拓扑：故障如何传播
- 案例：历史上如何发生

假设生成与验证

1. 提出候选根因
2. 为每个假设找证据
3. 排除冲突信息
4. 给出置信度与影响面

OUTPUT

根因结论

证据摘要
置信度
影响范围
推荐处置

CONTROLLED ACTION

第三步：把“建议”变成“受控执行”

1 **预检**
依赖 / 容量 / 权限

2 **分级**
风险 / 影响面

3 **审批**
人工或自动

4 **执行**
幂等 / 超时

5 **验证**
关键指标恢复

6 **回滚**
失败立即止损

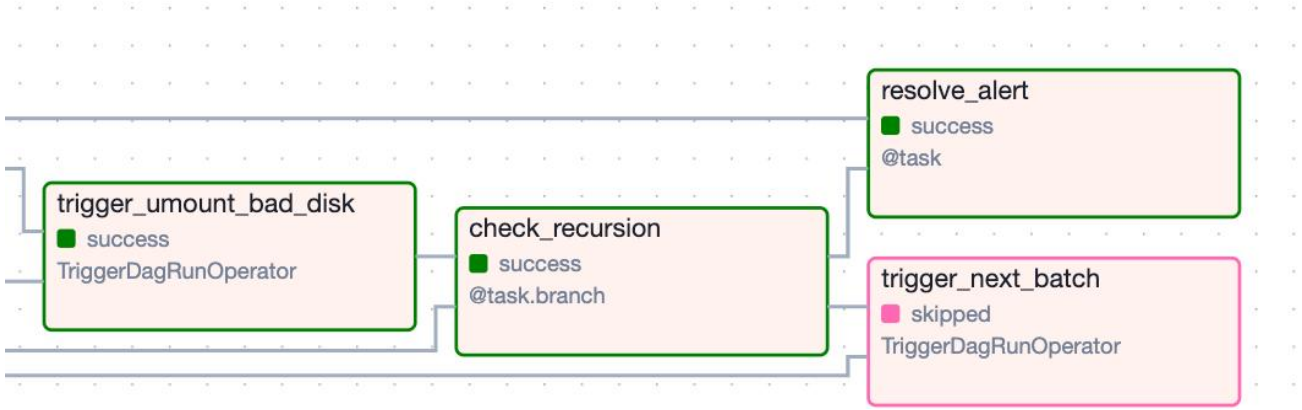
白名单　影响半径　速率限制　熔断开关　全链路审计

一次真实自愈任务：坏盘卸载如何闭环

累计任务 5,638　配置自愈 3,452　长耗时分析 2,186

真实运行量级

状态化执行 DAG



生产截图：卸载坏盘 → 递归检查 → 恢复告警 / 进入下一批

触发条件　SMART / IO wait 告警命中坏盘规则

关键判断　**本批是否完成？坏盘是否仍在服务？**

执行动作　调用白名单任务卸载坏盘

结果验证　**递归检查；成功恢复告警，失败进入下一批**

AI 负责跨信号归并、规则选择和状态判断；白名单 DAG 负责执行、审计与止损。

OUTCOME 01

结果：平台故障 MTTR 降低 50%

大量服务器与复杂架构，让故障发现和用户问题响应长期依赖人工

6 个技术支持群 · 11,031 人次

Artnova 4,460　Zeus 2,454　计算引擎 560　iData 757　Kafka 1,300　ES 1,500

此前：发现晚、处置慢

工程师持续处理监控告警和集群巡检，用户问题仍难以及时解决

案例 1

单台物理服务器 CPU 异常
P0 天级任务卡住，延迟超过 5 小时

案例 2

单个作业扫描数据量过大
五一期间拖慢多个 P1 作业，数小时后才发现

共同问题：异常发现依赖人工，影响持续放大

现在：巡检和自愈主动处置

磁盘	硬件故障、性能下降、寿命不足
CPU load	异常上升巡检
Black Hole	异常作业识别、自动拉群通知、自动 Kill

MTTR ↓ 50%　白名单动作，恢复失败转人工

从“数小时后发现”推进到异常识别、拉群通知和自动处置

04

实践二：从“专家经验”到“智能诊断”

核心组件故障，如何让 AI 真正理解？

CASE BACKGROUND

Spark 诊断：为什么模型直接回答还不够？

运维现场

证据跨系统

状态、阶段耗时、日志与配置分散

症状易混淆

同一现象可能对应多种互斥原因

结论要复查

每条判断都必须能回到原始依据

模型盲点

缺运行事实

只有报错文本，缺少现场运行数据

缺判断标准

容易套用最常见原因，未逐项区分

缺执行边界

证据不足时，仍可能生成一个结论

步骤固定 + 依赖取证 + 判断有标准 → 这类专家工作可以沉淀为诊断流程

一次诊断调用链：规则决定何时继续、何时停止



AI 的实际贡献：根据上一步证据动态下钻，并在规则边界内形成可复查结论。

先锁定分析对象，再从真实系统取证

CONTEXT

一个链接可能对应多次执行

1. **解析输入** — 识别任务链接、任务 ID 或自然语言
2. **建立诊断记录** — 一次诊断独立留档，会话内自动继承
3. **汇总上下文** — 状态、耗时、日志与配置按优先级合并

TOOLS

各系统负责一类证据

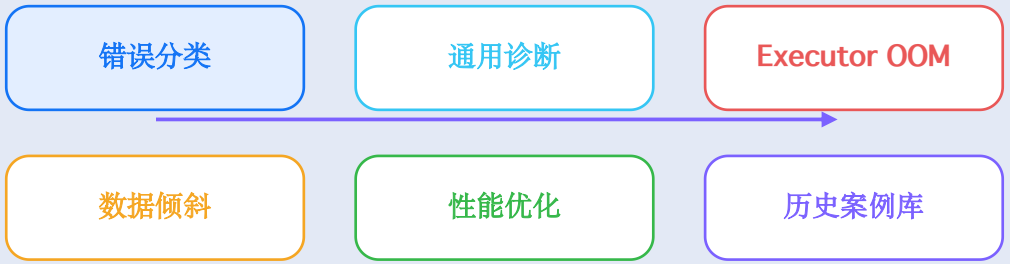
- **Zeus** — 本次执行结果与耗时
- **运行历史** — 各阶段耗时排序与倍数
- **资源与配置** — 当前配置值，作为建议前提
- **执行现场** — 只获取可疑阶段的日志片段

可回溯：报告里的每个数字都能查到来源

SKILLS + RULES

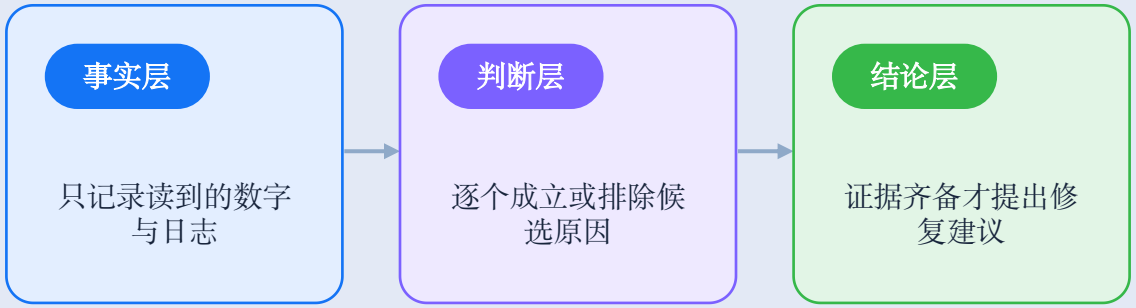
把专家判断写进 Skills，把证据门槛写进 Rules

按报错类型分流到专项技能



入口识别后，进入对应排查路径

证据分层后再下结论



固定执行边界

- 避免名称相似造成误判
- 只认实际执行计划
- 只调用只读白名单工具
- 公共资源改动交回负责方
- 证据不足允许给出否定结论

REAL CASE

一次 Spark 长尾诊断：三个数字锁定根因

2.7×

长尾成立

最长子任务 / 中位数

→

608 MB

分区倾斜

最大分区；中位数 < 1 MB

→

83 / 70 MB

广播被拒绝

维表大小 / 广播阈值

AI 取证路径：阶段耗时 → 分区分布 → GC / IO / 空值排除 → 执行计划与阈值配置

根因修复与验证

阈值 70 → 90 MB | 83 MB 维表恢复广播

倾斜缓解与验证

拆分目标 128 → 64 MB | 倾斜分区 5 → 10

结论可复查：每个判断都绑定现场数字、排除项和配置依据。

DELIVERY

从一次诊断，变成可复用的生产服务



基座 切换 AgentArk

维度 单任务 → 队列资源

开放 通过 MCP 复用能力

一套诊断能力，多入口交付；新人更快上手，On-call 减少重复排查。

05

实践三：从“资源监控”到“成本治理”

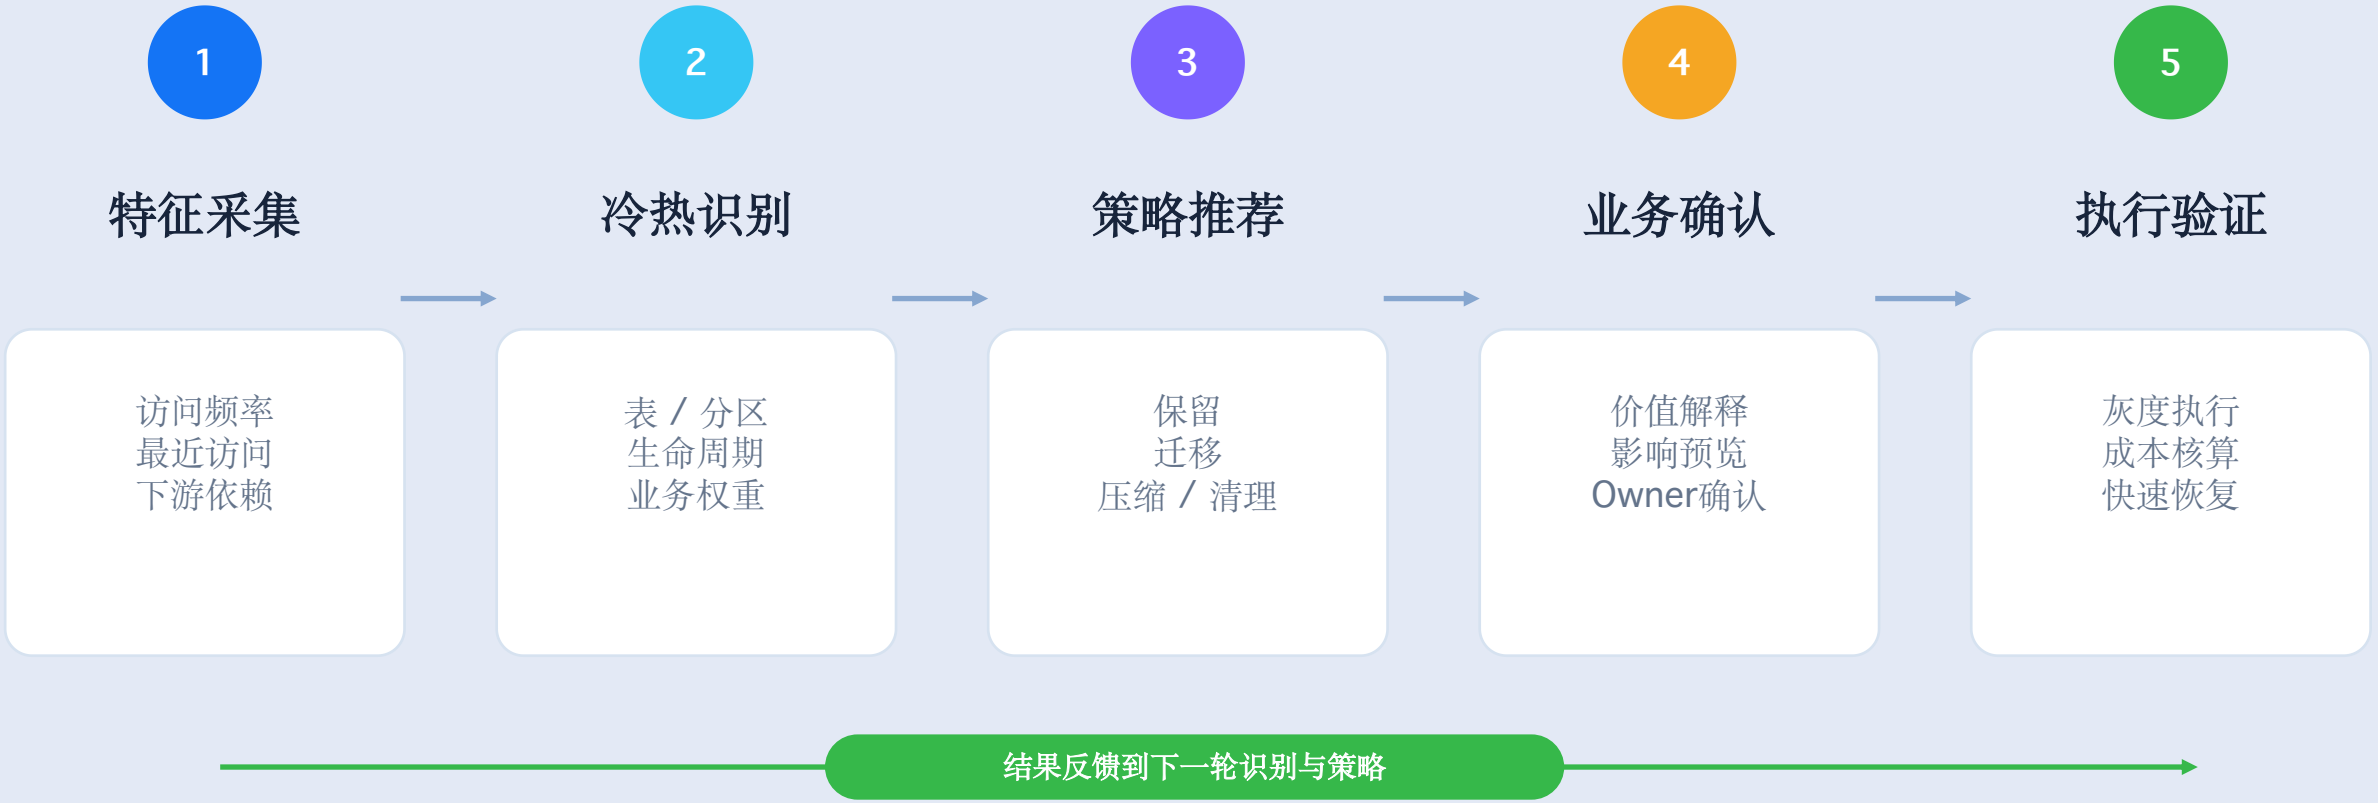
AI 如何参与存储优化决策？

存储治理的瓶颈，不只是“找出冷数据”



四步连续闭环，监控数据才会转化为真实成本下降。

Storage Insight：让建议走完治理闭环



冷热判断：访问热度 × 业务风险的二维决策



Owner、依赖关系和合规等级始终作为保护条件。

COLLABORATION

把业务方纳入闭环，才能让建议真正落地

1. **生成建议** — 平台给出价值与成本解释
2. **影响预览** — 展示依赖、空间与恢复方案
3. **Owner 确认** — 接受、延期或标记保护
4. **灰度执行** — 先迁移，保留观察窗口
5. **结果回报** — 成本变化与访问异常可见

误判补救机制

- **保守阈值** — 宁可少治理，也避免误伤
- **观察窗口** — 先标记 / 迁移，暂不删除
- **快速回热** — 访问恢复时自动回迁
- **特殊保护** — 核心链路与合规数据锁定

OUTCOME 03

结果：存储单价下降 20%

从访问日志到生命周期策略

数据使用事实决定哪些数据进入 IA、低频或归档

1. **日志采集** — 实时采集对象存储访问日志
2. **数据看板** — 数据访问情况、数据生存情况
3. **使用洞察** — 读、写、生存周期曲线
4. **AI 策略** — 配置 IA、低频、归档流转策略

策略执行与结果

AI 配置生命周期流转

IA　低频　归档

按读写热度与生存周期曲线配置

安全边界　核心链路与合规数据锁定
观察期内支持回热

20%

存储单价下降

治理前 = 100　治理后 = 80

访问日志驱动数据看板与使用洞察，AI 据此配置生命周期策略

SYNTHESIS

三个实践背后，是同一个 AISRE 引擎

场景	输入	AI 的关键判断	受控动作	结果反馈
故障自愈	告警· 日志· 指标	根因与影响面	预案执行 / 回滚	服务是否恢复
智能诊断	症状· 上下文· 案例	证据与置信度	建议 / 升级专家	诊断是否命中
存储治理	访问· 依赖· 成本	数据价值与风险	迁移 / 压缩 / 保护	成本与访问变化

共同链路：多源上下文 → 可解释判断 → 受控工具 → 结果验证 → 知识反馈

FOUNDATIONS

模型之外，决定成败的是五项工程基础

01	上下文	统一接入指标、日志、告警、变更与拓扑
02	知识	把案例、规则和预案变成可调用资产
03	工具	动作标准化、幂等化、可审计、可回滚
04	治理	权限、风险分级、审批、熔断与保护
05	评估	用真实结果衡量准确率、收益与副作用

五项基础缺一，AI 都难以安全走到“执行”。

ROADMAP

演进路径：从流程 AI 化走向 SRE 数字分身



TAKEAWAY

最后，回到标题

AISRE ≠ AI + SRE

AISRE 是让 AI 真正进入

发现、分析、决策、执行与反馈

的生产运维闭环。

关键不只在模型能力，更在于 SRE 的工程体系能否承载 AI。

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师

THANK YOU

让 AI 真正进入生产闭环

周昕毅 | 携程大数据平台

