QCon
全球软件开发大会

InfoQ 技术大会

Read, Don't Write: 重塑大模型评价体系

孙 鹏（大剩）

阿里巴巴高级技术专家



个人介绍 & 内容概述

千问智能体开放服务-业务架构负责人

过往经历：

信息流业务（推荐业务架构、ABTest ）

BoRP（Bootstrapped Regression Probing）

解决问题

传统行为指标在以LUI时代的失效问题：开放式对话的用户满意度难以规模化评估，难以支撑全量监控和敏感 A/B 测试

核心思路

摒弃了生成式的老路，而是采用读取模型隐藏状态的思路，用轻量回归器直接预测会话满意度分数

主要成果

在特定数据集的评测效果，基于4B模型可以持平 Qwen3-Max 的效果，成本大幅下降

BoRP的提出背景：LUI 时代的度量缺口

可度量是可迭代的重要前提

A/B Test 要回答策略是否有效，离不开一个好指标：

- **表征准确**：指标的变化能否真正代表用户体验的升降，能否与北极星目标保持逻辑同向
- **检测灵敏**：指标能否在统计学意义上快速检出显著差异，正向衡量改进，反向建立护栏
- **反馈及时**：从策略上线到拿到指标的周期要足够短，以配合敏捷迭代

GUI 时代 | 行为可以代理体验

- 界面交互将用户意图转化为结构化动作
- 通过结构化的动作，用户行为可以转换成为可观测的效果指标（人均点击次数、人均刷新数）
- 基于这些隐式的指标，我们可以完成用户满意度的评估

LUI 时代 | 轮次无法证明满意

Metric Gap

- 用户转向用自然语言表达需求，传统的界面行为信号减少
- 会话轮次、对话时长等指标很难说明用户是否真正得到满足
- 聊得更久，可能是用户更愿意对话也可能是问题迟迟没有得到解决，只能不断补充、纠正和重问

存量方案&BoRP的设计三原则

设计三原则

低成本高覆盖

评估成本要足够低，进而可以提升覆盖，以便支持全量监控和ABTest，同时提升检测灵敏度

高人类对齐

评分向人工对齐：模型评分贴近业务专家的判断

标准随场景定义：不同场景可以定义不同的满意度标准

底座可演进

基础模型持续迭代时，评价标准与评估体系应能平滑迁移，避免每次升级都从头建设

存量方案（截止去年底）

方案	核心问题
专用微调 Judge（如Prometheus）	需要大量高质量评估数据，构建和迁移成本高；底座升级时通常需重新准备数据并微调；作为生成式 Judge，仍需处理生成开销与输出协议问题
通用 LLM Judge	评分易受提示词与生成协议影响；存在中心化倾向、评分校准偏差等问题；逐条生成判断，推理成本高
人工评估	质量高，但成本高、吞吐有限；难以支撑大规模、持续性的全量评估与快速 A/B Test

给模型同一个评分任务，哪种输出方式效果更好？

A 先理由、后分数　　**B** 先分数、后理由　　**C** 只给分数

不同模型的评分协议实验

Model	Strategy	K-α	Pearson
Gen (Qwen3-14B)	Reason-then-Score	0.577	0.590
Gen (Qwen3-14B)	Score-then-Reason	0.587	0.612
Gen (Qwen3-14B)	**Score Only**	**0.620**	**0.623**
Gen (Qwen3-Max)	Reason-then-Score	0.690	0.710
Gen (Qwen3-Max)	**Score-then-Reason**	**0.733**	**0.737**
Gen (Qwen3-Max)	Score Only	0.697	0.698
Gen (Qwen2.5-14B)	Reason-then-Score	0.245	0.476
Gen (Qwen2.5-14B)	Score-then-Reason	0.564	0.577
Gen (Qwen2.5-14B)	**Score Only**	**0.565**	**0.582**

可以看到，生成式 Judge 的评分效果会随模型和输出协议变化。

BoRP 的思路不是寻找一套最优提示词，而是先把评分标准显式化，再从模型表征中**读取**评分。

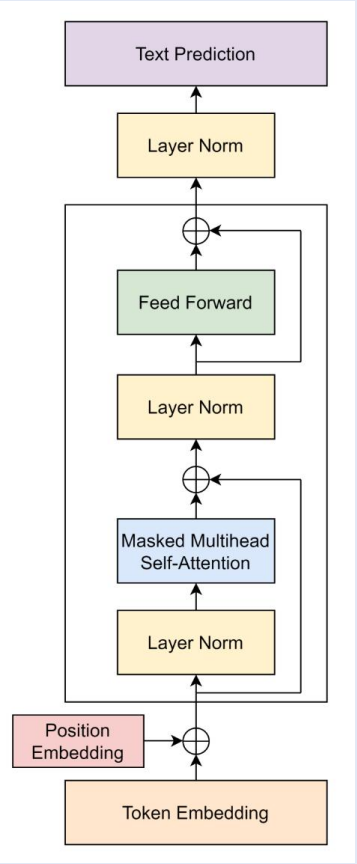
BoRP实现思路-低成本：Read, Don’t write

生成式评估的两个阶段

- Prefill：并行处理输入，形成上下文表征
- Decode：逐 token 自回归生成评语 / 分数

不生成评语，直接读取表征

- Attention： 汇聚上下文信息
- FFN： 通过非线性变换重组特征
- Residual： 保留并传递前层表征
- 隐向量 h：模型在当前上下文下形成的分布式表征



差值向量提供评价相关信号

Burns et al., *Discovering Latent Knowledge in Language Models Without Sup*

```
同一对话 + 正向提示 → h_pos ┐
                            ├→ v_diff → 后续评分
同一对话 + 负向提示 → h_neg ┘
```

- 正向提示：该对话针对Rubric的整体表现评分为：5
- 负向提升：该对话针对Rubric的整体表现评分为：1

$$\mathbf{v}_{\text{diff}}(x) = \mathbf{h}_L^{(T)}(P^{\text{pos}}) - \mathbf{h}_L^{(T)}(P^{\text{neg}})$$

其中，$\mathbf{h}_L^{(T)}$ 表示模型最后一层、最后一个 token 隐藏状态

https://towardsdatascience.com/meet-gpt-the-decoder-only-transformer-12f4a7918b36/

BoRP实现思路-高人类对齐：Rubric为媒

先定义什么是“好”，才能让评分对齐业务目标

基于Rubric：把业务标准变成明确的评分契约

Rubric | 业务标准的显式表达和沟通媒介

- 通用模型内化的偏好，不一定对齐具体业务想衡量的目标
- 不同业务场景下有不同的“好”标准：有的看准确性，有的看简洁性，有的看是否解决了用户问题
- Rubric 把评价维度、1–5 分档标准和可观察信号明确下来，作为业务标准与模型评分的对齐接口

冷启成本 | 不只是“写几条规则”

- 目标澄清： 把模糊的业务诉求转成可评价维度
- 分档定义： 说明 1–5 分的边界，避免相邻分档含义重叠
- 覆盖真实案例： 考虑线上表达、边界案例和长尾情形
- 专家校准： 让不同标注者对标准理解一致，并随业务变化维护更新

BoRP 把顺序倒过来：先从流量里找两端案例，再由案例归纳评分标准

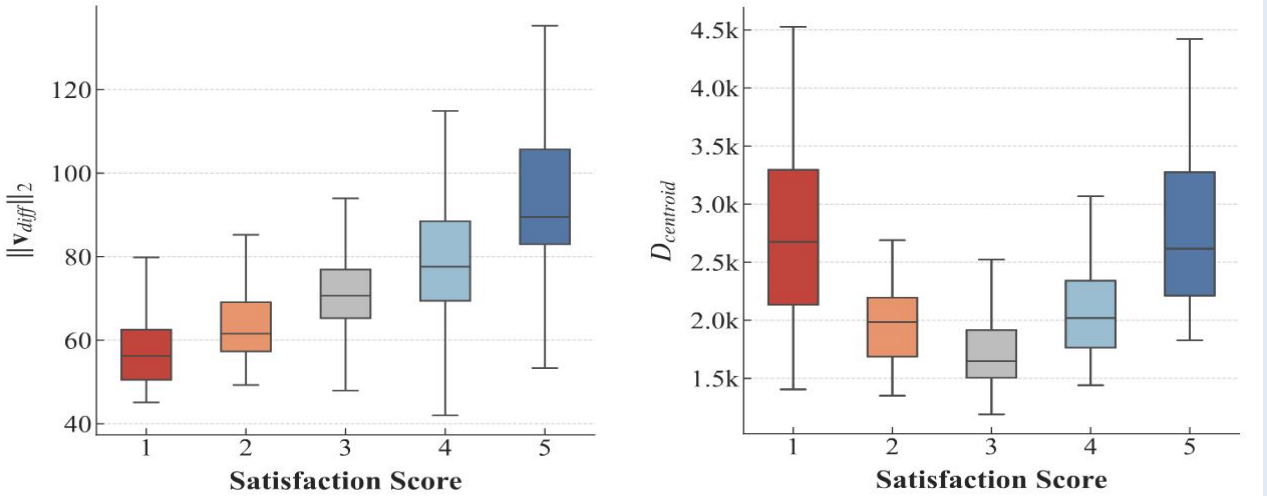
BoRP实现思路： Blind Probing

$$\mathbf{v}_{\text{diff}}(x) = \mathbf{h}_L^{(T)}(P^{\text{pos}}) - \mathbf{h}_L^{(T)}(P^{\text{neg}})$$

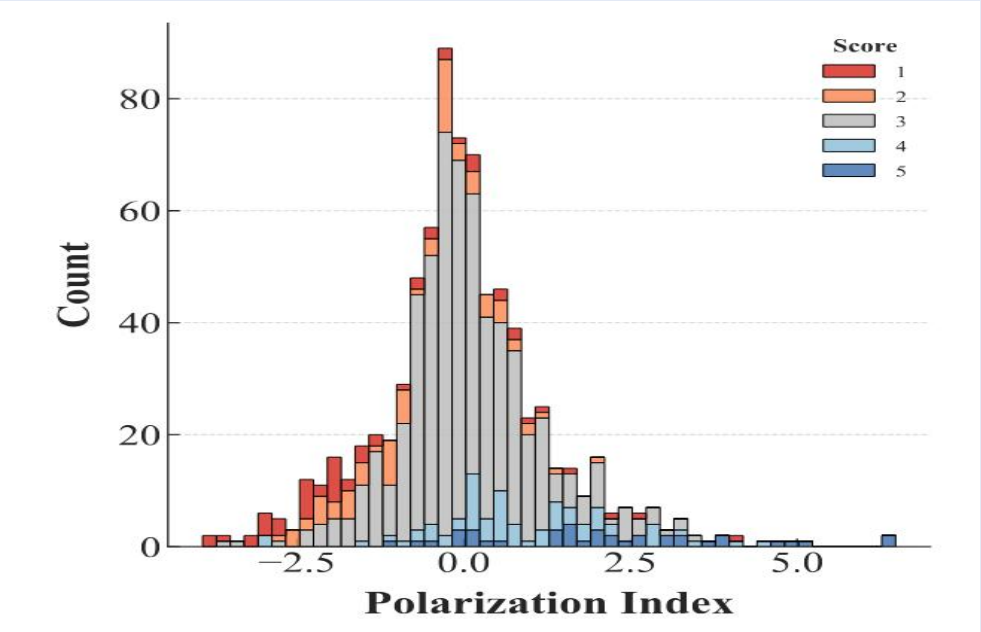
- 正向提示：该对话的整体表现很优秀
- 负向提升：该对话的整体表现很糟糕

$$\text{PI}(x) = Z(\|\mathbf{v}_{\text{diff}}(x)\|_2) \times \frac{\|\mathbf{v}_{\text{diff}}(x) - \mathbf{c}\|_1}{\mu_{\text{dist}}}$$

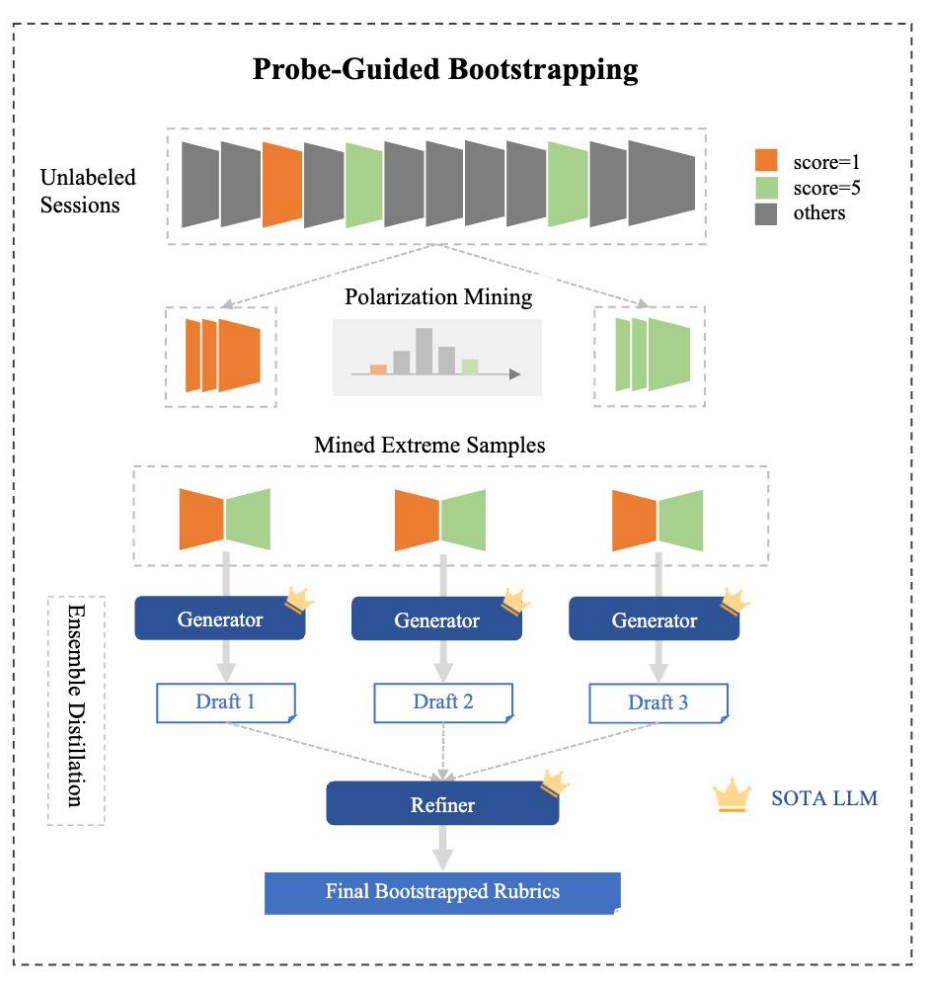
按 PI 排序，从两端挖掘高、低极化候选样本，供后续 Rubric 归纳



(a) Norm vs. Score (b) Distance vs. Score



BoRP实现思路：Rubric冷启动



Probe-Guided Bootstrapping

01 | 从无标注流量中找两端

用 Blind Probing 提取初始表征，结合 PI 挖掘高、低满意度的候选会话。PI 用于筛选候选样本，不直接给出真实分数

02 | 让案例带出评分标准

将高、低端会话提供给 Teacher LLM，让它比较两组案例，归纳评分维度与 1–5 分档标准，并生成多个 Rubric 草案

03 | 融合草案，形成可校准的 Rubric

融合多个草案的共性、抽象具体场景特征，再由业务人员补充领域逻辑，形成最终评分标准

BoRP实现思路：基于Rubric评分

Geometry-Aware Probing Engine

01 | Rubric 约束下提取对比表征

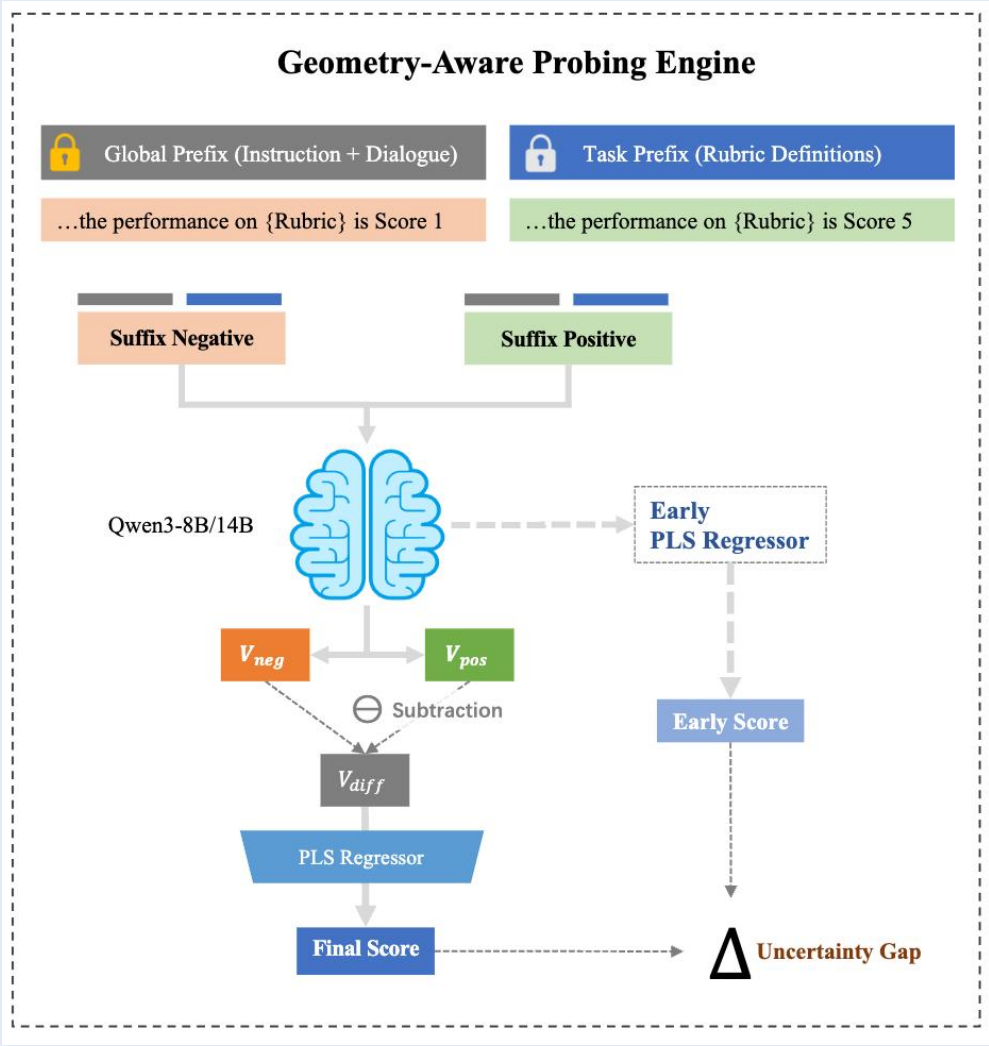
将同一段对话分别接上 1 分与 5 分评分提示，提取模型隐藏状态并做差，得到该会话的评分方向表征

02 | 用专家评分校准标准

专家依据 Rubric 对约 700 条会话进行 1–5 分标注，作为唯一监督信号；标注者间一致性达到 k-α > 0.90

03 | 用 PLS 学习评分映射

对训练数据进行逆密度采样，降低中间分数密集区的影响、补足分布尾部；再用 PLS 回归学习隐藏表征与人工评分之间的关系，输出校准后的 1–5 分



BoRP实现思路：高性能低成本

01 | 不生成，只读隐藏状态

直接从模型隐藏状态提取评分信号，省去逐 token 生成评语或分数的解码开销

02 | 共享前缀，避免重复计算

多个 Rubric 共用同一段对话上下文；利用 KV Cache 复用前缀计算，只处理各自不同的提示后缀



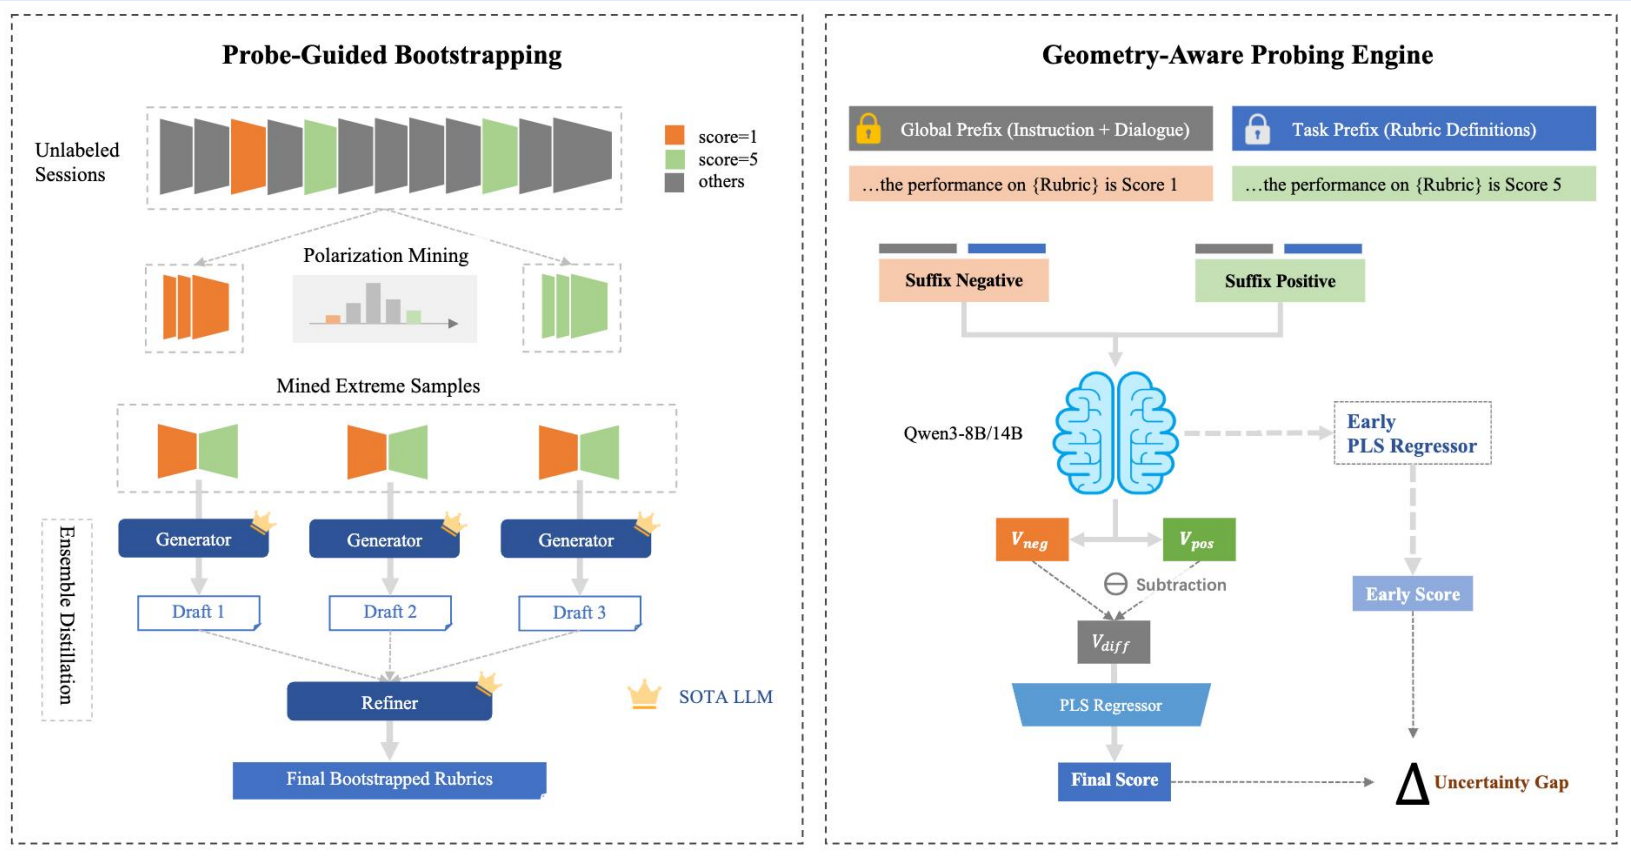
03 | 压缩长对话，降低预填成本

对长会话按意图切分，并采用 middle-out 压缩保留对话头尾和目标回答；论文报告预填充成本降低约 64%

04 | 按模型规模选择部署精度

结合模型规模与显存、吞吐需求部署：论文采用 >10B 模型 AWQ-Int4、<10B 模型 BF16 的混合策略

BoRP实现思路：总结



未标注对话 → 通用提示提取对比向量 → 用 PI 挖掘高低极端样本 → 教师模型归纳 rubric → 专家按 rubric 标注约 700 个样本 → 用详细提示提取表示并做逆密度采>样 → PLS 回归预测 1–5 分 → 用中间层与末层分歧筛出高风险样本 → 通过共享前缀缓存和压缩部署到全量流量

BoRP实际效果：如何衡量

$K-\alpha$ 高：模型评分与人工评分在分数等级上更一致

$$\alpha = 1 - \frac{D_o}{D_e}$$

D_o：评估者之间实际观察到的分歧；

D_e：假设评分随机分配时预期出现的分歧；

针对 1–5 分这类有序评分，分差越大，分歧惩罚越重

$Pearson$ 高：模型能跟上人工评分的趋势；但不保证分数本身一致

$$r = \frac{\mathrm{Cov}\left(S_{\mathrm{model}}, S_{\mathrm{human}}\right)}{\sigma_{\mathrm{model}}\sigma_{\mathrm{human}}}$$

$\mathrm{Cov}\left(S_{\mathrm{model}}, S_{\mathrm{human}}\right)$：模型评分与人工评分的协方差

$\sigma_{\mathrm{model}}\sigma_{\mathrm{human}}$：两组评分各自的标准差

结果组合	可以说明什么
K-α 高，Pearson 高	分数等级较一致，整体趋势也对齐
Pearson 高，K-α 低	趋势同向，但分数可能存在系统性偏移、尺度不匹配或档位判断差异
K-α 高，Pearson 低	分档一致性尚可，但整体线性变化关系较弱

BoRP实际效果：BoRP对生成式 Judge 的超越

模型 / 方法分类	评测方法	K-α(一致性)	Pearson (趋势)
专用微调 Judge	M-Prometheus（Qwen2.5-14B）	0.49	0.53
通用生成式 Judge	Gen (Qwen3-14B)	0.62	0.62
	Gen (Qwen3-Max)	0.73	0.74
判别式探针 (Ours)	BoRP（Qwen3-4B）	0.73	0.73
	BoRP（Qwen2.5-14B）	0.69	0.70
	BoRP（Qwen3-14B）	0.80	0.81

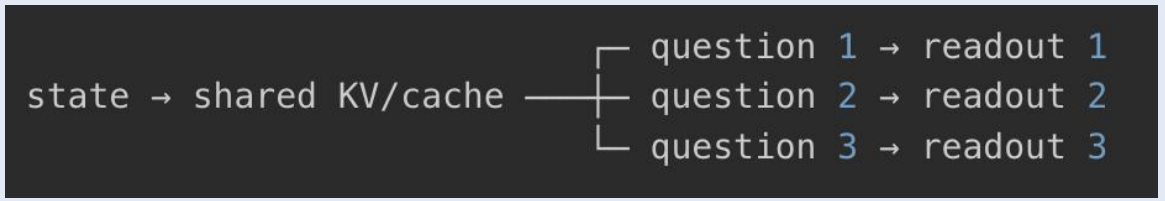
方法	吞吐量（会话/小时）	每 10 万会话成本	相对成本
Qwen3-Max（API）	—	$124	100%
Gen（14B）	7,300	$28	22.6%
M-Prometheus（14B）	6,200	$34	27.4%
BoRP（8B）	57,800	$4	3.2%

- 同底座对照，BoRP全面超越生成式和专用微调模型（黄色+绿色）
- BoRP仅用4B的小模型，就可以复刻Qwen3-Max的效果
- BoRP(Qwen3-14B)取得全场最佳，从绝对值来看具备很高的人类对齐
- 底座可演进的优势可以持续追踪模型升级带来的红利，BoRP由Qwen2.5-14B升级成Qwen3-14B以后，效果取得了显著的提升

BoRP实际效果：与Jev的效果比较

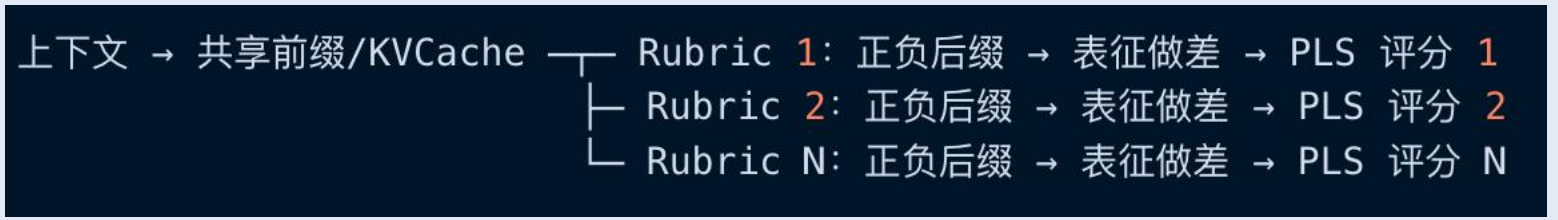
模型 / 设置	评分方式	K-α（一致性）	Pearson（趋势）
BoRP（Qwen3-14B）		0.80	0.81
Jev + Rubric	连续分	0.70	0.75
Jev + Rubric	整数分	0.64	0.68
Jev w/o Rubric	连续分	0.52	0.59
BoRP（Qwen3-4B）		0.73	0.72
Kev-4B	连续分	0.52	0.74

- BoRP（14B）的评测效果要优于Jev，但由于不确定Jev的参数规模，所以比较并不公平
- 单纯看Jev，连续分要比整数分要好，带Rubric要比不带Rubric效果好，证明了Rubric在对齐过程中发挥的作用
- BoRP（4B）与开源的Kev（4B）进行比较，Kev对于趋势的追踪要比BoRP略好，但是一致性水位较低



< --- Jev

BoRP --- >



BoRP实际效果：消融分析

	实验设置	K-α(一致性)	Pearson (趋势)
(a) 训练策略消融 (Based on Industrial Dataset)	BoRP (Full)	**0.80**	**0.81**
	-移除几何重采样	0.62	0.69
	-用无监督PCA替代有监督PLS	0.55	0.58
(b) Rubric 来源对比 (Based on HelpSteer2)	Gen (Max) + 原始人工标准	0.15	0.62
	Gen (Max) + AI 自举标准	0.22	0.66
	BoRP (14B) + 原始人工标准	0.70	0.70
	BoRP (14B) + AI 自举标准	0.67	0.67

- 几何重采样不可或缺：若直接在真实长尾偏置分布上训练，K-α 从 0.80 骤降至 0.62
- 有监督 PLS 远胜无监督 PCA：用 PCA 替代 PLS 会进一步跌至 0.55
- 自举 Rubric 具备极高可用性：BoRP 在 AI 自动生成的 Rubric 下取得 0.67，逼近人工专家编写的 0.70，验证了无标注流量冷启的可行性
- 对生成式亦有正向增益：自举 Rubric 让 Gen (Qwen3-Max) 的 K-α 从 0.15 提升至 0.22

BoRP实际效果：消融分析

无监督的盲区（PCA = 0.55）

- 语言模型隐藏层中，方差最大的方向往往是“讨论的话题是什么”，而不是“用户满不满意”。
- 纯无监督方法抓到的往往是“领域噪音”，导致 K-α 崩塌至 0.55

极小代价的高回报（PLS = 0.80）

- 仅用几百条专家样本提供的监督信号，是提升人类对齐度的高性价比手段
- 同时少量的监督样本，是消除主观业务评估歧义的重要手段

Qwen3-14B：P-Tuning v2 实验结果

设置	拼接 Token 数	K-α
生成式 Judge（对照组）	0	0.620
P-Tuning v2	1	0.696
P-Tuning v2	5	0.712

微调确实有效

- 通过 P-Tuning注入Prefix Token，K-α从0.62升至 0.71
- 证明模型内部确实有这种判别倾向，只是需要被激发

为什么依然选择 BoRP

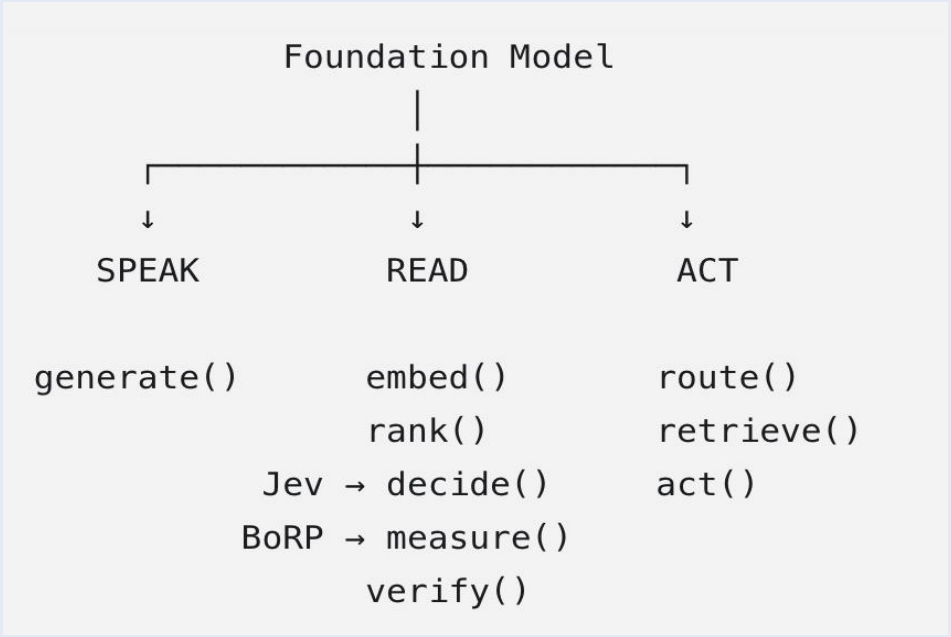
- 上限差异：即使做了参数级对齐，生成式依然难以匹敌
- 推理硬伤：P-Tuning 改变的是前缀表征，但依然需要 Decoding，无法享受吞吐红利

BoRP Limitations & Discussion

Limitations

- 模态范围有限： 当前仅面向文本对话，尚未覆盖语音等包含声学信息的场景
- 复杂推理能力受限： 依赖基座模型隐状态；若复杂推理信息未充分编码，线性探针可能难以恢复
- 对话结构敏感： 单轮、缺少用户反馈，或频繁话题切换的长尾会话，可能降低评估效果
- 部署依赖模型访问权限： 需要读取基座模型隐状态，不适用于纯黑盒 API 场景

Beyond generate(): Rethinking the Foundation Model API



参考资料

BoRP (本文方法)
Sun et al., BoRP: Bootstrapped Regression Probing for Scalable and Human-Aligned LLM Evaluation

Jev (决策式裁判模型)
Deußer et al., Evaluating and Benchmarking the System One Model Jev
Evaluating and Benchmarking the System One Model Jev
文档参考：TypeSafe AI Jev Documentation — Introduction - TypeSafe

Prometheus (专用微调裁判基准)
Kim et al., Prometheus: Inducing Fine-grained Evaluation Capability in Language Models (ICLR 2024)

M-Prometheus (多语言专用裁判模型)
Pombal et al., M-Prometheus: A Suite of Open Multilingual LLM Judges (COLM 2025)

P-Tuning v2 (深度提示微调方法)
Liu et al., P-Tuning v2: Prompt Tuning Can Be Comparable to Fine-tuning Universally Across Scales and Tasks (ACL 2022)

Kev
https://github.com/jaredpalmer/kev

千问内推请联系我
备注“QCon”

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The Software

