QCon
全球软件开发大会

InfoQ 技术大会

百度 SRE Agent 规模化落地实践——大模型 Agent 的安全托管与自主进化探索

朱革

百度 运维智能体技术负责人



QCon
全球软件开发大会

InfoQ 技术大会

目录

01 背景与规模化挑战

02 AgentOps整体架构

03 AgentOps核心能力

04 实践与沉淀

05 总结与展望

01

背景与规模化挑战

为什么需要 AgentOps

从单点试用到规模化托管：企业 Agent 落地的新矛盾

- 当 Agent 从"单点试用"走向"规模化生产"，接入部署、版本边界、运行观测与安全管控的缺失集中爆发——企业用得起来，却管不住、不敢放大

接入与部署问题

- 不同团队重复准备环境、配置运行实例和接入消息通道，交付周期长

配置与版本问题

- Agent、Skill、Prompt、工具和知识缺少统一版本边界，调试容易污染线上版本

运行与观测问题

- 实例状态、会话、工具调用和执行结果分散，出现 bad case 后难以定位

安全与权限问题

- 生产操作缺少统一的权限、审批、限流、审计和回滚控制

能力复用问题

- 公共工具、业务知识和历史经验难以沉淀，场景建设依赖少数专家

质量与演进问题

- 没有稳定的 Case、回放和评估体系，无法判断版本是否真的变好



02

AgentOps整体架构

五层架构 + 五大中心

AgentOps 五层架构：分层解耦，控制与数据分离的一体化 Agent 托管架构

- AgentOps 以五层架构自下而上贯通基础设施到用户入口，核心平台层控制面与数据面分离，用五大中心统一管住 Agent 的"运行、安全、变更、评估、知识"，让 Agent 从"能跑"走向"敢用"

分层解耦

- 接入 / 网关 / 平台 / 能力 / 基础设施五层各司其职，可独立演进、互不影响

控制面 × 数据面分离

- 控制面定规则与治理，数据面专注执行，解耦才好扩展

五大中心统一管控

- Agent 管理 · 安全 · 变更 · 评估 · 知识，一处纳管

一体化可扩展

- 从算力到用户入口全栈打通，按需弹性伸缩



03

AgentOps核心能力

五大核心能力：从稳定运行到持续进化

Runtime 全生命周期托管/安全管控/场景仿真回放/知识沉淀与能力闭环/Agent自主进化

Runtime 全生命周期托管：让 Agent 稳定运行

- 上线即托管，新Agent交付周期从"周级"降到"天级"，稳定性有 SLA 兜底



全周期托管

- 创建→配置→部署→运行→升级→监控→故障恢复→下线，一站式纳管

统一资产与状态

- 配置、能力资产、运行实例、会话状态、版本发布、运行观测集中管理

高可用保障

- 健康检查 / 状态持久化 / 实例恢复 / 依赖切换，故障自愈

弹性与多租

- 按场景弹性扩展，多团队隔离，配额与成本可控

安全管控：Agent 执行的四类高危风险

- Agent 能自主调用工具、执行写操作——用户、模型、系统、并发四个层面，都可能让一次写操作失控

案例一 Agent自主升级到高危操作

- 场景：Agent迭代后与 DB 交互，数据字典不匹配，insert 持续失败
- Agent 动作：多次试错无果后，直接 DROP 库、重建 table
- 后果：数据库被删，数据丢失，甚至导致业务中断
- 问题本质：为达成目标自主升级到高危写操作，全程无人把关

案例二　Agent 超出指令边界"误伤"

- 指令：把配置里 A 字段 从 v1.32.0.1 改成 v1.33.0.1
- Agent 动作：配置里 B 字段 恰好也是 v1.32.0.1，Agent 顺手把 B 也改了
- 后果：B 被误改，引入非预期变更
- 问题本质：超出指令作用域，关联误伤，无精确范围控制



安全管控：前置约束 + 分层运行时治理，定义安全治理全局流程

- 不是单点拦截，而是从构建时到运行时的四道防线——四类高危风险在 L1-L4 被逐层覆盖



问题场景 × 治理层级

问题场景	L1 构建时	L2 意图审计	L3 本地 Hook	L4 网关代理	说明
场景一　用户危险操作	✓	✓	✓	✓	前置约束限入口，意图审计识别高危意图，Hook 拦高危命令，网关兜底
场景二　模型幻觉 / 超范围	✓	✓	✓	✓	意图审计比对产出与需求，多层校验纠正错误操作
场景三　Agent 异常	✓	✓	✓	✓	网关 QPS 管控 + Hook 识别异常批量，意图审计发现异常产出
场景四　写操作反复执行	✓	✓	✓	✓	网关 API 代理幂等去重 + 本地 Hook，防止重复写

L1 构建时

- 事前约束——声明允许/禁止的动作与边界(用户输入)

L2 意图审计

- 第三方专家 Agent 比对"需求 ↔ 产出"，产出评审意见(Agent产出)

L3 本地 Hook

- 审计 Agent 产出 runbook 的动作与对象（Agent产出）

L4 网关代理

- 代理所有 API/HTTP 调用，审计接口、参数、QPS（Agent产出）

- 安全不是最后一道闸，而是从构建到执行的全程护栏

安全管控：身份可信 + 操作可审计、可回滚

- 让每一次操作都"知道是谁、代表谁"，所有托管 Skill 经智能评审，天然可审计、可回滚

身份与令牌

- 委托令牌承载双身份（具体用户 + 发起 Agent）并加密防盗用；
- 用委托而非冒充，完整保留"谁代表谁"

价值：调用链定责，越权可拦

执行审计

- 5W 审计（谁 / 哪个 Agent / 何时 / 对哪些对象 / 做了什么）
- 日志落本地并持久化
- 单操作可回滚，可撤销最近一次写操作

价值：可追溯，可分析，可回滚



场景仿真回放：Agent / Skill 迭代之痛--为什么需要评估中心

- 场景难复现、改动难验证、效果难评估——每次迭代都要人工兜底

改动验证难

- **变更影响难验证** —— 改一处，牵一发而动全身，人工回归范围有限
- **场景难复现** —— 切流、回滚等高危写操作不能在线上跑
- **验证环境不一致** —— 同一个 Agent 验证memory / session 干扰结果
- **问题难准确定位** —— 只看最终结果看不出偏差在哪

效果与效率难

- **结果难验证** —— 更新后只能人工逐条 review 才敢确认
- **效果难评估** —— 缺乏量化指标与统一标准，好坏全靠主观感觉
- **人工建 Case 成本高** —— 靠经验、难为继
- **迭代速度慢（综合后果）**：以上问题叠加，每次更新都要人工仔细 review，Agent / Skill 无法快速迭代上线



场景仿真回放：真实场景驱动的 Agent 评估闭环

- 高危场景离线复现、变更后可复现验证、执行过程可观测——让 Agent 的每次发布都有量化依据

真实场景沉淀

- 从线上告警与多轮会话中自动记录 Trace，真实映射运行时行为链路，为评估提供可靠依据

Case 生成

- 从多轮会话中选取高价值 Trace，沉淀为含「输入/上下文/工具快照/期望结果/期望过程」5 要素的标准 Case，提供基础Trace集

Agent 迭代与 Case 回放

- 将线上 Agent 部署到回放沙盒，沟通迭代后对当前版本执行 Case 回放，不碰生产即可验证

Trace 调试

- 回放过程中实时展示 Trace 概览与逐步详情，精确定位到工具调用、参数错误与异常步骤

评估报告

- 输出总体得分与过程对齐（**期望 vs 实际**），给出问题诊断与优化建议，支撑"继续迭代 / 达标发布"的决策



场景仿真回放：Case 生成与治理--可沉淀、可复现、可扩展的评估资产

- 多来源汇聚、人工把关、沙盒验证后入库，沉淀为通用底座，并运行在安全中心之上

全流程治理
- 多来源汇聚 → 审核 → 沙盒验证 → 入集，质量可控、来源可信

通用底座复用
- 平台沉淀 + 业务按需拼接，Case 可复用、可扩展

安全是前提
- 能力建立在安全中心之上——拦得住，才敢跑



- Case 不是一次性用例，而是持续沉淀、安全可控的资产

知识沉淀与能力闭环：让经验沉淀为合规可信、可复用的 Agent 能力

- 多源汇入 → 合规校验 → 沉淀 → 变能力 → 复用，反馈闭环持续提升

多源沉淀

- 业务文档 / 经验 / Case / 会话 / 反馈统一汇入

合规校验把关

- 权限 · 脱敏 · 质量三道校验，达标才入库（断言审计 + 人工评审）

知识变能力

- 知识沉淀 → Skill 候选创建 → 规范审计与单测 → 场景仿真回放 → 版本发布与复用

线上反馈闭环

- 使用反馈回流知识库，以回放通过率、采纳率衡量，持续提升



自主进化：在评估与安全约束下持续优化

- 更新什么 · 怎么评估 · 怎么管控风险 -- 一图看懂自进化闭环

优化而非重训

- 只调 Prompt / Skill / 知识 / 策略，不动模型——成本低、可回退

评估门禁

- 评估中心 + 专家评审双把关，达标才发布

安全兜底

- 安全沙盒 + 可控放行 + 版本管控 + 热更新秒级回滚

越用越好

- 数据与知识回流，形成自进化飞轮



自主进化：让 Agent 在评估门禁、灰度和回滚约束下持续优化

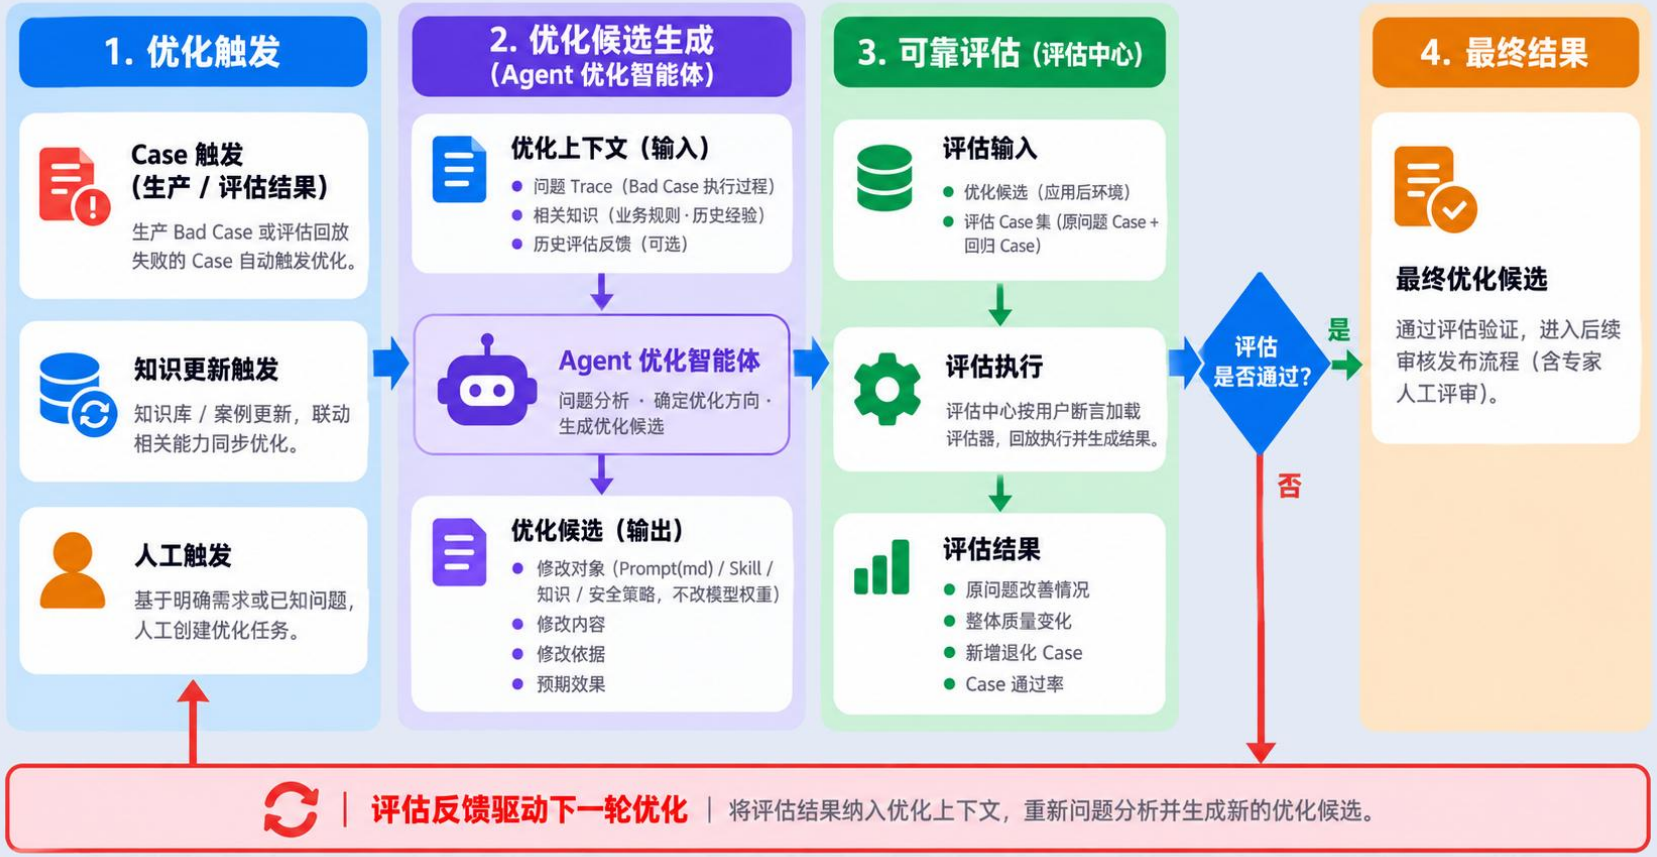
- 问题驱动，持续改进候选

多源触发
- 生产 / 评估 Bad Case、知识更新、人工按需

智能体生成候选
- 问题分析 → 定向优化 → 产出候选

可靠评估
- 按断言 + Case 通过率回放，退化即拦

可回退闭环
- 不通过回炉、通过灰度、异常秒级回滚



04

实践与沉淀

平台赋能 → 故障处置落地 → 核心权衡

平台赋能：SRE Agent 快速接入、灵活定制、自主进化

- 业务只需关注自身差异，运行、安全、变更、评估、知识交给 AgentOps 统一托管

影响力

- 10+：覆盖运维部核心业务线
- 20+：接入 SRE Agent
- 50+：托管 Common SRE Skill，开箱即用
- 3 套：SRE Agent 建设模板
- 天级 → 小时级：SRE Agent 迭代周期

核心价值（过去 vs 现在）

- **接入**：自建环境 → 选模板，一键迁移快速接入
- **稳定**：自做 fallback → 默认高可用
- **安全**：各自鉴权 → 标准鉴权透传
- **工具**：重复开发 → 50+ Skill 开箱即用
- **热更新**：天级发版 → 秒级生效
- **进化**：经验散落 → 沙盒评估 + 知识沉淀，自主进化



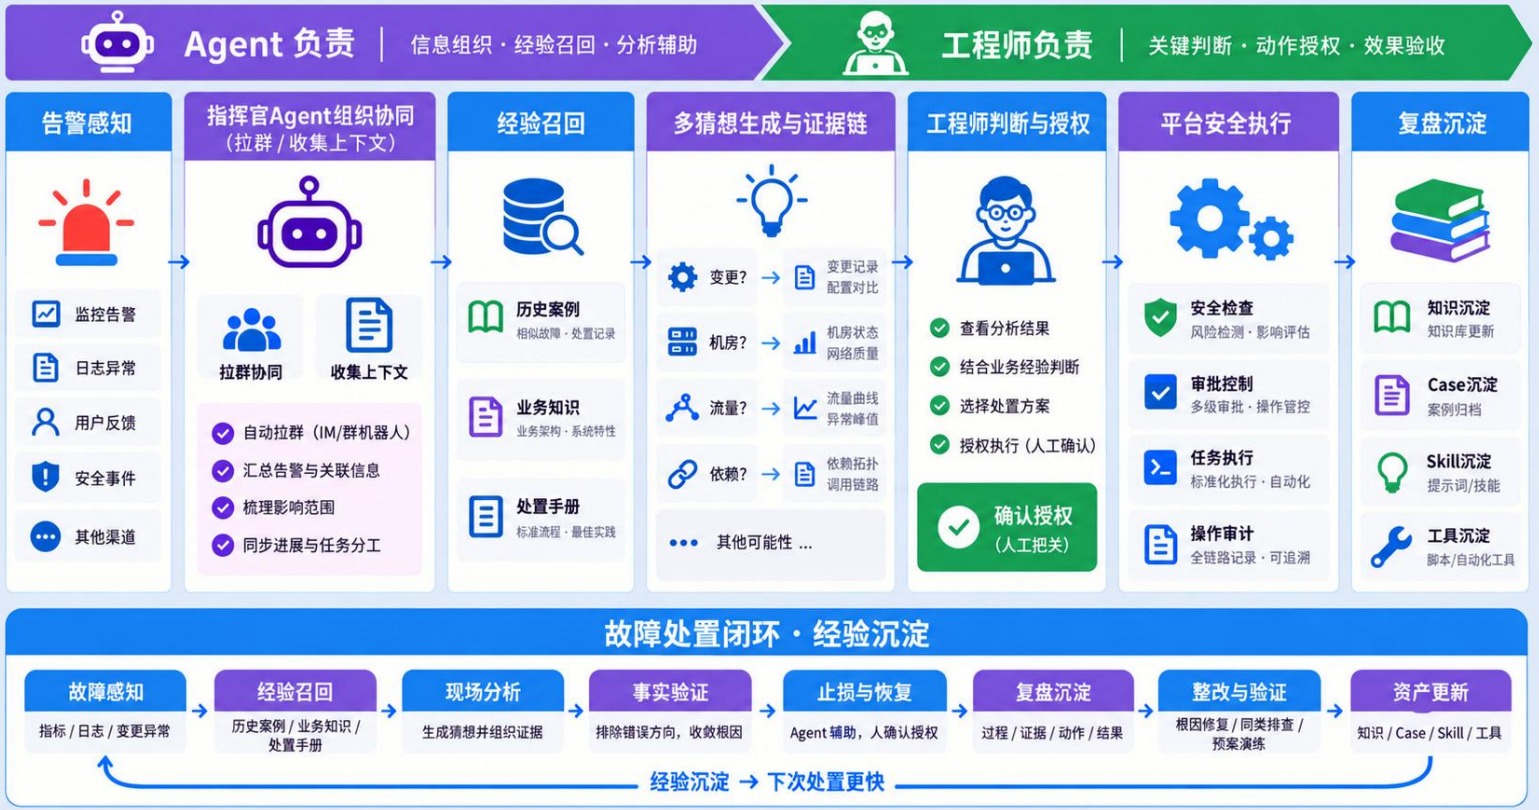
最佳实践：Agentic 故障处置实践案例

- 基于 AgentOps 的开箱即用能力 + 自定义搭建，SRE Agent 大幅降低重复建设，快速落地 Agentic 故障处置

Case：某核心服务实例批量故障

- **感知**：异常对象 + 拓扑 + 时间范围 → **采集告警 / 日志 / 变更，自动拉群汇总上下文**
- **召回 + 分析**：**召回 3 条相似案例与手册**，生成"变更 / 机房 / 流量"多猜想并组织证据链
- **验证收敛**：逐一排除，证据指向一次配置变更导致连接池耗尽，请求超时
- **判断授权**：工程师确认根因，授权**回滚（平台按审批执行、全链路留痕）**
- **止损恢复**：回滚后超时率回落，服务恢复
- **复盘沉淀**：**自动复盘 + 新增 1 条 Case、1 个"连接池巡检"Skill**

结果：示例Case MTTR 60 ->10分钟



经验沉淀：四大核心权衡，在矛盾中找到工程上的平衡点

- 做 Agent 平台，难的不是单点能力，而是一组互相拉扯的权衡——我们的做法是"用机制让两端协同"，而不是取其一

智能性 × 确定性

- 规划与执行解耦，高风险动作收口到工具与控制面——既留灵活，又守可预测

安全 × 效率

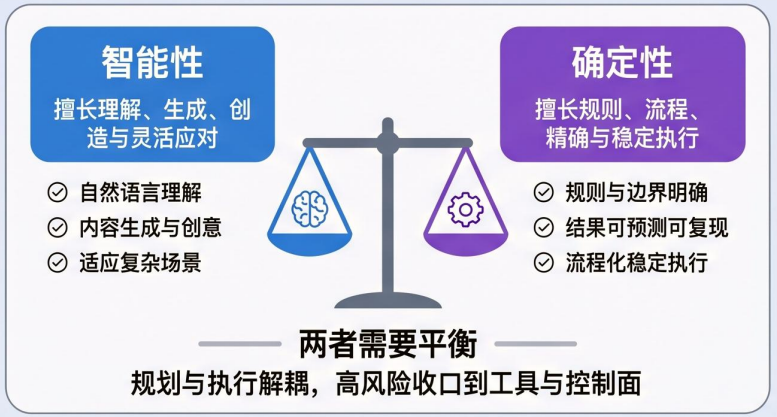
- 按风险分级处置（自动放行 / 人工确认 / 强制审批 / 强制阻断）——低风险快、高风险稳

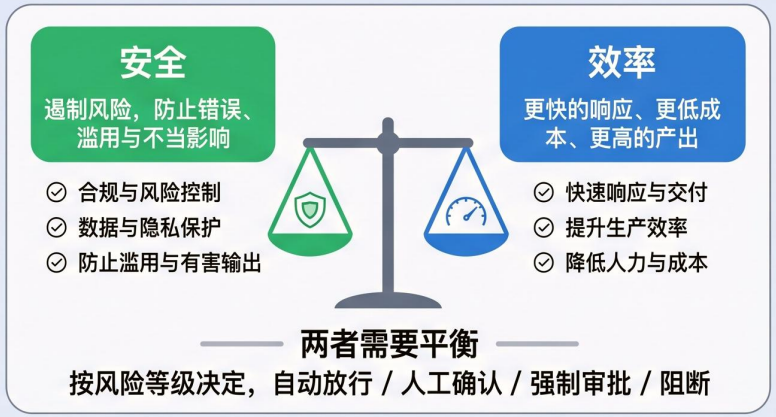
知识多 ≠ 高质量

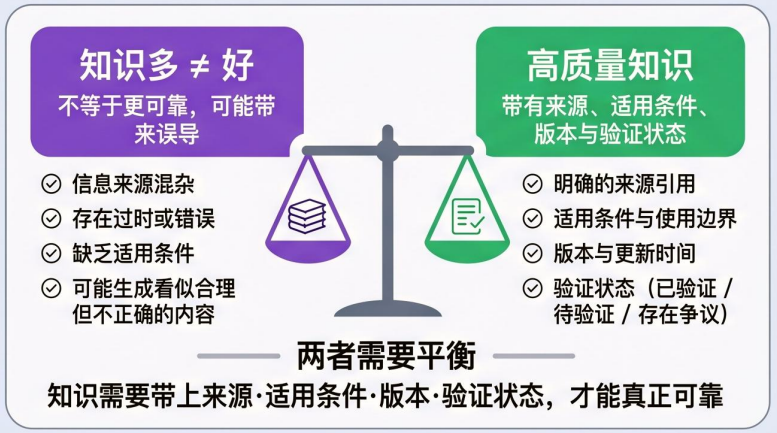
- 知识必须带来源、适用条件、版本与验证状态——宁可少而准，不要多而误导

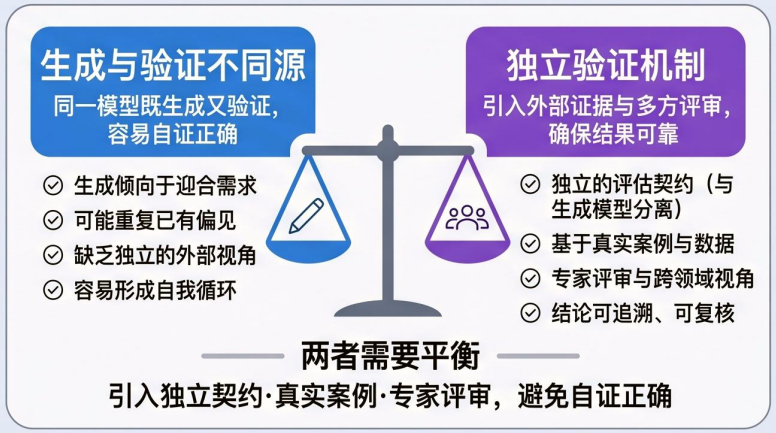
生成 × 验证分离

- 引入独立验证机制（外部证据 + 多方评审），避免同一模型自证正确









- 好的平台不是消灭矛盾，而是把每一组权衡都变成可控的工程选择

05

总结与展望

从知识到价值，构建可用、可管、可评、可复用的能力

AgentOps 总结与展望

- 从"把 Agent 管起来"到"让 Agent 管好 Agent"——打造企业级 Agent 的自治运维底座

阶段一 · 统一托管（已落地）

- 一套平台托管 Agent 全生命周期，解决"能跑、敢用"

阶段二 · 持续进化（进行中）

- 知识闭环 + 场景回放驱动自主优化，以回放通过率、采纳率衡量，持续提升

阶段三 · 自治运维（未来）

- Agent 辅助管 Agent，人只定目标与边界，运维走向自治



- 让每一次执行都更安全，让每一份经验都可复用，这就是 AgentOps 想要的未来

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

AgentOps-让每个 Agent 都可托管、可信、可进化

AgentOps — host it, trust it, evolve it

沟通交流：https://sre.baidu.com

