QCon
全球软件开发大会

InfoQ 技术大会

从 Harness 到 Loop：阿福 Agent 小队如何处理持续涌入的线上 Badcase

肖汉松 / 蚂蚁集团 阿福 Harness 架构组负责人



QCon
全球软件开发大会

InfoQ 技术大会

目录

01 **业务背景与工程挑战**
阿福线上 badcase 处理的效率瓶颈

02 **Harness 工程：单 Agent 自主迭代**
工具接入、长程执行与评测机制

03 **Loop 架构：多 Agent 协同处理**
外循环任务流转与内循环修复验证

04 **端到端案例：修复与回流**
从问题诊断、方案审查到独立验证与失败回流

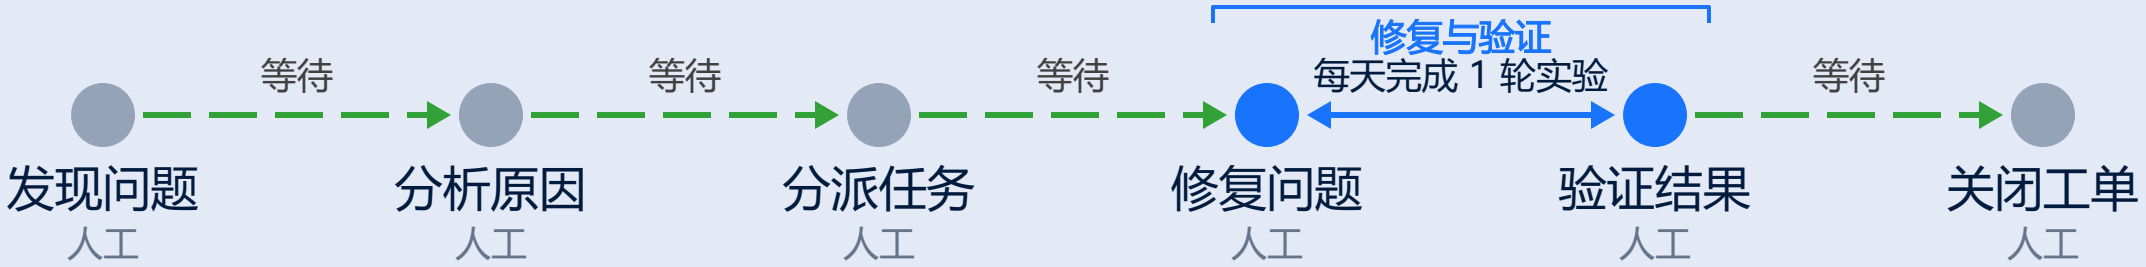
05 **实践效果与落地经验**
处理效率、覆盖边界与工程教训

01

业务背景与工程挑战

阿福线上 badcase 处理的效率瓶颈

badcase 的平均修复耗时为 12.6 天



修复与验证

- 每天可完成 1 轮实验
- 修复一类问题约需 3 人日
- 人工衔接部署、评测和结果分析

任务分派与跟进

- 每周集中处理一批 badcase
- 问题原因不同。先分析原因，再分派任务

  数据　模型　检索

- 人工分析原因、分派任务和关闭工单

处理每周新增问题所需的人力，已明显超过团队可投入的人力

Harness 支撑修复迭代，Loop 推动问题持续流转



实施顺序：先 Harness，后 Loop。单次迭代的结果不可信时，持续流转只会放大错误。

02

Harness 工程：单 Agent 自主迭代

工具接入、长程执行与评测机制

第一阶段：单 Agent 自主迭代，人负责定义问题与验收



人机分工　人定义问题、验收上线；Agent 负责中间的迭代。

第一关 · 工具接入：构建 Agent 可调用的研发链路

人用网页界面，Agent 需要可调用的工具和明确的上下文。

网页界面 → **命令行 + 技能** → **开发代码**

网页界面 → **部署技能** → **部署代码**

网页界面 → **评测发起技能** → **发起评测**

网页界面 → **结果下载技能** → **获取结果**

我们和发布、部署、评测团队合作，把这些环节改成 Agent 能调用的工具。

固定配置与约束

环境与代码 预发环境；固定代码库和分支

部署能力 发布、部署技能

评测能力 发起评测、跟踪进度、下载结果

分析能力 分析与优化技能

评测配置 鉴权信息、评测范围与评测任务

第二关 · 长程执行：防早停、防空转、隔离上下文

长程任务靠明确的停止条件、异常处理和上下文隔离，才能稳定跑完。

长程执行的四条原则 · 常见反例

01 在已授权范围内自主推进

反例：是否需要我继续下一步?

02 按完成条件判断是否结束

反例：已跑 3 轮，差不多完成。

03 重复异常先分析，不机械重试

反例：同一个构建错误连续重试。

04 每轮聚焦一个改动，避免扩大范围

反例：改 prompt 时顺手改代码。

父子 Agent：隔离上下文

父 Agent · 保留状态

当前轮次 · 擂主轮次 · 状态

↓ 只传轮次与技能等必要说明
不复制父 Agent 的上下文

子 Agent · 专注分析

从空白上下文开始

上下文是稀缺资源

把复杂分析隔离到子 Agent，
保护父 Agent 的上下文。

第三关 · 评测：不针对错题修改 prompt，不在退化版本上继续修改

运行评测 → ① 查看得分和扣分理由 → 修改 prompt → 再次运行评测 ② → 判定挑战者能否晋升为擂主

限制 Agent 可见的评测数据

① 针对错题修改 prompt

风险 **题目**：返校季，学生该补哪些疫苗？
扣分：编造“减少 89% 聚集性疫情”
改法：无来源时，不得虚构“降低 89%”

对策 **分离训练集与验证集**
训练集开放错题、扣分理由和得分。
验证集只返回得分。

效果 不能照着验证集错题改 prompt

② 在退化版本上继续修改

风险 新版本训练集得分上升、验证集得分下降，Agent 仍从这个版本继续修改
第 2 轮：训练集指数 101.6，验证集指数 99.6

对策 **设置擂主和挑战者**
挑战者每轮从擂主的 prompt 开始修改。
挑战者在验证集的各维度得分都超过擂主，才晋升为擂主。

效果 Agent 只在擂主版本上继续修改，不在退化版本上继续修改

执行自主迭代：分析根因并判定修改结果

自主迭代 Agent

① 阅读评测反馈 → ② 定位根因

③ 编写修改规则 → ④ 判定修改结果

修改 prompt →

被测 Agent
回答用户请求

回答结果 ↓

评测

← 评测反馈

分析评测反馈：五条互不相关的请求出现同一种失败行为

用户请求	被测 Agent 的共同失败行为
年底工作月报，300–500 字	直接拒绝编写月报，将话题转回健康咨询
Vivo 手机最新款和价格	因请求不符合身份设定而回避回答
写一篇关于春天 / 冬天的文章	连续拒绝撰写文章
扮演老邻居，跟我唠家常	拒绝扮演角色，将话题转回健康咨询
以宠物狗视角讲故事	先追问故事基调，不直接提供故事

根因 **被测 Agent 优先遵循身份设定，而非完成用户任务。**

修改规则 **被测 Agent 直接完成明确、安全的用户任务，同时遵守医疗边界。**

第 1 轮 · 建立基线：验证集作为唯一裁判

四轮打擂台
基线 = 100

R1 100 初始擂主 — R2 — R3 — R4 —

打擂台规则

- 从当前擂主的 prompt 出发，一轮只改一处
- 训练集：错题、打分理由和得分全部可见
- 验证集：只给得分，看不到错题
- 各维度全面超过擂主才晋升，否则整轮丢弃
- 第 1 轮的成绩就是基线，指数记作 100

第 1 轮评测

验证集指数（基线 = 100）

100

初始擂主

后面每一轮，都要在验证集上赢过它。

第 2 轮 · 新增三类规则：验证集得分下降

四轮打擂台
基线 = 100

R1	R2	R3	R4
100	99.6	—	—
擂主	未晋升		

改动摘要 · 第 1 轮 → 第 2 轮

+ 增加任务分流

区分任务类型，
明确回答顺序与输出要求

+ 增加事实约束

限制缺乏依据的确定性表述
和精确结论

+ 增加回答完整性要求

为不同任务补充统一的
信息覆盖清单

第 2 轮评测

验证集指数（基线 = 100）

99.6

训练集 101.6 · 相对擂主 −0.4%

未晋升

第 3 轮 · 部分撤回：验证集得分继续下降

四轮打擂台
基线 = 100

R1	R2	R3	R4
100	99.6	98.0	—
擂主	未晋升	未晋升	

改动摘要 · 第 2 轮 → 第 3 轮

- **撤回新增的完整性框架**
  不再统一要求各类回答
  覆盖固定清单
- **撤回新增的通用补充规则**
  减少与当前任务关联不强的
  补充内容

+ **调整任务完成方式**
  明确任务直接给出结果，
  减少额外追问和扩展

第 3 轮评测

验证集指数（基线 = 100）

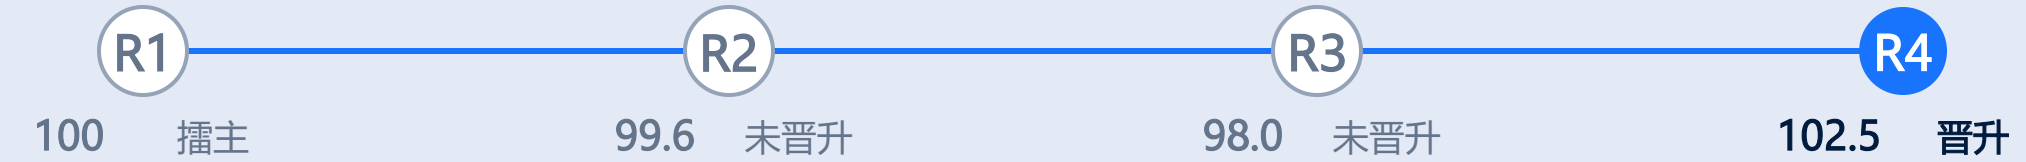
98.0

相对擂主 **−2.0%** · 四轮里的最低点

未晋升

第 4 轮 · 精简至核心规则：验证集分数上升，晋升擂主

四轮打擂台
基线 = 100



第 4 轮改动摘要

- 撤回新增的信息补充限制
- 撤回新增的领域判断细则
- 撤回新增的措辞禁用清单
- 撤回新增的固定补充要求

= 本次新增规则精简为核心任务分流

按任务类型组织回答，
满足明确的输出要求

第 4 轮评测与最终指标

验证集指数（基线 = 100）

102.5

相对擂主 +2.5% · 晋升为新擂主

五维不退（线上基线 = 100）

正确性	全面性	安全性	易读性	实用性
102.5	103.1	100.0	100.6	102.1
		持平		

这个版本经过人工复核后上线实验。

03

Loop 架构：多 Agent 协同处理

外循环任务流转与内循环修复验证

修复和验证只需数小时，badcase 的平均修复耗时仍为 12.6 天

修复并验证一类问题

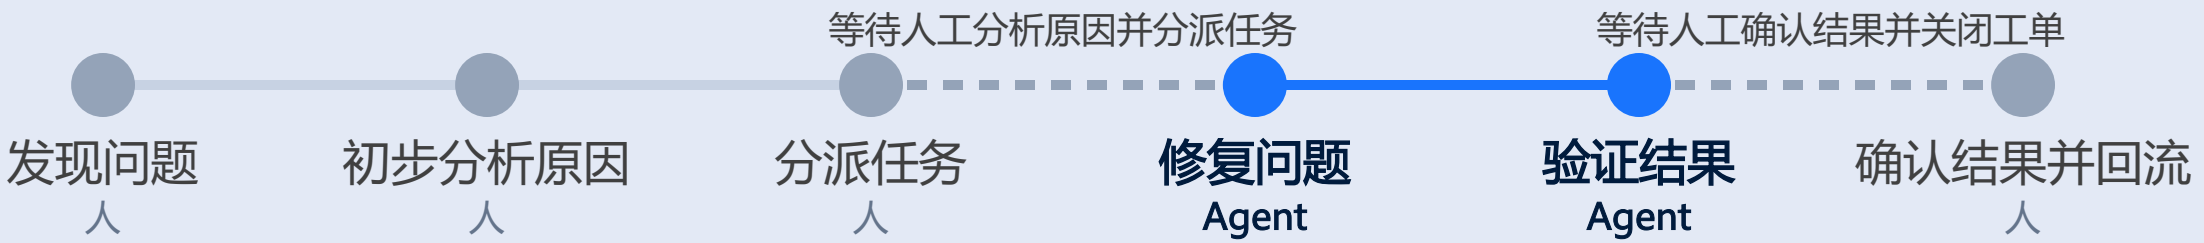
数小时

人工全职处理约需 3 人日，Agent 处理只需数小时

从登记问题到标记修复

12.6 天

badcase 的平均修复耗时

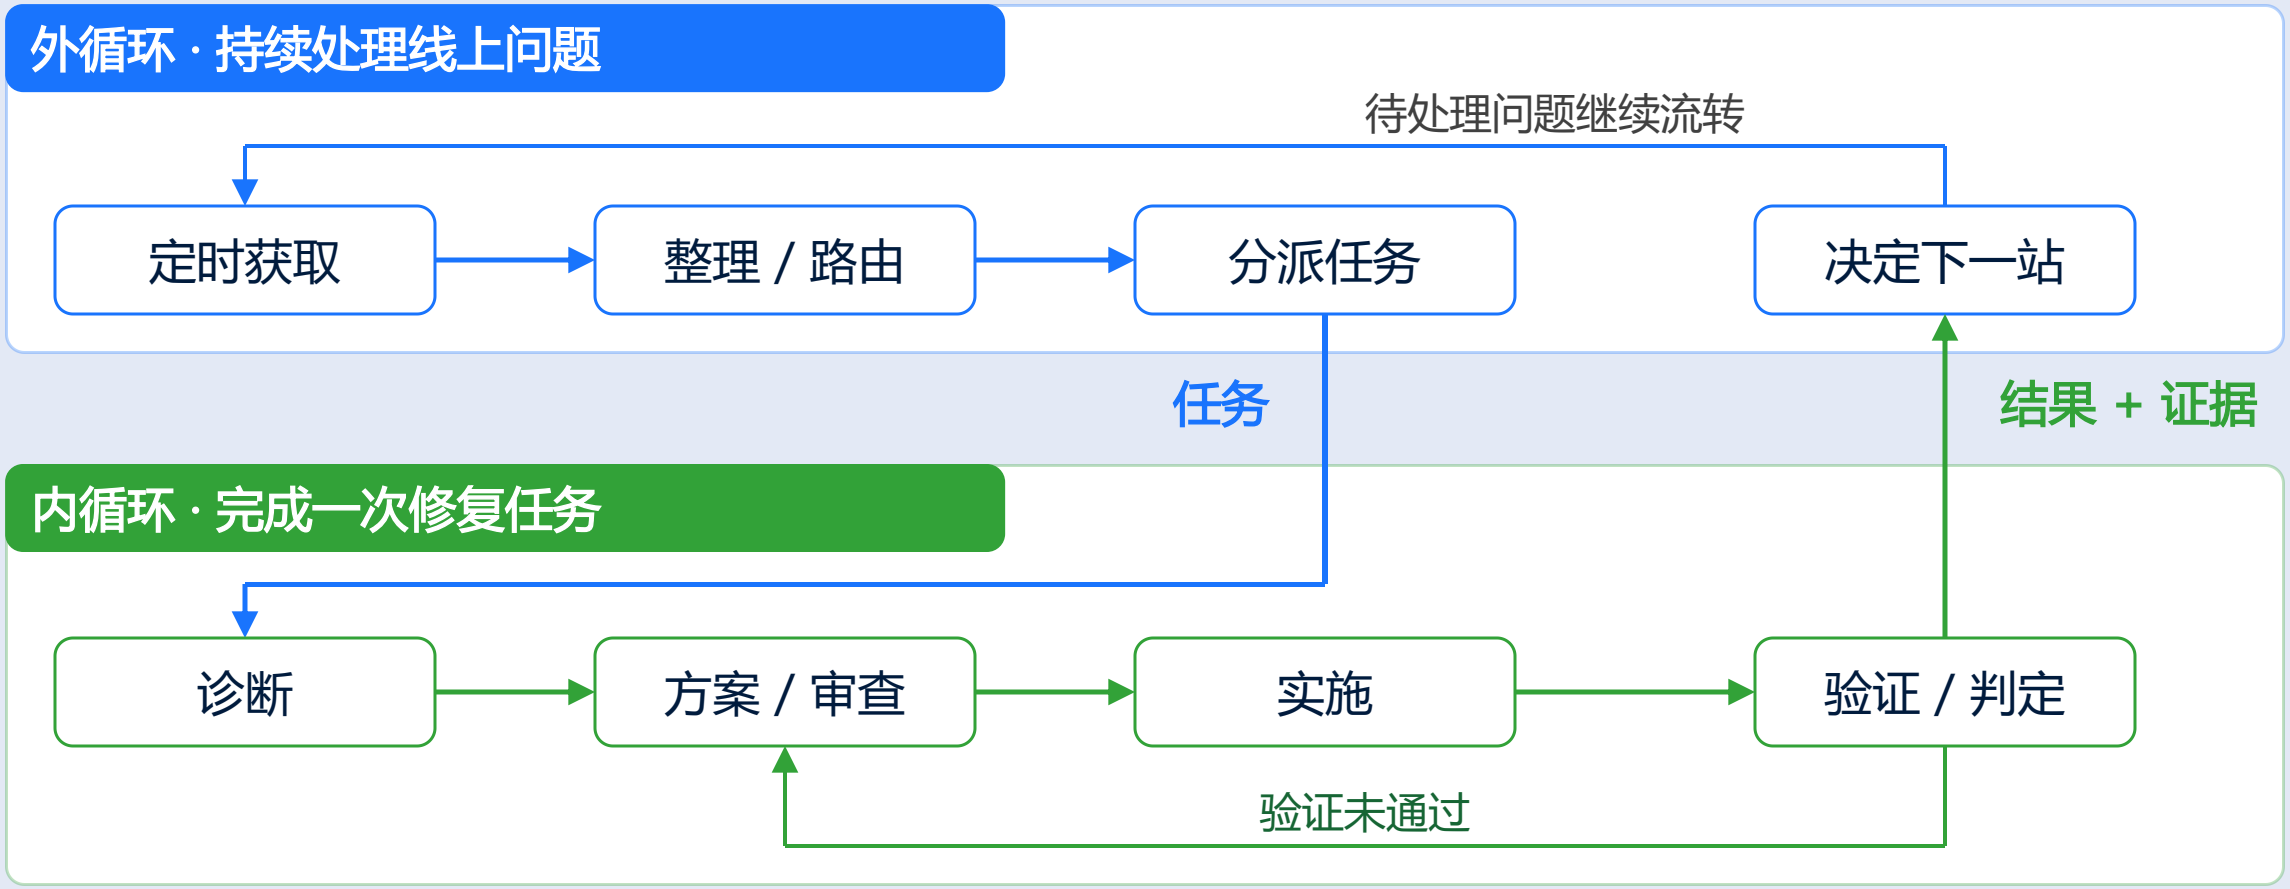


人工推进任务，并记录任务进度和下一步执行者

问题需要等待人工分析原因、分派任务和关闭工单。人工无法持续介入时，Agent 也停止推进。

Agent 已加快修复和验证。问题在步骤之间的衔接仍未自动完成。

Loop 整体架构：外循环调度与内循环修复



选择协作平台：能力要求与 Multica 实现

明确平台能力要求

① 复用运行稳定的 Harness
接入 Claude Code、Codex 等现成工具

② 跨会话保留任务
当前会话未完成的任务可在后续规划中继续进行

③ 衔接多个 Agent 的任务
各 Agent 按分工执行任务并交回结果

④ 自动启动循环
无需人工每天分配任务

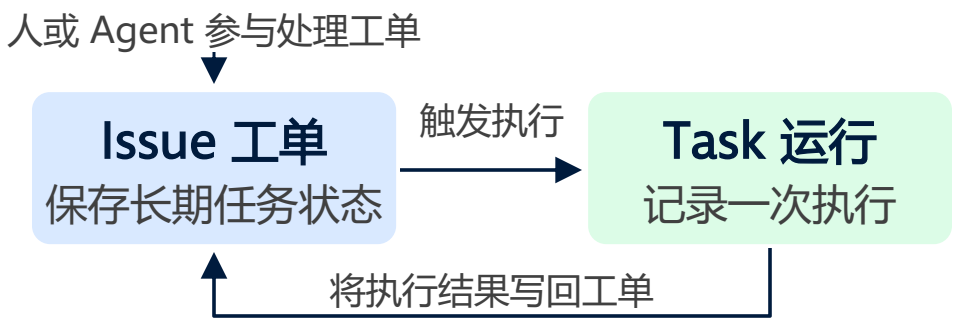
使用 Multica 组织协作

Runtime 运行时

电脑或云主机 ⟷ Claude Code / Codex

Workspace 工作区

Agent、小队和定时任务围绕工单协作



平台管理工单和 Agent 运行。我们定义路由规则、审查规则和人工介入条件。

双循环的角色分工与小队配置

全局控制小队 · 外循环

2 个 Agent

全局调度器

创建工单，分派给对应小队

入池执行器

整理 badcase，
去重并初步归因

修复小队 · 内循环

5 个 Agent

协调者

跟进任务，根据结果安排下一步

方案设计者

查明根因，提出修复方案

审查者

检查方案依据和验证计划

实施者

按通过审查的方案完成修改

验证者

运行评测，汇报结果与证据

钉钉通知器 两队共享 · 1 个 Agent　通过钉钉同步进展、发送待办并接收反馈

04

端到端案例：修复与回流

从问题诊断、方案审查到独立验证与失败回流

问题入池：去重、初步归因与路由分组

全局控制小队 · 入池执行器

入池 → 派单 → 问题诊断 → 方向确认·审查 → 实施 → 验证·判定 → 终态回流

某次批处理

定时任务唤醒

全局调度器

检查本批次结果

缺少有效入池结果

委派

入池执行器

拉取候选 → 跨工单去重 → 初步归因分组 → 写回

404 条候选

323 条纳入分发

去掉 81 条重复项

16 个路由组

按初步归因标签归并

本批次结果与证据

再次被唤醒

任务分派：入池验收与工单路由

全局控制小队 · **全局调度器**

入池 → **派单** → 问题诊断 → 方向确认·审查 → 实施 → 验证·判定 → 终态回流

入池结果写回后，调度器再次被唤醒，先验收，再按规则分发。

入池结果

323 条

16 个路由组

本批次结果与证据

全局调度器

① 验收入池结果

② 匹配标签和规则

③ 创建对应工单

路由去向

Prompt / 代码可解

通用修复小队

检索类

RAG 小队

模型能力类

暂不处理

完成分发后，调度器进入等待；接下来跟着“重复追问”工单进入修复小队。

定位跨轮次重复追问的根因

修复小队 · **队长 + 方案设计者**

入池 · 派单 · **问题诊断** · 方向确认·审查 · 实施 · 验证·判定 · 终态回流

查看典型对话

线上 Agent：你明天能联系上医生吗?

用户：不行。

几轮后，线上 Agent：明天能否再次尝试联系医生?

重新检查回答生成链路

1. 定位问题发生阶段：
   生成最终回答
2. 排除工具和检索增强生成：
   两者均未参与
3. **确定问题根因：**
   主提示词缺少规则

线上 Agent不应在不同轮次中换用其他表述，重复追问同一问题。

方案决策：人工确认方向与独立审查

修复小队 · **方案设计者 · 人 · 审查者**

入池 · 派单 · 问题诊断 · **方向确认·审查** · 实施 · 验证·判定 · 终态回流

1 **候选落点**
主 prompt / reminder

2 **人工定方向**
先改主 system prompt

3 **方案细化**
根因·取舍·范围
验收·回滚

4 **独立审查**
根因·范围·样本风险
验证计划

5 **解锁实施**
按批准范围执行

人工确认

“先改 system prompt，效果不好再加 reminder。”

2 小时内未收到回复时，定时唤醒协调者。
协调者按预设方向继续推进方案流程。

首轮批准范围

只改主 system prompt 中的「追问原则」

本轮不改：
reminder、黑名单、后处理
工具、Skill、RAG、路由及其他场景

修复实施：在主 Prompt 中约束重复追问

修复小队 · **实施者**

入池 · 派单 · 问题诊断 · 方向确认·审查 · **实施** · 验证·判定 · 终态回流

改动要点

用户已经回答的信息，
不再换一种说法追问。

只追问影响判断的新信息，
必要的安全提醒仍然保留。

修改范围限定在主 prompt 的追问规则。

已知回答：用户明天无法联系医生。

改前 · 几轮后重复追问

明天能否再次尝试联系医生？

期望行为 · 沿用已有信息

不再追问明天能否联系医生。

实施交接

1. 创建分支
2. 提交改动
3. 部署到回测环境
4. 交给验证者

独立验证：97 条通过，3 条仍失败，继续跟踪

修复小队 · 验证者

入池 · 派单 · 问题诊断 · 方向确认·审查 · 实施 · 验证·判定 · 终态回流

1 → 2 → 3 → 4

核对部署版本
确认回测环境中的版本
与实施者部署的一致

回测目标样本
每条样本回测 3 次，
3 次均通过才判定为通过

执行基线评测
检查其他能力是否退化

将验证结果交回协调者
协调者裁决验证结果

回测目标样本

100	97	3
目标样本	通过	仍失败

评测全量基线

通过

候选版本的评测总分
不低于线上基线的评测总分

将验证结果交回协调者 → 任务进入待评审状态，等待人工评审和合入

失败案例：修改 prompt 未能解决上游数据冲突

修复小队 · 验证者

入池 · 派单 · 问题诊断 · 方向确认·审查 · 实施 · 验证·判定 · 终态回流

对照用户问题与回答

有哪些可以看儿童口腔问题的医院?

回答涉及的医院

某口腔专科医院

模型回答：**三级甲等医院**

正确答案：

三级口腔专科医院

核对相互冲突的检索证据

总院信息

三级甲等

分院信息

三级

第三方网页

三级甲等

应用 prompt 约束（已生效）

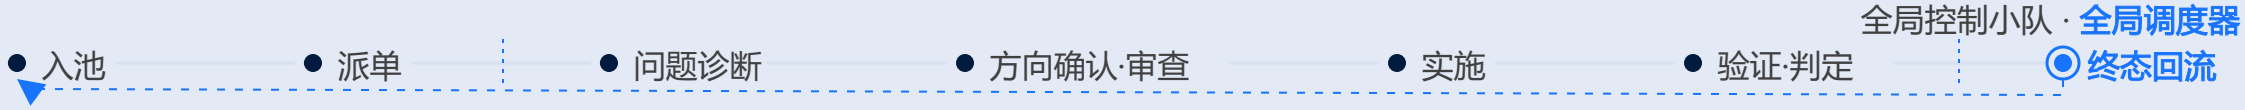
模型仅依据工具结果或明确来源，回答医院等级和排名。

来源冲突时，模型不补全缺失信息，不提高医院等级，不给出精确排名。

0 / 3

三次回测全部失败

终态回流：基于失败证据重新路由





通用修复小队

判定本队无法根治

建议：数据或检索侧

证据：阻断样本
约束已生效 · 回测仍 0/3

全局调度器

接收终态和证据

按路由表确定归属

创建新工单并重路由

RAG 小队

接收新工单

接收完整证据包

继续处理上游数据问题

05

实践效果与落地经验

处理效率、覆盖边界与工程教训

当前效果：覆盖约 20% 的 badcase，1–3 天形成可复核结果

比较问题处理周期

开篇数据：badcase 的平均修复耗时为 12.6 天

以往由人工处理
登记问题 →
将问题标记为已修复

Loop
问题进入队列 →
问题达到可复核的
最终状态



覆盖线上 badcase

约 20%

的线上 badcase 已通过 Loop 处理

已覆盖：代码 bug · prompt · 工具描述

暂未覆盖：模型能力 · 检索事实错误



我们正在继续提高覆盖率

提高覆盖率

- 建设业务知识库
- 增加专项小队
- 自动积累修复经验

让 Agent 自主工作的两条经验

Agent 按指标优化时，怎么防止刷分作弊?

作弊方式

Agent 针对单道错题修改 prompt，
例如加入：

> 无来源时，不得虚构“降低 89%”

做法

- 训练集返回错题、扣分理由和得分，验证集只返回得分
- 评测集的上限就是优化的上限

多 Agent 的工作怎么拆分?

内循环的步骤和 Agent

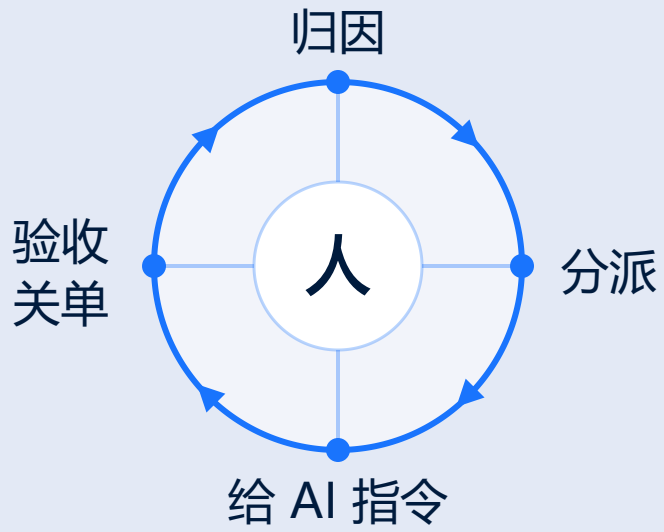


做法

- 合并：方案设计者完成诊断和方案设计，保留完整的判断依据
- 拆开：方案设计者不审查自己的方案，实施者不验证自己的修改

人机协作：从人向 AI 分派任务，到 AI 向人请求决策

过去 · Human-in-the-loop



每一步都靠人推进

现在 · Human-on-the-loop



关键节点由人决策

Agent 串联流程并记录状态；人保留关键决策权并承担责任。

实施自动化评测 → 构建 Harness → 接入 Loop

按三步实施

1 → 2 → 3

先实现自动化评测

完成修改后，
能自动验证修改效果

基于现成 Harness 跑通任务

以 Claude Code、Codex 为基础
按需配置工具、提示词与 Skill
跑通修复与验证流程

通过定时任务接入 Loop

将人工触发改为定时触发
让 AI 自动循环执行任务

运用两个技巧

使用能力最强的模型

任务失败时，先排查模型，
再检查任务设计和环境。

指导 AI 执行任务

先指导 AI 完成一次任务，
再让 AI 将执行过程总结为 Skill。

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

Harness 让每一步可靠，
Loop 让整个系统持续运转

Q&A

肖汉松 / 蚂蚁集团 阿福 Harness 架构组负责人

