QCon
全球软件开发大会

InfoQ 技术大会

智能路由：选型与生产实践

阶跃星辰开放平台

2026-09-06 原稿 · 2026-10-17 增补



01

智能路由成立的三个前提

Part 01 · Why

智能路由要成立，依赖三个前提

尺寸差

小模型通常更快、推理成本更低；大模型承担更复杂的工作。

同尺寸也分岔

数据配方、架构设计、推理引擎适配，改变能力、价格与速度。

harness × 目标任务

同模型、同思考力度，换执行框架，部分场景成本差 2 倍以上而质量不变。

1.1 尺寸差：计算与资源是两本账

简化估算有架构与 batch 前提，最终回到任务实测

激活参数 → 边际成本

每 token 算力约为 2 倍激活参数；decode 吞吐上限约为显存带宽 / 激活权重体积。

总参数 → 固定成本

MoE 稀疏主要省计算；常见高性能部署仍需在集群中存放专家权重。

27B 与 13B / 284B

稠密 27B 每 token 算力，约为激活 13B、总参 284B MoE 的 2.1 倍。

1.2 同尺寸候选：分数之外看效率

同一批任务的匿名样本；设置与错误率分母待核实

评测	X	X-v1	Y	Y-v1
某 BMK	42	52	45	57
总 token	260M	260M	130M	140M
工具调用错误率	0.39%	0.01%	2.78%	2.58%

1.2 相同模型，供应商差距也很大

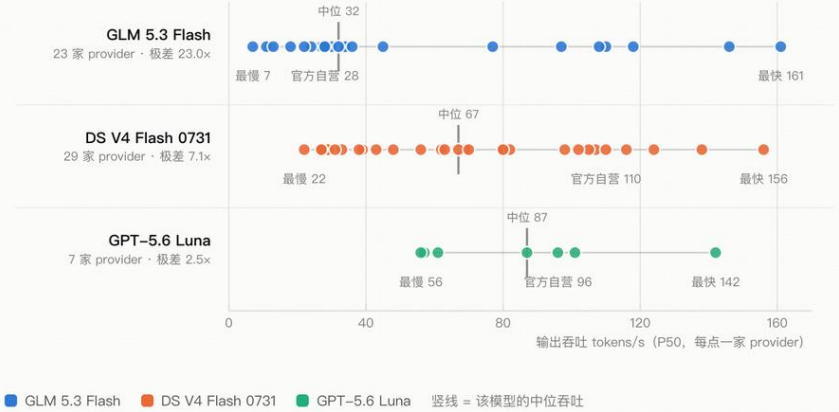
同权重、同挂牌价，吞吐差 23 倍 · OpenRouter provider P50 · 2026-09-06 历史采样

越多，离散度越大。

图 3

同一份权重、同一个挂牌价，换一家托管商速度差 23 倍

OpenRouter 各 provider 的 P50 输出吞吐；GLM 5.3 Flash 与 DS V4 Flash 是开放权重，Luna 只有官方与云厂自营



组合的价值来自互补，而不是数量

整合不同团队积累

组合不同厂商的模型，是利用它们训练与部署中的数据、算力和人才。

偏差度越大，越适合路由

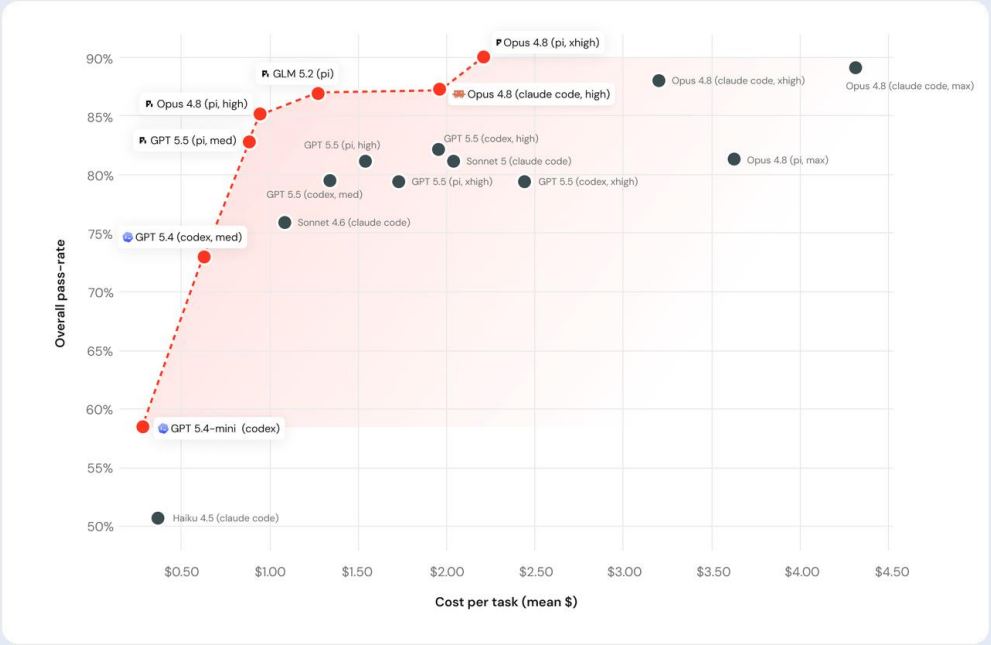
十个模型同样失败，未必胜过两个各有所长的模型。

选型要看错误重叠

哪些任务只有 A 做对，哪些只有 B 做对？互补性比单一排名更有意义。

1.3 模型与 harness 必须联合评测

Databricks 千万行级代码库内部基准 · 横轴每任务成本 / 纵轴通过率 / 红线帕累托前沿



1.3 “谁更便宜”是联合属性

框架改变成本弹性

同模型、同思考力度，部分场景每任务成本差超过 2 倍而质量不变；Pi 每轮上下文少约 3 倍。

单价便宜 ≠ 任务便宜

Sonnet 5 单价便宜 1.7 倍，每任务却为 $2.09 对 $1.94，完成率低 6pp。

成本排序也会翻转

同两个模型比较：Hermes 上贵 32%，Kilo 上贵 57%，Claude Code 上便宜 16%。

真正的命题：匹配模型 + harness

不充分的简化

“难的给大模型，不难的给便宜模型”只考虑了复杂度。

复杂度不是全部答案

长上下文不一定需要复杂推理；短指令也可能推进大型工程。

路由的是执行方案

把适合的任务，交给适合的模型 + harness，并满足质量、预算与供给约束。

02

动手之前，先把目标定下来

Part 02 · What · 目标与供应链

2.1 从 tokenmaxxing 到 benchmaxxing

从把 token 用满，到给定效果下把 token 用对。

用对 token

没有可验证的“同样效果”，路由就是赌博。

目标范围可控

公开基准可能污染，也不代表真实业务负载。

用自己的目标

coding 与 working，是两套不同的评价函数。

先分目标类型

2.1 构建目标：来源与防污染

Databricks 方法参考：从自家已合并 PR 生成任务

环节	具体做法
任务来源	近期历史、人 review 过的代码，配有能验证变更的高质量测试
任务改写	将 PR 重写为明确的问题与约束，删掉解法描述
三道护栏	全部人工评审；不用 LLM judge 判正确性；运行期间封存 git 历史

2.1 构建目标：分类型、记成本

目标	验收方式
coding	测试是否通过、变更是否可合并、构建是否成功；可自动评分
working	人的接受度：格式、术语、完整性、风险；人工或规则 + 业务约束 + 模型复核
共同要求	每任务成本和质量一起记录；不记成本，就无法验证路由收益

2.2 供应链：三个波动的量

运行时状态而非静态配置；不同变化节奏应分别监测

维度	原稿样本 / 幅度	来源
成本	谷 $0.22 / 峰 $0.44，2 倍	分时定价、折扣与缓存政策
速度	7 → 161 tokens/s，23 倍	部署、并发与批处理
稳定性	工具错误率 0.01% → X%，以及 5xx	上游故障、版本灰度
共同点	实时采样，不写死配置	价格、健康与模型行为分别监测

03

路线、场景选型与建设取舍

Part 03 · How

3.1 会话一致性是第一条硬约束

缓存代价

换模型或不共享缓存的端点，可能重新支付长前缀输入成本。

行为漂移

命名、格式、工具协议与上下文理解可能变化。

默认绑定，必要时交接

切换必须有状态交接、预算与验证；正常绑定与检查点 → 故障恢复 → 一致性验收。

模式	适合关注点	实际含义
`auto/balanced`	大多数通用场景	在任务适配、成本和运行状态之间综合权衡
`auto/cheap`	大批量、成本敏感任务	只在能力充分的候选中偏向更低的成本尺度
`auto/fast`	交互式、低延迟场景	在有效运行样本基础上偏向更好的首个非空响应体延迟与健康状态
`auto/quality`	复杂推理、关键任务	在能力充分的候选中优先考虑任务适配程度

3.1 档位不是全模型搜索

每档 1 主力 + 1 验证备用是工程建议；离线候选池 → 在线供给选择 → 会话绑定版本

cheap

质量过线后，比较完整任务成本；包含缓存、重试与平台费用。

fast

区分首字延迟与完工延迟；在合格池里按服务状态选择端点。

quality

用自有 eval 定义质量门槛，不默认选择参数最大的模型。

3.2 面向 task 的三条技术路线

选择式与协作式分别评测；共同验收：质量过线 + 完整任务成本

路线	谁决策	能力上限	主要代价
分类器	规则 / 本地小模型	逐任务候选可达边界	分类精度、冷启动数据
Advisor	executor 判断求助	协作效果单独评测	漏判误判、流式暂停
小模型路由器	训练复杂度预测器	逐任务候选可达边界	数十万条真实 turn

3.2 路线一：分类器的三种做法

本地决策、毫秒级、可解释，成本低但非零；备注另述监督学习，保留原稿口径差异

硬规则路由

长上下文 / 复杂推理 / 多模态给大模型；FAQ / 翻译 / 摘要 / 分类给小模型。

任务分类路由

判断请求属于哪类任务，再按类别选择模型。

语义相似度路由

query 向量检索历史相似请求，参考当时哪个模型效果更好。

3.2 路线二：Advisor 的历史样本

小模型执行，关键节点请教大模型 · 原稿引用 Anthropic 数据，基线仍需核对

组合	效果	成本
Sonnet + Opus advisor	SWE-bench Multilingual +2.7pp	每 agentic task 降 11.9%
Haiku + Opus advisor	BrowseComp 19.7% → 41.2%	比 Sonnet solo 便宜约 85%
阶跃 step-router-v1	自建 BMK 能力提升 15%	5% 的额外请求

3.2 Advisor：接口简单仍需验收

同一请求内部

模型切换封装在一个请求内部；客户端没有额外往返。

可见建议 400–700 token

可见建议长度，不等于全部子推理的消耗；计算、时间和钱仍需入账。

阶跃对应能力

step-router-v1：切换 model；历史指标非本次复测，不承诺当前产品可用范围。

3.2 Advisor 不是自动最优的黑盒

该求助没求助会退化；不必求助却调用会增加成本与延迟。

漏判 / 误判

子推理不流式，前台会停顿；判断本身也消耗 token。

流式与预算

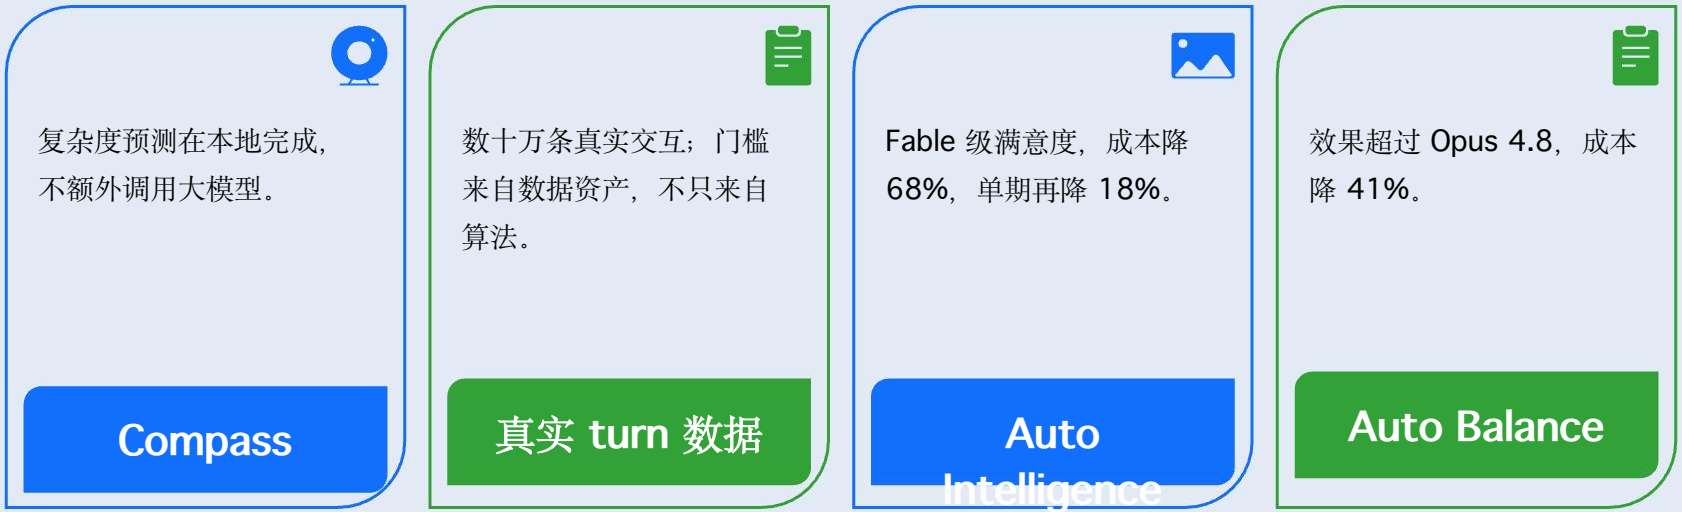
executor 较大时，针对路由任务后训练的代价很高。

后训练代价

单轮、极短或每步都需强模型的任务，直接用强模型更简单。

不适合的任务

3.2 路线三：专门训练路由器



Cursor Router · 2026-08-06 原稿披露口径，未独立复核；注意反事实缺失

04

从会选模型，到做好路由产品

Part 04 · 决策信号 → 用户默认项 → 判断与控制 → 总账验收

4.1 Auto：沉淀“我的任务默认项”

从替新用户做第一次选择，到保存老用户经验；默认项可解释、可修改、可关闭



4.1 选择表达偏好，结果验证效果

留什么

任务特征 / 候选与建议；用户选择与覆盖原因；质量、成本、延迟与返工。

怎么用

显式选择优先于自动推荐；按任务建默认项，不贴死标签。

产品边界

经用户授权、最小化留存；选择不直接当成功标签；默认不留敏感原文，并支持删除和退出。

4.2 好的路由，是持续迭代的方案

专业名词解释 ≠ 系统设计；领域相同，能力要求不同。

任务分类

同样一句“继续”，可能在推进，也可能在返工。

状态判断

速度 / 质量 / 风格权重不同；同一任务也有不同选择。

用户偏好

模型、价格和任务分布变化，旧边界需要不断更新。

持续校准

分别建模任务、状态与偏好，再用真实结果持续校准

4.3 路由做得好不好，最终看任务总账

净收益 = 路由节省 − 决策 / 切换 / 重试等开销

规则 / 本地小模型

本地推理 + 部署维护；成本低，但不是零。

LLM 判断

额外调用 + 网络等待；准确之外，更要算净节省。

Advisor 协作

子推理 + 误判升级；设置预算与调用边界。

4.3 验收净收益，而不是便宜调用占比

警惕单向变贵

只升不降，以及“升档更保险”的反馈偏置；不满意有反馈，可以更便宜却常被忽略。

同一套 eval

质量不降，完整任务成本下降；不存在通用的固定决策成本占比门槛。

守住交付指标

同时守住完工延迟与稳定性；缓存损失、重试和返工也要入账。

选得合适、运行可控、总账划算

先定义效果

用自己的任务与 eval，明确什么叫“足够好”。

再设计执行

综合模型、harness、供给与偏好；做好预算、会话绑定与恢复。

最后验收总账

质量守住，完整任务成本下降；延迟与稳定性达标。



阶跃后续计划：开放工具，共建路由评测与数据；持续开源相关模型，降低建设门槛

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

阶跃星辰开放平台

智能路由：选型与生产实践 · 2026-10-17 增补

